

Hệ thống hỏi–đáp có trích dẫn trên kho tin NewsQA

Báo cáo thực nghiệm Phase 1 và Phase 2

Nhóm Text Mining

Học kỳ 3 — Năm 3

Abstract

Báo cáo trình bày quá trình xây dựng và tinh chỉnh một hệ thống RAG hỏi–đáp có trích dẫn trên 11.064 bài báo CNN. Công việc chia làm hai giai đoạn tách bạch: Phase 1 chọn cách truy xuất đoạn văn bằng một giải đấu phân tầng 23 cấu hình, Phase 2 chọn cách ra lệnh cho LLM sinh câu trả lời bằng một quy trình đăng ký trước có guardrail. Cấu hình cuối cùng — BGE-M3 sparse → bge-reranker-large → prompt P2 với 5 đoạn context — đạt Answer Correctness **0,7157** trên 284 câu held-out chưa từng bị chạm tới, chạy đúng một lần. Điểm phương pháp trọng tâm của báo cáo không nằm ở con số đó mà ở việc phân tách được *lỗi truy xuất* khỏi *lỗi sinh*: toàn bộ khoảng cách giữa tập tinh chỉnh và tập held-out quy về việc truy xuất khó hơn, không phải prompt bị overfit.

1 Bài toán và cách chia việc

Hệ thống nhận một câu hỏi bằng tiếng Anh, tìm trong 22.766 đoạn văn (cắt từ 11.064 bài báo CNN) những đoạn nhiều khả năng chứa câu trả lời nhất, rồi để một LLM viết đáp án *chỉ dựa trên* các đoạn đó, kèm số trích dẫn [n] trở về đoạn đã dùng.

Dự án tách làm hai giai đoạn vì hai nửa của đường ống hồng theo hai cách khác nhau và phải đo bằng hai loại thước khác nhau.

	Phase 1 — lấy đoạn văn	Phase 2 — hỏi LLM
Hồng kiểu gì	Không tìm ra đoạn chứa đáp án	Tìm ra rồi nhưng trả lời sai, hoặc bịa
Đo bằng gì	Hit@k, nDCG@5, MRR@5	Answer Correctness, Faithfulness, Citation
Chi phí	GPU, không gọi API	Tốn tiền API mỗi lần chạy
Tái lập	Có, nhờ chỉ mục cố định	Chỉ trong giới hạn nhiễu của LLM

Thứ tự là bắt buộc: Phase 1 phải khóa xong trước khi Phase 2 bắt đầu. Nếu vừa đổi cách lấy đoạn vừa đổi cách hỏi thì không có cách nào quy được cải thiện về nguyên nhân nào. Cụ thể hơn, Phase 2 chạy lại trên một **vết truy xuất đã đóng băng**: cùng một danh sách đoạn đã xếp hạng cho mọi cấu hình sinh, nên mọi khác biệt quan sát được đều thuộc về tăng sinh.

1.1 Dữ liệu và những gì EDA phát hiện

Giai đoạn khảo sát dữ liệu không phải bước trang trí — nó viết sẵn giả thuyết cho từng vòng thí nghiệm về sau, và đặt ra ngưỡng phán quyết.

Phát hiện	Hệ quả lên thiết kế thực nghiệm
Nhân nhiều 7,0%–24,5%	Chênh lệch dưới 7,0% không được coi là thắng
Trung vị 25 đoạn đối thủ cùng chủ đề cho mỗi câu hỏi	Reranker là bắt buộc, không phải tùy chọn
Câu hỏi neo vào tên riêng, ngày tháng, con số	Dự đoán sparse thắng dense, <i>trước</i> khi đo
4.603 bài bị cắt mất phần đuôi	Dựng lại kho: 19.263 → 22.766 đoạn
Notebook cũ đặt JUDGE_MODEL = GENERATOR_MODEL	Tách judge sang nhà cung cấp khác generator

Biên độ nhiễu 7,0%. EDA ước lượng được rằng 7,0%–24,5% số câu trong tập đánh giá mang nhãn có vấn đề — đáp án chuẩn không đầy đủ, hoặc có nhiều span đúng nhưng chỉ một được ghi nhận. Hệ quả trực tiếp: một cấu hình hơn cấu hình khác dưới 7,0% thì khoảng cách đó *có thể* hoàn toàn do nhiễu nhãn. Toàn bộ báo cáo áp dụng luật phán quyết hai điều kiện:

Một cấu hình chỉ được tuyên là thắng khi **(1)** khoảng cách vượt biên độ nhiễu 7,0%, và **(2)** khoảng tin cậy 95% của hiệu *theo cặp* không chứa 0. Có ý nghĩa thống kê là điều kiện cần, không phải điều kiện đủ.

Hai cách đọc cùng một tập câu hỏi. Nhiều câu hỏi NewsQA không đứng độc lập được — chúng được viết như đang nói tiếp một cuộc hội thoại (“*How many were killed?*”). Tỷ lệ câu phụ thuộc ngữ cảnh giảm từ 57,5% xuống 11,3% sau khi giải quyết tham chiếu. Bản **original** **thiên vị sparse**: câu hỏi càng cụt thì khớp từ vựng càng có lợi thế giả tạo. Vì hệ thống thật luôn nhận câu hỏi đầy đủ ngữ cảnh, mọi số chính trong báo cáo đo trên tập resolved; original chỉ dùng làm cận dưới.

Bootstrap theo cặp, gom theo bài báo. Nhiều câu hỏi cùng trỏ về một bài báo, nên chúng không phải quan sát độc lập. Mọi khoảng tin cậy trong báo cáo tính bằng bootstrap phần trăm *theo cụm bài báo*: mỗi lần lấy mẫu bốc lại nguyên một bài kèm toàn bộ câu hỏi của nó (2.000 mẫu, seed 42). Coi từng câu là một lần bốc độc lập sẽ làm khoảng tin cậy hẹp hơn thực tế.

2 Phase 1 — Chọn cách lấy đoạn văn

2.1 Thiết kế: giải đấu phân tầng

Lưới đầy đủ của các lựa chọn (retriever × reranker × kích thước chunk) là 72 tổ hợp. Thay vào đó, dự án chạy một giải đấu ba vòng, mỗi vòng chỉ đưa quán quân đi tiếp — tổng cộng 23 cấu hình.

Vòng	Thử gì	Thắng
1	4 mô hình dense × 4 mô hình sparse	BGE-M3 learned sparse
2	3 retriever × 3 reranker	+ BAAI/bge-reranker-large
3	3 kích thước chunk (256/512/1024)	512/64 — <i>không ai thắng rõ</i>

Đây là một đánh đổi có ý thức và cần nêu rõ: cách này rẻ hơn nhiều lần, nhưng **không phát hiện được tương tác** giữa các lựa chọn ở hai vòng khác nhau. Ví dụ, khả năng một mô hình dense nào đó phối hợp đặc biệt tốt với chunk 1024 sẽ không bao giờ được kiểm tra, vì dense đã bị loại từ vòng 1.

2.2 Vòng 1 — Sparse áp đảo dense

So sánh (nDCG@5, resolved, 281 câu)	Δ	CI95
BGE-M3 sparse vs e5-base-v2 dense	+0,1634	[+0,1231; +0,2080]
BGE-M3 vs BM25-okapi-stemmed	+0,0194	[−0,0125; +0,0508]
e5-base-v2 vs bge-small-en-v1.5	+0,0094	[−0,0261; +0,0448]

Chỉ dòng đầu vượt được cả hai điều kiện phán quyết. Khoảng cách +0,1634 lớn hơn biên độ nhiễu 7,0% và khoảng tin cậy không chứa 0. EDA đã giải thích trước vì sao: câu hỏi NewsQA bám vào tên riêng, ngày tháng và con số — đúng thứ mà khớp từ vựng bắt được chính xác, còn embedding dày đặc thì làm nhòe đi thành “ý nghĩa gần giống”.

Hai dòng sau có khoảng tin cậy **chứa 0**. Không phân định được BGE-M3 với BM25 đã stem, và cũng không phân định được hai mô hình dense với nhau.

Không tồn tại “mô hình dense tốt nhất” trong thí nghiệm này, và đó tự nó là một kết quả cần báo cáo. Xếp hạng chúng theo số thập phân thứ ba sẽ là đọc nhiễu thành tín hiệu.

2.3 Vòng 2 — Reranker, và một kết quả phủ định

Reranker cross-encoder thêm +0,0659 nDCG@5, lọc top 20 xuống top 5. Mức cải thiện này được EDA dự báo trước: với trung vị 25 đoạn đối thủ cùng chủ đề cho mỗi câu hỏi, việc xếp hạng lại bằng một mô hình đọc được cả cặp (câu hỏi, đoạn) là bắt buộc.

Hybrid dung hợp dense và sparse **không chứng minh được là có lợi**. Cần phát biểu chính xác: kết quả là “không chứng minh được có lợi”, *không phải* “đã chứng minh có hại”. Trong điều kiện dense yếu hơn sparse tới +0,1634 nDCG@5, việc trộn một tín hiệu yếu vào một tín hiệu mạnh khó có đường tạo ra lợi ích.

2.4 Vòng 3 — Một kết quả null

Chunk 512 / 64	0,8976
Chunk 1024 / 128	0,8862
Chunk 256 / 32	0,8507
Khoảng cách cao nhất – thấp nhất	0,0469

0,0469 nằm dưới biên độ nhiễu 7,0%, và cả ba khoảng tin cậy chồng lẫn nhau. Không có cơ sở thống kê để xếp hạng ba cấu hình này.

Lý do nằm ở phân bố độ dài bài báo: sau khi phục hồi, trung vị vẫn là 724 token mỗi bài và **75,9% số bài vẫn chỉ có tối đa 2 chunk**. Với ba phần tư kho ngữ liệu, bài toán tìm đúng chunk gần như đồng nhất với bài toán tìm đúng bài báo, nên dư địa để chiến lược chunking tạo khác biệt là rất hẹp. Việc chọn 512/64 dựa trên lý do vận hành — không quá ngắn khiến câu trả lời bị cắt đôi, không quá dài gây loãng và tốn token ở Phase 2 — chứ không phải vì nó thắng.

2.5 Ablation bổ sung — Contextual chunking

Ba vòng trên so sánh **retriever**, nhưng luôn trên **một cách biểu diễn dữ liệu duy nhất**: mọi chỉ mục đều dựng từ chunk[“text”] và không gì khác. Nói cho chặt thì kết luận “sparse thắng dense” là “sparse thắng dense *trên cách biểu diễn này*”. Ablation đổi cách biểu diễn rồi đo lại.

Giả thuyết đến từ phân bố ở mục trước: bài báo trung bình cắt thành 2,06 chunk, và chunk đầu tiên mở đầu bằng chính bài báo nên tự nó có ngữ cảnh. Các chunk tiếp nối thì đến tay retriever mà không mang dấu hiệu nào cho biết chúng thuộc câu chuyện gì. Can thiệp: nối 160 ký tự đầu bài báo vào trước mỗi chunk tiếp nối. Số chunk được sửa khớp chính xác với số chunk tiếp nối — $22.766 - 11.064 = 11.702$ (51,4%), nên không chunk đầu bài nào bị đụng tới.

Đây là *contextual chunking*, không phải *metadata indexing*. Ý tưởng ban đầu là index thêm metadata, nhưng dataset này không có metadata thật: url, author, publish_date đều rỗng do chunker gán mặc định, publisher là hằng số "CNN", và metadata.title **không phải headline** — nó là 160 ký tự đầu của chính body, đã kiểm là tiền tố của body ở 200/200 bài. Thí nghiệm vì vậy trả lời được “ngữ cảnh cấp bài báo có giúp không”, nhưng *không* trả lời được “metadata có giúp không” — dữ liệu không cho phép hỏi câu đó.

Một trục khác đã đúng sẵn từ trước: embeddings.py:131-144 áp prefix chính tắc của từng mô hình (query: /passage: cho e5, instruction riêng của BGE cho bge-*, không prefix cho bge-m3 đúng khuyến nghị). Nhánh dense chưa bao giờ ngày thơ ở trục prompt truy vấn.

nDCG@5 (resolved, 1.152 câu)	plain	contextual	Δ và CI95
Dense (e5-base-v2)	0,6598	0,6891	+0,0293 [+0,0184; +0,0406]
Sparse (BGE-M3)	0,7741	0,7533	-0,0208 [-0,0288; -0,0136]

Hai hiệu ứng ngược chiều, cả hai đều có ý nghĩa thống kê. Contextual chunking **giúp dense** và **hại sparse** — và cả hai đều nhất quán với phát hiện của EDA. Với dense, 160 ký tự ngữ cảnh là thông tin embedding trước đó không có: nó giúp phân biệt hai đoạn gần giống nhau đến từ hai bài khác nhau. Với sparse, chính 160 ký tự đó lặp lại trên mọi chunk của cùng một bài, **làm loãng tần suất của những từ hiếm** vốn là thứ giúp BGE-M3 tìm đúng đoạn.

Kết quả này **không đổi quyết định của Phase 1**: sparse vẫn thắng dense trên cả hai kho, khoảng cách thu hẹp từ 0,1143 xuống 0,0641 nhưng không đảo ngược. Ngoài ra, cả +0,0293 lẫn -0,0208 đều nhỏ hơn ngưỡng thực dụng 7,0%.

Quan trọng: kết luận này *mạnh hơn* bằng vòng 1 chứ không yếu hơn. Nhánh dense ở đây dùng **tìm kiếm chính xác** (nhân ma trận trên vector đã chuẩn hóa) thay vì Chroma/HNSW, và cả hai hệ quả đều nghiêng về phía dense: nó tái lập được (bỏ đúng nguồn nhiễu khiến số dense vòng 1 trôi 0,0143), và nó không mất recall do xấp xỉ nên là một baseline dense mạnh hơn lần chạy giải đấu. Sparse vẫn thắng trong điều kiện đó.

Ba điểm cần ghi nhận trung thực:

- Đây là ablation chứ không phải một vòng của giải đấu: harness riêng (top_k 10, không reranker), nên con số tuyệt đối không so trực tiếp với bảng vòng 1 — chỉ các hiệu số mới so được với nhau.
- Khoảng tin cậy ở đây bootstrap theo *câu hỏi*, không gom cụm theo bài báo. Nó dùng đúng paired_comparison của Phase 1 nên nhất quán trong nội bộ phase, nhưng lỏng hơn chuẩn Phase 2 đã nâng lên. Gom cụm sẽ làm khoảng tin cậy rộng ra; với khoảng cách sparse–dense (0,1143) điều đó không đổi kết luận, nhưng với hai hiệu ứng nhỏ thì nên đọc là “đo được”, đừng đọc là “chắc chắn”.
- Ablation chạy trên cả 1.152 câu, tức **có chạm vào các câu held-out của Phase 2**. Vì đây là chỉ số truy xuất thuần và không có quyết định cấu hình nào được rút ra từ nó, phần sinh trên held-out vẫn chưa bị nhìn thấy.

2.6 Cấu hình khóa

BGE-M3 learned sparse (top_k=20) → BAAI/bge-reranker-large (top 5) → chunk 512/64

Hit@1	Hit@3	Hit@5	nDCG@5	Latency P50
0,8221	0,9324	0,9573	0,8976	512,7 ms

Chỉ mục được đóng gói và băm (fc5d67b7acf6e8be...). Con số cần giữ lại cho phần sau: **Hit@5 = 0,9573**. Nó sẽ trở thành trăn của Phase 2.

3 Phase 2 — Chọn cách hỏi LLM

Phase 2 nhận 5 đoạn văn Phase 1 đưa sang và trả lời một câu hỏi duy nhất: ra lệnh cho Gemini thể nào để nó trả lời đúng mà không bịa. Cần nói rõ phạm vi — **không có huấn luyện lại hay fine-tune nào cả**. Chỉ hai thứ được thay đổi: nội dung system prompt, và số đoạn context đưa vào.

3.1 Baseline, và chẩn đoán từ ba con số

Chạy prompt gốc P0 với 5 đoạn context trên 281 câu development:

Answer Correctness	Exact Match	Token F1	Faithfulness
0,6308	0,0000	0,2648	0,9761

Ba con số này đọc cùng nhau cho một chẩn đoán duy nhất. Faithfulness 0,9761 nghĩa là gần như mọi khẳng định đều bám vào bằng chứng đã lấy được — hệ thống *không* bịa. Nhưng Exact Match 0,0000 nghĩa là không một câu trả lời nào trùng khớp đáp án chuẩn.

Hệ thống không bịa. Nó chỉ nói dài. Model biết đáp án nhưng gói nó trong một đoạn văn, trong khi đáp án chuẩn của NewsQA là một span rất ngắn: một cái tên, một mốc thời gian, một con số. Vấn đề nằm ở *hình dạng* câu trả lời, không phải ở độ trung thực của nó.

Chẩn đoán này đến từ một audit tay **30 câu** có Answer Correctness thấp nhất, phân loại theo nguyên nhân. Đáng chú ý: người duyệt thấy **23/30** câu điểm thấp thực ra *đúng về mặt ngữ nghĩa* — điểm thấp vì cách diễn đạt, hoặc vì nhân có vấn đề.

3.2 Bốn prompt, mỗi cái nhắm một nhóm lỗi đã đếm được

Prompt không được viết theo trực giác mà theo bảng phân loại lỗi từ audit. Nội dung nguyên văn cả bốn prompt nằm ở docs/prompts.md.

ID	Ý tưởng	Nhắm nhóm lỗi	Cỡ nhóm
P0	Prompt RAG có citation	<i>control</i>	—
P1	Siết grounding tường minh	Hallucination	~0
P2	Trả lời ngắn, đúng answer type	Đúng nhưng quá dài	11/30
P3	Chọn đúng đoạn trước khi trả lời	Trộn bài, trộn mốc thời gian	3/30

P1 thất bại, và đó là bài học đắt nhất. P1 siết ràng buộc bằng chứng để tăng faithfulness. Nhưng baseline đã đạt 0,9761 — không còn dư địa. P1 nhắm vào một vấn đề không tồn tại và *mất* correctness khi làm vậy. Trực giác “siết chặt hơn thì tốt hơn” là sai khi chưa đo xem nhóm lỗi ấy có bao nhiêu ca.

P2 thắng vì nó khớp với hình dạng của nhãn. P2 yêu cầu một câu trả lời ngắn chứa đúng loại thông tin được hỏi. Đây cũng là lý do Answer Relevancy *giảm* — metric ấy thường câu trả lời đầy đủ ngữ cảnh, còn dữ liệu này thường câu trả lời cụt. Sự giảm đó là hệ quả có chủ đích, không phải suy thoái.

3.3 context_depth — thứ được tính chỉnh song song

context_depth là số đoạn được dán vào khối context, lấy từ đầu danh sách đã xếp hạng. Trong mã nguồn nó đúng là một phép cắt danh sách:

```
generation_chunks = ranked_chunks[:context_depth]
```

Không truy xuất lại, không xếp hạng lại — nên chênh lệch giữa các mức depth quy hết được cho tăng sinh. Model nhận khối context đánh số [1] [2] [3]..., và chính các chỉ số này là số nó dùng khi trích dẫn.

depth	Model thấy	Đánh đổi
1	[1]	Ít token nhất — nhưng 38/281 câu mất sạch bằng chứng
3	[1] [2] [3]	Cân bằng — nhưng 7/281 câu mất sạch bằng chứng
5	[1]...[5]	Không mất bằng chứng — tốn token nhất

Cột bên phải không đến từ ước lượng. Nó đọc thẳng ra từ đường cong Hit@k mà Phase 1 đã đo: Hit@1 0,8221, Hit@3 0,9324, Hit@5 0,9573. Đây là chỗ Phase 1 định giá sẵn một quyết định của Phase 2 mà không tốn thêm một lệnh gọi API nào.

3.4 Quyết định winner: guardrail chạy trước, điểm số chạy sau

Bốn điều kiện được khóa *trước khi nhìn thấy bất kỳ kết quả nào*: Faithfulness không tụt quá 0,02; Citation F1 không tụt quá 0,01; Citation Validity không tụt quá 0,01; coverage $\geq$ 95%. Chỉ những cấu hình qua cả bốn mới được xét, và trong số đó mới chọn Answer Correctness cao nhất.

	P0	P2-depth3	P2-depth5
Answer Correctness	0,6308	0,7711	0,7350
Exact Match	0,0000	+0,2633	+0,0925
Faithfulness Δ	—	−0,0200 (FAIL)	+0,0040 (PASS)
Citation F1 Δ	—	+0,0356 (PASS)	+0,0366 (PASS)
Citation Validity Δ	—	−0,0142 (FAIL)	−0,0036 (PASS)
Phán quyết	—	LOẠI	CHỌN

P2-depth3 đạt Answer Correctness *cao hơn* (0,7711 so với 0,7350) nhưng trượt 2 trong 4 guardrail. Kiểm định theo cặp xác nhận cả hai mức tụt đều là thật, không phải nhiễu đo: Faithfulness −0,0200 với CI95 [−0,0372; −0,0048] — không chứa 0.

Nói ngưỡng ở đúng thời điểm này — sau khi đã thấy rằng cấu hình bị loại có điểm cao hơn — chính là hành vi mà việc đăng ký trước sinh ra để ngăn. Bộ guardrail đã làm đúng việc của nó.

3.5 Winner: P2-depth5

So với baseline P0 (281 câu development)	Δ	CI95
Answer Correctness	+0,1043	[+0,0844; +0,1240]
Exact Match	+0,0925	[+0,0596; +0,1296]
Token F1	+0,1542	[+0,1317; +0,1786]
Faithfulness	+0,0040	[−0,0127; +0,0189]
Citation F1	+0,0366	[+0,0127; +0,0616]

Correctness tăng +0,1043 với khoảng tin cậy không chứa 0. Faithfulness +0,0040 với CI95 [−0,0127; +0,0189] — *không tách được khỏi 0*, và đây là kết quả tốt: cải thiện correctness mà không đánh đổi grounding. Cái giá phải trả là chi phí input token cao hơn depth 3 khoảng 60%.

3.6 Hai lát cắt kiểm tra

Phân tầng theo truy xuất. Truy xuất đưa được bằng chứng ra trước mặt model ở 269/281 câu; 12 câu còn lại thì không.

Answer Correctness	n	P0	P2-depth3	P2-depth5
gold_in_top5	269	0,6522	0,7971	0,7597
gold_not_in_top5	12	0,1504	0,1885	0,1829

Trên 12 câu không có gold trong context, đổi prompt chỉ nhích Answer Correctness từ 0,1504 lên 0,1829 — và phần lớn mức đó là điểm ngữ nghĩa cho một câu từ chối đúng cách, không phải câu trả lời đúng. Trên 269 câu có gold, cùng thay đổi prompt ấy tăng hơn 0,10.

Macro theo bài báo. Trung bình theo câu để một bài đóng góp nhiều câu lần át bài đóng góp ít câu. Đọc theo macro (trung bình theo bài trước, rồi trung bình theo 50 bài): P0 0,6343, P2-depth3 0,7709, P2-depth5 0,7319. Cả ba mức chênh so với micro đều dưới 0,004 — không bài báo nào chi phối kết quả, và winner không đổi dù đọc theo cách nào.

4 Held-out — con số được phép công bố

Mọi con số ở hai mục trước đó trên 281 câu development — chính tập mà nhóm đã thử 4 prompt $\times$ 3 mức depth rồi chọn cấu hình điểm cao nhất. Chọn ra cái tốt nhất trong 12 lần thử rồi báo cáo điểm của nó trên chính tập đã dùng để chọn là **lệch lạc quan theo cấu trúc**. Vì vậy chúng không phải số công bố.

4.1 Quy trình, và dấu vết kiểm chứng được

- Tập held-out 284 câu / 50 bài được chốt từ đầu bằng lấy mẫu theo bài có seed 46; danh sách id được bấm và ghi vào manifest chuẩn bị.
- Bản ghi quyết định winner ký duyệt lúc 2026-09-06 13:31:30Z, bấm e2fa5915c45a7722...
- Run held-out bắt đầu 2026-09-06 14:23:24 UTC — **sau** khi bản ghi quyết định đã đóng băng, và tham chiếu đúng bấm đó.
- Chạy **đúng một lần**. Coverage 284/284, 0 lỗi.
- Bốn trong năm bấm artifact (quyết định, danh sách id, predictions, judge results) kiểm lại khớp. Bấm retrievals.jsonl khớp với bản lưu trong heldout_trace/; bản sao thứ hai dưới runs/ là một lần tuần tự hóa lại và không khớp — không ảnh hưởng kết quả, nhưng ghi lại để khỏi hiểu nhầm về sau.

Thứ tự thời gian ở đây chính là bằng chứng: không thể chọn winner sau khi đã thấy điểm held-out.

4.2 Kết quả

P2-depth5	Dev (281)	Held-out (284)	macro
Answer Correctness	0,7350	0,7157	0,7230
Exact Match	0,0925	0,1092	—
Token F1	0,4191	0,4313	0,4370
Faithfulness	0,9801	0,9249	0,9318
Citation F1	0,8391	0,7289	0,7315
Citation Validity	0,9858	0,9437	0,9483
Answer Relevancy	0,7092	0,6485	0,6477
Hit@5 (truy xuất)	0,9573	0,8768	—

Toàn bộ run tốn \$0,94; latency tổng P50 1957,5 ms. Micro và macro lệch nhau dưới 0,008 ở mọi metric, nên không bài báo nào chỉ phối con số công bố.

Điểm cần chú ý: Answer Correctness chỉ tụt 0,0193, nhưng Hit@5 tụt $-0,0805$. **Tập held-out khó hơn hẳn ở tầng truy xuất**, chứ không phải ở tầng sinh.

4.3 Phát hiện quan trọng nhất: prompt không bị overfit

Tách 284 câu held-out theo cùng tiêu chí đã dùng ở development:

Held-out	n	Answer Corr.	Citation F1	Faithfulness
gold_in_top5	249	0,7689	0,8313	0,9552
gold_not_in_top5	35	0,3375	0,0000	0,7095

Trên các câu mà truy xuất làm đúng việc, held-out đạt 0,7689 — cao hơn chính development (0,7597). Tỷ lệ truy xuất trượt thì tăng gần ba lần: $12/281 \rightarrow 35/284$.

Citation F1 trên nhóm trượt bằng 0,0000, đúng theo định nghĩa: không có đoạn đúng nào trong context để mà trích dẫn, nên recall bằng 0. Faithfulness trên nhóm này cũng tụt xuống 0,7095 — khi không có bằng chứng, model bám vào đoạn sai.

Toàn bộ khoảng cách development $\rightarrow$ held-out là câu chuyện của truy xuất, không phải của prompt. Prompt P2 tổng quát hóa được sang dữ liệu chưa từng thấy; cái không tổng quát hóa được là độ dễ của việc tìm đoạn.

4.4 Trần của tầng sinh nằm ở tầng truy xuất

Cùng một hiện tượng đo được ở cả hai tập:

Answer Correctness của P2-depth5	gold_in_top5	gold_not_in_top5
Development (281 câu)	0,7597	0,1829
Held-out (284 câu)	0,7689	0,3375

Với $\text{Hit}@5 = 0,8768$ trên held-out, khoảng 12% số câu không có đường nào để trả lời đúng, bất kể prompt viết thế nào. Đầu tư tiếp vào prompt engineering sẽ cho lợi ích giảm dần; đòn bẩy còn lại nằm ở **query rewriting** và ở chính tầng truy xuất.

Kết luận này rút ra được *chỉ* vì hai phase dùng chung một vết truy xuất đóng băng và mọi điểm số đều truy ngược được về từng câu hỏi. Đây là lợi ích trực tiếp của quyết định thiết kế ở mục 1.

5 Giới hạn và việc còn lại

5.1 Những gì chưa được phép kết luận

Phase 1. Không phân định được mô hình dense nào tốt nhất — các khoảng tin cậy chồng lấn. Nghiêm trọng hơn, nhánh dense **chưa tái lập được** giữa các lần chạy: độ trôi đo được 0,0143 nDCG@5, *lớn hơn* khoảng cách 0,0094 giữa hai mô hình dense đang so sánh. Nguyên nhân đã xác định được trong mã nguồn: không đặt seed cho HNSW, không cố định batch_size khi tính embedding, không gọi `torch.manual_seed`. Chừng nào chưa sửa, mọi xếp hạng nội bộ giữa các mô hình dense đều không có ý nghĩa. Kết quả chunk size là null; hybrid là “không chứng minh được có lợi”, không phải “đã chứng minh có hại”.

Phase 2. Answer Correctness 0,7157 là một **cận dưới**. EDA ước lượng 7,0%–24,5% số câu mang nhãn có vấn đề, và audit tay thấy 23/30 câu điểm thấp thực ra đúng về ngữ nghĩa. Con số thực nằm đâu đó trong dải giữa 0,7157 và một trần cao hơn đáng kể mà thí nghiệm này không đo được.

Judge cũng là một LLM. Nó đã được tách sang nhà cung cấp khác generator — một sửa lỗi trực tiếp từ phát hiện của EDA rằng notebook cũ chắm bài bằng chính mô hình sinh — nhưng **chưa được hiệu chuẩn với nhãn người**. Tập 20 câu dành cho việc hiệu chuẩn đã chuẩn bị nhưng chưa dùng.

Answer Relevancy giảm từ 0,7092 xuống 0,6485. Đây là hệ quả có chủ đích của P2, không phải suy thoái: metric ấy thưởng câu trả lời đầy đủ ngữ cảnh, còn dữ liệu này thưởng câu trả lời cụt. Nêu ra vì nó là một đánh đổi thật, không phải để giấu.

Cuối cùng, giải đấu phân tầng ở cả hai phase **không phát hiện được tương tác** giữa các lựa chọn ở những vòng khác nhau.

5.2 Việc còn lại

#	Việc	Phase	Ghi chú
1	Audit mù 30 cặp P0 ↔ winner, hai người chấm độc lập	2	Cần chia việc giữa hai người
2	Lập 25 câu × 2 cấu hình để đo độ ổn định API	2	
3	Hiệu chuẩn judge trên 20 câu đã dành sẵn	2	Tập đã chuẩn bị
4	Chạy held-out trên 150 bài final-test	1	Nghiệm thu Phase 1
5	Chạy lại vòng 1 trên chỉ mục đã đóng gói	1	Cố định lại số dense
6	Bốn biểu đồ 300 DPI theo test plan Phase 1 §6	1	Chưa có cái nào
7	Duyệt tay dataset abstention 200 case	3	3 loại cần reviewer thứ hai

Phase 3 — dạy hệ thống biết từ chối trả lời khi bằng chứng không đủ — là bước tiếp theo, và phân tầng ở mục 4 cho thấy vì sao nó đáng làm: 35/284 câu held-out không có bằng chứng nào để trả lời đúng, nhưng hệ thống vẫn trả lời chúng.

5.3 Tổng kết

1. **Sparse thắng dense** (+0,1634 nDCG@5, [+0,1231; +0,2080]) vì câu hỏi NewsQA neo vào tên riêng, ngày tháng và con số. EDA dự báo trước, thực nghiệm xác nhận.
2. **Prompt đúng *dạng* là đòn bẩy lớn nhất ở tầng sinh** — không phải vì kỹ thuật viết prompt khéo, mà vì nó khớp với hình dạng của nhân.
3. **Guardrail đăng ký trước đã loại một cấu hình có điểm cao hơn**, và đó chính xác là việc nó sinh ra để làm.
4. **Prompt không bị overfit**: khoảng cách development $\rightarrow$ held-out quy về việc truy xuất khó hơn, không phải prompt kém tổng quát.

Số công bố: Answer Correctness **0,7157** trên 284 câu held-out, cấu hình P2-depth5, chạy đúng một lần.

Tài liệu và mã nguồn liên quan

- Prompt nguyên văn và cách một request được ghép: docs/prompts.md
- Báo cáo chi tiết từng phase: docs/reports/phase1/report.md, docs/reports/phase2/report.md
- Kế hoạch đăng ký trước: docs/Detailed Test Plans/
- Quyết định winner và bằng chứng held-out: docs/reports/phase2/phase2b_winner_decision.json, docs/reports/phase2/phase2b_winner_decision.md
- Sinh lại toàn bộ con số trong tài liệu này: python scripts/build_latex_numbers.py