

Báo cáo hệ thống hỏi đáp tin tức NewsLens

Nhóm 9

Mục lục

3	Dữ liệu và phương pháp đánh giá	2
3.1	Dữ liệu	2
3.1.1	Nguồn dữ liệu	2
3.1.2	Hiệu chỉnh câu hỏi đánh giá	3
3.2	Chia tập	4
3.3	Nguyên tắc thực nghiệm	4
3.3.1	Phase 1: đánh giá retrieval	4
3.3.2	Phase 2: đánh giá generation end-to-end	4
3.4	Thước đo và kiểm định	5
3.4.1	Thước đo retrieval	5
3.4.2	Thước đo generation và citation	6
3.4.3	Khoảng tin cậy và điều kiện chọn cấu hình	6
4	Giai đoạn 1: Truy xuất	7
4.1	Thiết kế thực nghiệm	7
4.2	Sàng lọc retriever	8
4.3	Sàng lọc chiến lược retrieval và reranker	8
4.4	Final-test và cấu hình retrieval khóa	9
5	Giai đoạn 2: Sinh câu trả lời	10
5.1	Thiết kế thực nghiệm	10
5.2	Thiết lập và kết quả baseline end-to-end	10
5.3	Sàng lọc prompt zero-shot	11
5.4	Sàng lọc số lượng context	11
5.5	Kết quả zero-shot trên development và held-out	12
5.6	Thử nghiệm prompt one-shot	13
5.7	So sánh các mô hình sinh câu trả lời	14
	Phụ lục	16
A	Prompt zero-shot	16
B	Prompt one-shot P2-1S	16
C	Prompt judge RAGAS	17
D	Cách chấm citation	23
E	Nguồn tái lập	24

3 Dữ liệu và phương pháp đánh giá

3.1 Dữ liệu

3.1.1 Nguồn dữ liệu

Bộ dữ liệu ban đầu của nghiên cứu là NewsQA, được tải từ kho `lucadiliello/newsqa` trên Hugging Face. NewsQA gồm các bài báo CNN, câu hỏi do người đọc đặt, đáp án dạng đoạn văn bản ngắn (answer span) và vị trí ký tự của đoạn đáp án trong bài báo.

Dữ liệu được tổ chức theo câu hỏi, không gom sẵn theo bài báo. Mỗi dòng chứa một câu hỏi và toàn bộ bài báo tương ứng. Vì vậy, một bài có nhiều câu hỏi sẽ được lặp ở nhiều dòng. Nguồn không có `article_id`; số bài được tính bằng số context khác nhau.

Ví dụ rút gọn một dòng dữ liệu gốc:

```
{
  "context": "... full CNN article ...",
  "question": "When was Pandher sentenced to death?",
  "answers": ["February."],
  "key": "724f6eb9a2814e4fb2d7d8e4de846073",
  "labels": [{"start": [261], "end": [269]}]
}
```

Ý nghĩa các trường:

- `context`: toàn bộ nội dung bài báo CNN.
- `question`: câu hỏi được đặt dựa trên bài báo đó.
- `answers`: một hoặc nhiều đáp án ngắn lấy từ bài báo.
- `key`: mã định danh của câu hỏi.
- `labels`: vị trí ký tự đầu và cuối của đáp án trong context. Ví dụ, `start = 261` và `end = 269` nghĩa là đáp án gồm cả ký tự ở vị trí 269. Pipeline đổi thành đoạn `[261, 270)` và kiểm tra đoạn này khớp với đáp án.

Revision nguồn được khóa tại `728e52920b8e4ffcfad93fa47556f26a1d82546`. Thống kê theo định dạng gốc như sau:

Bảng 1: Quy mô các split NewsQA nguồn.

Split	Số câu hỏi	Số context khác nhau	Câu hỏi/bài
Train	74.160	10.895	6,8
Validation	4.212	638	6,6

Từ 638 context của split validation, nhóm dùng seed 42 để chọn ngẫu nhiên 200 context và lấy toàn bộ câu hỏi tương ứng làm tập đánh giá. Split train có 10.895 context khác nhau; 31 context trùng nội dung với tập đánh giá bị loại để tránh rò rỉ dữ liệu. 10.864 context còn lại được dùng làm distractor. Corpus cuối gồm 11.064 bài báo: 200 bài đánh giá và 10.864 distractor. Các distractor không có câu hỏi đánh giá, nhưng buộc hệ thống phải tìm bằng chứng trong một kho dữ liệu lớn hơn.

3.1.2 Hiệu chỉnh câu hỏi đánh giá

Câu hỏi NewsQA được đặt khi người đọc đang xem bài báo, nên nhiều câu thiếu ngữ cảnh khi đứng riêng. Nhóm giữ dữ liệu gốc để truy vết và tạo phiên bản resolved theo quy trình sau:

1. Codex đọc bài báo, gắn nhãn vấn đề và đề xuất sửa tối thiểu.
2. Người đánh giá duyệt từng câu; phần thêm vào chỉ dùng để xác định chủ thể hoặc sự kiện, không chứa đáp án.
3. Đáp án và evidence sai được sửa; câu không thể trả lời được loại.
4. Các câu cùng bài, cùng ý nghĩa và cùng đáp án được gom cụm để loại trùng.
5. Evidence span được ánh xạ sang `relevant_chunk_ids` sau khi chunk.

Trong 1.340 câu nguồn, 4 câu không có đáp án đáng tin cậy bị loại. Sau review còn 1.336 câu; loại tiếp 184 câu trùng nghĩa, thu được 1.152 câu resolved thuộc 200 bài báo. Việc loại trùng diễn ra sau khi làm rõ câu hỏi để so sánh đúng ý nghĩa đầy đủ của chúng.

Bảng 2: Các mốc tạo tập câu hỏi đánh giá.

Mốc dữ liệu	Số câu	Thay đổi
Câu hỏi lấy từ 200 bài NewsQA	1.340	–
Sau human review	1.336	Loại 4 câu invalid
Sau semantic deduplication	1.152	Loại 184 câu lặp

Bảng 3: Các vấn đề được ghi nhận khi review.

Issue code	Số lần	Ý nghĩa
missing_subject	688	Thiếu chủ thể cần xác định
underspecified_event	139	Chưa xác định rõ sự kiện
generic_reference	98	Dùng tham chiếu chung như “he”, “it”
wrong_evidence	87	Evidence không hỗ trợ đáp án
malformed_question	71	Câu hỏi sai hoặc thiếu cấu trúc
truncated_answer	59	Đáp án bị cắt thiếu
wrong_answer	35	Đáp án nguồn không đúng
yes_no_answer_mismatch	4	Câu hỏi Yes/No nhưng gold không phải Yes/No

Một câu hỏi có thể mang nhiều issue code.

Hai ví dụ về câu hỏi cần hiệu chỉnh:

1. **Ngữ cảnh/làm rõ câu hỏi:** “When was her surgery?” được sửa thành “When was Natalie Cole’s kidney transplant surgery?”. Đáp án “Tuesday” không được đưa vào câu hỏi mới.
2. **Đáp án:** câu hỏi về quân Canada có gold nguồn là “35,000”, nhưng đây là tổng quân của các đồng minh NATO. Bài báo ghi Canada có hơn 2.800 quân, nên nhóm sửa đáp án và evidence span, đồng thời giữ giá trị nguồn để truy vết.

3.2 Chia tập

Toàn bộ partition được tạo theo bài báo. Danh sách article ID và question ID được cố định bằng seed và SHA-256.

Bảng 4: Các partition của tập resolved deduplicated.

Partition	Bài	Câu	Vai trò
Development	50	281	Screening và chọn cấu hình
Held-out generation	50	284	Đánh giá cấu hình generation đã khóa
Held-out reserve	100	587	Dữ liệu dự trữ, không dùng để tuning
Phase 1 final-test retrieval	150	871	Toàn bộ held-out pool dùng kiểm tra retrieval

Trong 200 bài đánh giá, 50 bài với 281 câu được dùng làm development. 150 bài còn lại tạo thành held-out pool gồm 871 câu. Từ 150 bài này, nhóm dùng seed 46 để chọn 50 bài với 284 câu cho held-out generation; 100 bài với 587 câu còn lại được giữ làm reserve. Phase 1 dùng toàn bộ held-out pool 150 bài, còn Phase 2 chỉ dùng phần held-out generation 50 bài. Development và held-out pool không trùng bài báo.

3.3 Nguyên tắc thực nghiệm

3.3.1 Phase 1: đánh giá retrieval

- Đánh giá khả năng đưa gold evidence lên đầu danh sách; không gọi generator hoặc LLM-as-a-Judge.
- Các vòng chọn retriever, reranker và hybrid dùng cùng 281 câu development. Mỗi vòng chỉ thay đổi thành phần đang xét.
- Sau khi khóa cấu hình, final-test được chạy một lần trên 871 câu của 150 bài chưa dùng để tuning. Kết quả này không được dùng để chọn lại cấu hình.

3.3.2 Phase 2: đánh giá generation end-to-end

- Dùng cấu hình retrieval đã khóa từ Phase 1.
- Chạy retrieval và reranking một lần trên development, sau đó dùng lại cùng ranked traces cho mọi cấu hình generation.
- Khi thử context depth 1, 3 hoặc 5, pipeline chỉ lấy số context tương ứng từ đầu cùng một danh sách đã rerank.

Để kiểm soát chi phí API, Phase 2 được chia thành các chế độ sau:

- Screening 80 câu và judge calibration 20 câu được chọn một lần với seed 42 và giữ nguyên ID trong mọi thí nghiệm.
- Screening là bước tiết kiệm chi phí: loại cấu hình kém hơn trên tập nhỏ, chỉ giữ cấu hình có kết quả tương đương hoặc tốt hơn để làm finalist.

Bảng 5: Các chế độ chạy trong Phase 2.

Chế độ	Số câu	Mục đích
Screening	80	So sánh nhanh prompt/context configuration
Judge calibration	20	Tập con cố định của screening để chấm RAGAS
Full development	281	Xác nhận finalist và áp dụng guardrail
Held-out generation	284	Đánh giá cấu hình đã khóa trên 50 bài chưa thấy

- Các finalist được chạy và chấm trên đủ 281 câu development. Guardrail được áp dụng ở bước này để chọn winner.
- Held-out chỉ được mở sau khi khóa winner và không dùng để tuning tiếp.
- Mỗi run lưu cấu hình, model, prompt hash, question IDs, source trace hash, coverage và retry log để có thể dùng và tiếp tục.

3.4 Thước đo và kiểm định

3.4.1 Thước đo retrieval

Với câu hỏi q , gọi r_q là thứ hạng đầu tiên có gold chunk và G_q là tập gold chunks. Các thước đo được tính tại cutoff k :

$$\text{Hit}@k(q) = \mathbf{1}[G_q \cap R_q^{(k)} \neq \emptyset], \quad (1)$$

$$\text{Recall}@k(q) = \frac{|G_q \cap R_q^{(k)}|}{|G_q|}, \quad (2)$$

$$\text{MRR}@k(q) = \begin{cases} 1/r_q, & r_q \leq k, \\ 0, & r_q > k, \end{cases} \quad (3)$$

Trong đó, $R_q^{(k)}$ là k kết quả đầu:

- **Hit@ k** : bằng 1 nếu top- k chứa ít nhất một gold chunk; ngược lại bằng 0.
- **Recall@ k** : tỷ lệ gold chunks xuất hiện trong top- k .
- **MRR@ k** : dựa trên vị trí của gold chunk đầu tiên; gold xuất hiện càng sớm thì điểm càng cao.
- **nDCG@ k** : đánh giá toàn bộ thứ tự top- k , ưu tiên gold chunks ở vị trí cao và chuẩn hóa theo thứ tự lý tưởng.
- **Latency**: thời gian truy xuất và rerank cho một câu hỏi.
- **Quy tắc chọn**: ưu tiên MRR@5; dùng nDCG@5, Hit@5 và latency để phân xử và mô tả trade-off.

3.4.2 Thước đo generation và citation

Bảng 6: Vai trò của các thước đo Phase 2.

Metric	Ý nghĩa
So sánh đáp án	
Exact Match	Đáp án chuẩn hóa trùng hoàn toàn một accepted answer.
Token F1	Mức chồng lấp token giữa đáp án sinh và accepted answer tốt nhất.
RAGAS	
Answer Correctness	RAGAS đánh giá độ đúng ngữ nghĩa so với gold answer.
Answer Relevancy	Mức độ câu trả lời trực tiếp giải quyết câu hỏi.
Faithfulness	Tỷ lệ các phát biểu trong đáp án được context hỗ trợ.
Context Precision	Mức độ các context được đưa vào thực sự liên quan.
Context Recall	Mức độ context bao phủ evidence cần để trả lời.
Citation	
Citation Validity	Tỷ lệ citation trỏ tới một context index hợp lệ.
Citation F1	Trung bình điều hòa giữa precision và recall của citation so với gold evidence.

Exact Match, Token F1 và citation metrics được tính xác định từ artifact. Answer Correctness, Answer Relevancy, Faithfulness, Context Precision và Context Recall được chấm bằng RAGAS với judge tách biệt khỏi generator. Báo cáo phải ghi model, provider, reasoning setting và score coverage của judge. Latency được báo cáo theo P50/P95; token usage và chi phí chỉ so sánh khi các run dùng cùng phạm vi câu hỏi và cùng cách tính giá.

3.4.3 Khoảng tin cậy và điều kiện chọn cấu hình

Khi so sánh hai cấu hình A và B trên cùng câu hỏi, nhóm tính sai khác theo cặp:

$$d_i = m(B, q_i) - m(A, q_i). \quad (4)$$

- **Paired bootstrap:** lấy lại các cặp sai khác d_i , thay vì lấy điểm của hai cấu hình độc lập.
- **Phase 1:** tạo 1.000 mẫu bootstrap; mỗi mẫu lấy lại 281 câu hỏi có hoàn lại.
- **Phase 2:** tạo 2.000 mẫu bootstrap; mỗi mẫu lấy lại 50 bài báo có hoàn lại và giữ toàn bộ câu hỏi của từng bài. Do đó, đây không phải 2.000 tập gồm 50 câu hỏi.
- **CI95:** lấy percentile 2,5–97,5% của 1.000 hoặc 2.000 giá trị trung bình mô phỏng.
- **Diễn giải:** CI95 không chứa 0 cho thấy khác biệt ở mức ý nghĩa 0,05; CI95 chứa 0 nghĩa là chưa đủ bằng chứng về khác biệt, không phải hai cấu hình tương đương.
- **Guardrail:** kiểm tra delta trung bình so với baseline có nằm trong mức suy giảm cho phép hay không; đây là tiêu chí khác với CI95.

Trong các ứng viên qua guardrail, Answer Correctness là metric chất lượng chính; token cost, generation P95 và độ đơn giản của cấu hình lần lượt được dùng khi khác biệt Answer Correctness nhỏ. Quy tắc này chỉ áp dụng trên full development. Held-out được báo cáo nguyên trạng và không mở thêm vòng lựa chọn.

Bảng 7: Guardrail dùng khi chọn cấu hình Phase 2 trên full development.

Điều kiện	Ngưỡng
Δ Faithfulness	$\geq -0,02$
Δ Citation F1	$\geq -0,01$
Δ Citation Validity	$\geq -0,01$
Generation và judge coverage	$\geq 95\%$

4 Giai đoạn 1: Truy xuất

4.1 Thiết kế thực nghiệm

- **Mục tiêu:** chọn cấu hình đưa chunk chứa bằng chứng lên đầu danh sách trước khi đánh giá generation.
- **Phạm vi:** chỉ đánh giá retrieval offline; không gọi generator, không chấm RAGAS và không phát sinh chi phí API sinh văn bản.
- **Gold label:** đối chiếu kết quả với `relevant_chunk_ids` được ánh xạ từ evidence span. Một chunk chỉ đúng khi ID của nó thuộc tập gold.

Thiết lập cố định

- Development: 281 câu resolved thuộc 50 bài; corpus gồm 11.064 bài.
- Chunking: recursive, kích thước 512 token và overlap 64 token.
- Resolved là biến thể chính vì câu hỏi có thể hiểu độc lập. Original chỉ dùng để phân tích ảnh hưởng của câu hỏi thiếu chủ thể.

Quy trình chọn cấu hình

1. Sàng lọc riêng dense và sparse retriever, không rerank.
2. So sánh dense tốt nhất, sparse tốt nhất và hybrid RRF với ba chế độ reranker.
3. Khóa pipeline rồi chạy đúng một lần trên 871 câu thuộc 150 bài chưa thấy.

Tiêu chí đánh giá

- Ưu tiên $MRR@5$ vì generator có lợi nhất khi bằng chứng đầu tiên xuất hiện sớm.
- Khi MRR gần nhau, lần lượt xét $nDCG@5$, $Hit@5$ và latency.
- Dùng $Recall@5$ để kiểm tra độ phủ khi một câu có nhiều gold chunks.
- Mọi run phải đạt coverage 100%; question IDs, seed và cách chấm được giữ cố định trong cùng một vòng.

4.2 Sàng lọc retriever

- **Dense:** all-MiniLM-L6-v2, bge-small-en-v1.5, bge-large-en-v1.5 và e5-base-v2.
- **Sparse:** BM25 Okapi, BM25+, BM25 có stemming/stopword normalization và learned sparse BGE-M3.
- **Điều kiện chung:** mỗi phương pháp trả tối đa 10 candidates; chưa dùng cross-encoder.

Bảng 8: Kết quả sàng lọc retriever trên 281 câu resolved.

Retriever	MRR@5	nDCG@5	Hit@5	P50 (ms)
BGE-M3 learned sparse	0,8059	0,8317	0,9181	76,7
BM25 Okapi + stemming	0,7815	0,8123	0,9146	56,1
BM25+	0,6881	0,7206	0,8221	101,1
BM25 Okapi	0,6732	0,7087	0,8185	111,8
Dense: e5-base-v2	0,6316	0,6684	0,7865	15,5
Dense: bge-small-en-v1.5	0,6285	0,6589	0,7651	16,0
Dense: bge-large-en-v1.5	0,6252	0,6536	0,7544	27,4
Dense: all-MiniLM-L6-v2	0,4851	0,5165	0,6299	10,6

Kết quả và phạm vi kết luận

- Trong các mô hình và dữ liệu được khảo sát, nhánh sparse đạt kết quả retrieval cao hơn nhánh dense.
- BGE-M3 được chọn làm sparse representative vì đứng đầu theo quy tắc MRR@5, sau đó là nDCG@5. Tuy nhiên, so với BM25-stemmed trên tập resolved, CI95 của hiệu nDCG@5 là $[-0,0125; 0,0508]$; chưa đủ bằng chứng kết luận một sparse model tốt hơn model còn lại.
- e5-base-v2 được chọn làm dense representative. Chênh lệch giữa các dense models nhỏ và chưa đủ để thiết lập một thứ hạng tổng quát.
- BGE-M3 chậm hơn e5-base-v2; P95 vẫn dưới 0,1 giây trong thử nghiệm.

4.3 Sàng lọc chiến lược retrieval và reranker

- **Retriever:** e5-base-v2 dense, BGE-M3 sparse và hybrid RRF giữa hai nhánh.
- **Reranker:** không rerank, cross-encoder MiniLM-L6 và BGE-reranker-large.
- **Thiết lập:** retriever lấy 20 candidates; reranker sắp lại và trả top 5 để tính metric.

Bảng 9: MRR@5 và nDCG@5 theo retriever và reranker trên tập development.

Retriever	MRR@5			nDCG@5		
	Không	MiniLM	BGE-large	Không	MiniLM	BGE-large
BGE-M3 sparse	0,8059	0,8387	0,8797	0,8317	0,8642	0,8976
e5-base dense	0,6316	0,7783	0,7997	0,6684	0,7994	0,8172
Hybrid RRF	0,7192	0,7938	0,8203	0,7474	0,8164	0,8405

Bảng 10: Độ trễ P50 của ma trận Phase 1 trên cùng môi trường chạy.

Retriever	Không rerank	MiniLM	BGE-large
BGE-M3 sparse	66,1 ms	163,9 ms	510,1 ms
e5-base dense	17,7 ms	127,3 ms	540,5 ms
Hybrid RRF	90,4 ms	193,3 ms	609,8 ms

Kết quả

- Trên BGE-M3, MiniLM tăng $MRR@5$ từ 0,8059 lên 0,8387; BGE-large đạt 0,8797 nhưng P50 tăng từ 163,9 ms lên 510,1 ms.
- BGE-M3 + BGE-large đứng đầu ma trận: $MRR@5$ 0,8797; $nDCG@5$ 0,8976; $Hit@5$ 0,9573; $Recall@5$ 0,9555. Vì vậy, cấu hình này được chọn.
- Hybrid RRF không vượt BGE-M3 sparse ở cả ba chế độ reranker; fusion không đem lại lợi ích quan sát được trong thiết lập này.

4.4 Final-test và cấu hình retrieval khóa

- **Cấu hình khóa trước final-test:** recursive chunking 512/64; BGE-M3 learned sparse lấy top 20; BGE-large cross-encoder trả top 5.
- **Dữ liệu:** 871 câu resolved thuộc 150 bài chưa dùng để chọn cấu hình.
- **Phạm vi:** chỉ chạy retrieval; không gọi generator. Cả 871/871 câu đều có bản ghi thành công.

Bảng 11: Kết quả của pipeline retrieval đã khóa.

Metric	Development (281 câu)	Final-test (871 câu)
$MRR@5$	0,8797	0,8112
$nDCG@5$	0,8976	0,8313
$Hit@5$	0,9573	0,8978
$Recall@5$	0,9555	0,8955
P50 latency	512,7 ms	550,0 ms
P95 latency	531,0 ms	567,0 ms
Coverage	100%	100%

Kết quả

- 782/871 câu có ít nhất một gold chunk trong top 5; 89 câu không đạt $Hit@5$.
- So với BGE-M3 trước rerank, BGE-large tăng $MRR@5$ từ 0,7269 lên 0,8112, $nDCG@5$ từ 0,7555 lên 0,8313 và $Hit@5$ từ 0,8519 lên 0,8978.
- Mức tăng $nDCG@5$ là 0,0758, với paired CI95 [0,0504; 0,1017]. Khoảng này không chứa 0, nên hiệu quả rerank vẫn xuất hiện trên các bài chưa thấy.

Diễn giải và quyết định

- Bốn metric chính đều thấp hơn development; điểm development đã lạc quan hơn so với dữ liệu chưa thấy.
- Coverage vẫn đạt 100%; pipeline tìm được gold evidence trong top 5 cho gần 90% câu hỏi.
- Khóa BGE-M3 top 20 + BGE-large top 5 làm retrieval đầu vào cho Phase 2. Final-test không được dùng để chọn lại model.

5 Giai đoạn 2: Sinh câu trả lời

5.1 Thiết kế thực nghiệm

- **Mục tiêu:** đánh giá pipeline end-to-end và cải thiện câu trả lời mà không làm giảm grounding hoặc chất lượng citation.
- **Retrieval cố định:** recursive 512/64, BGE-M3 top 20, BGE-reranker-large top 5.
- **Dữ liệu:** development gồm 281 câu/50 bài; held-out gồm 284 câu/50 bài chưa dùng để tuning.
- **Generator:** Gemini 3.1 Flash-Lite, reasoning minimal, temperature 0 và tối đa 512 output tokens.
- **Judge:** GLM-5.3-Flash qua Fireworks, reasoning low; chấm năm RAGAS metrics. Exact Match, Token F1 và citation metrics được tính trực tiếp.
- **Metric chính:** Answer Correctness. Guardrail gồm Faithfulness, Citation F1, Citation Validity và coverage.

5.2 Thiết lập và kết quả baseline end-to-end

Baseline dùng prompt P0 và 5 context trên toàn bộ development.

Bảng 12: Baseline P0-depth5 trên 281 câu development.

Nhóm	Metric	Điểm
Đáp án	Exact Match	0,0000
	Token F1	0,2648
	Answer Correctness	0,6308
	Answer Relevancy	0,7950
Grounding	Faithfulness	0,9761
	Context Precision	0,8980
	Context Recall	0,9644
Citation	Citation F1	0,8025
	Citation Validity	0,9893
Vận hành	Coverage	100%
	Latency P50 / P95	2,77 s / 53,63 s

Phân tích baseline

- Faithfulness và Citation Validity cao, nhưng Answer Correctness chỉ đạt 0,6308 và Exact Match bằng 0.
- Audit 30 câu có Answer Correctness dưới 0,5: 24 câu vẫn có gold evidence trong top 5. Lỗi chính là trả lời dài, sai loại thông tin hoặc chọn nhầm chi tiết trong context.
- Sáu câu còn lại không có gold trong top 5; prompt không thể khôi phục bằng chứng mà retrieval không cung cấp.
- Vì vậy, bước tiếp theo tập trung vào prompt ngắn và đúng loại đáp án, đồng thời giữ các guardrail của RAG.

5.3 Sàng lọc prompt zero-shot

Bảng 13: Các zero-shot prompt được khảo sát.

ID	Mục tiêu	Chỉ thị khác biệt
P0	Đôi chứng	Trả lời dựa trên context và kèm citation.
P1	Siết grounding	Chỉ nêu claim được context hỗ trợ trực tiếp.
P2	Tăng độ chính xác	Trả đúng loại thông tin, ngắn gọn và kèm citation.
P3	Chọn evidence	Chọn đoạn hỗ trợ trước khi tạo câu trả lời ngắn.

Bảng 14: Sàng lọc prompt trên 80 câu; RAGAS dùng cùng 20 câu calibration.

Prompt	Token F1	AC	Faith.	AR	Cit. F1	Cit. Valid.
P0	0,2417	0,7118	1,0000	0,8131	0,7808	0,9750
P1	0,2570	0,6885	0,9750	0,7426	0,7863	0,9625
P2	0,3999	0,8363	1,0000	0,7388	0,8133	0,9750
P3	0,2790	0,7190	0,9750	0,8153	0,8146	0,9625

- Screening là bước tiết kiệm chi phí, không phải final comparison.
- P1 thấp hơn P0 về Answer Correctness và Faithfulness nên bị loại.
- P2 và P3 có kết quả cạnh tranh; P2 nổi bật về Answer Correctness và Token F1 nên được đưa sang bước kiểm tra depth.

5.4 Sàng lọc số lượng context

Giữ nguyên thứ tự rerank và cắt danh sách context còn 1, 3 hoặc 5 đoạn.

Bảng 15: Ảnh hưởng của context depth trên tập screening.

Prompt	Depth	Token F1	AC	Faith.	AR	Cit. F1	Cit. Valid.
P0	1	0,2543	0,7063	0,9750	0,7365	0,7250	0,8167
P0	3	0,2527	0,7046	0,9875	0,7667	0,7792	0,9500
P0	5	0,2417	0,7118	1,0000	0,8131	0,7808	0,9750
P2	1	0,5809	0,8671	0,9500	0,4825	0,5500	0,6125
P2	3	0,5311	0,8795	0,9250	0,6806	0,8125	0,9500
P2	5	0,3999	0,8363	1,0000	0,7388	0,8133	0,9750

- Depth 1 tăng Answer Correctness nhưng giảm mạnh Citation F1 và Citation Validity; 38/281 câu không có gold ở rank 1.
- P2 depth 3 và P2 depth 5 được chọn để chạy đủ 281 câu development.

5.5 Kết quả zero-shot trên development và held-out

Bảng 16: Kết quả finalist trên toàn bộ development.

Cấu hình	Token F1	AC	Faith.	AR	Cit. F1	Cit. Valid.
P0-depth5	0,2648	0,6308	0,9761	0,7950	0,8025	0,9893
P2-depth3	0,5549	0,7711	0,9561	0,5694	0,8381	0,9751
P2-depth5	0,4191	0,7350	0,9801	0,7092	0,8391	0,9858

- P2 depth 3 tăng Answer Correctness nhiều nhất, nhưng giảm Faithfulness 0,0200 và Citation Validity 0,0142; cấu hình không qua guardrail.
- So với P0 depth 5: Answer Correctness tăng 0,1043. CI95: [0, 0844; 0, 1240]. Citation F1 tăng 0,0366; Faithfulness không giảm.
- P2 depth 5 qua toàn bộ guardrail và được khóa trước khi mở held-out.

Bảng 17: P2-depth5 trên development và held-out.

Metric	Development (281)	Held-out (284)
Token F1	0,4191	0,4313
Answer Correctness	0,7350	0,7157
Faithfulness	0,9801	0,9249
Answer Relevancy	0,7092	0,6485
Citation F1	0,8391	0,7289
Citation Validity	0,9858	0,9437
Coverage	100%	100%

- Held-out có 35/284 câu không có gold trong top 5, so với 12/281 câu ở development. Hit@5 giảm từ 0,9573 xuống 0,8768.

- Khi gold có trong top 5, Answer Correctness held-out đạt 0,7689, so với 0,7597 trên development. Phần suy giảm tổng thể chủ yếu đi cùng retrieval miss.
- Held-out chỉ dùng để đánh giá khả năng tổng quát hóa, không dùng để sửa prompt hoặc chọn lại cấu hình.

5.6 Thử nghiệm prompt one-shot

Giả thuyết: một ví dụ hoàn toàn tổng hợp giúp generator học định dạng đáp án ngắn và citation đúng vị trí, từ đó tăng độ đúng của câu trả lời. P2-1S giữ chỉ thị P2 và thêm ví dụ gồm context, câu hỏi và đáp án có citation. Chỉ thay prompt; retrieval trace, depth 5 và Gemini 3.1 Flash-Lite được giữ nguyên. Ví dụ không thuộc development hoặc held-out.

Bảng 18: So sánh P2 zero-shot và one-shot, cùng depth 5, trên development.

Metric	P2 zero-shot (281)	P2 one-shot (281)
Exact Match	0,0000	0,3559
Token F1	0,4191	0,6267
Answer Correctness	0,7350	0,8015
Faithfulness	0,9801	0,9603
Answer Relevancy	0,7092	0,5251
Citation F1	0,8391	0,8441
Citation Validity	0,9858	0,9786
Coverage	100%	100%

Bảng 19: P2 one-shot trên development và held-out; chỉ kiểm tra khả năng tổng quát hóa của cùng cấu hình, không chọn lại prompt.

Metric	Development (281)	Held-out (284)
Exact Match	0,3559	0,3239
Token F1	0,6267	0,6032
Answer Correctness	0,8015	0,7557
Faithfulness	0,9603	0,9082
Answer Relevancy	0,5251	0,4688
Citation F1	0,8441	0,7315
Citation Validity	0,9786	0,9437
Coverage	100%	100%

Bảng 20: Sai khác paired của P2-1S so với zero-shot P2-depth5 trên 281 câu development; CI95 bootstrap theo 50 bài, 2.000 lần lấy mẫu.

Metric	P2-D5	P2-1S-D5	Δ và CI95
Answer Correctness	0,7350	0,8015	+0,0664 [0,0444; 0,0883]
Token F1	0,4191	0,6267	+0,2076 [0,1728; 0,2427]
Faithfulness	0,9801	0,9603	-0,0199 [-0,0388; -0,0028]
Answer Relevancy	0,7092	0,5251	-0,1841 [-0,2233; -0,1458]
Citation F1	0,8391	0,8441	+0,0050 [-0,0104; 0,0229]
Citation Validity	0,9858	0,9786	-0,0071 [-0,0182; 0,0000]

- Trên development, Answer Correctness và Token F1 tăng; CI95 của hai sai khác đều không chứa 0. Citation F1 chưa có bằng chứng thay đổi.
- Answer Relevancy giảm rõ rệt; Faithfulness cũng giảm, dù mức giảm trung bình 0,0199 vẫn nằm sát ngưỡng guardrail 0,02. Do đó, one-shot không phải cải thiện đồng đều trên mọi tiêu chí của RAG.
- Held-out chỉ đối chiếu P2-1S với chính P2-1S trên development. Các metric chất lượng thấp hơn trên bài chưa thấy; đây không phải so sánh zero-shot với one-shot trên held-out, và không được dùng để chọn lại prompt.

Phân tích Answer Relevancy giảm

- Trên cùng 281 câu, câu trả lời one-shot có trung vị 7 từ, so với 11 từ của zero-shot; 105 so với 23 câu dài không quá ba từ. Số câu có Answer Relevancy dưới 0,5 tăng từ 54 lên 133.
- Trong 133 câu one-shot dưới 0,5, có 109 câu vẫn đạt Answer Correctness từ 0,8 trở lên. Ví dụ, với câu hỏi “Where was the 2009 Swamp Soccer World Championship held?”, zero-shot trả lời “The 2009 Swamp Soccer World Championship was held in Scotland [1]” (Relevancy 1,00), còn one-shot trả lời “Scotland [1]” (Relevancy 0,037; Correctness 1,00).
- RAGAS Answer Relevancy sinh câu hỏi ngược từ đáp án rồi so với câu hỏi gốc. Đáp án chỉ gồm một thực thể hoặc địa điểm thường không giữ chủ thể và sự kiện cần để tái tạo câu hỏi gốc. Điều này phù hợp với các ví dụ đã kiểm tra, nhưng không chứng minh độ ngắn giải thích mọi trường hợp giảm điểm; Answer Relevancy vẫn là một trade-off cần báo cáo riêng.

5.7 So sánh các mô hình sinh câu trả lời

Mục tiêu: mô tả điều gì thay đổi khi thay generator, gồm độ chính xác, grounding, citation, token usage và latency. Thí nghiệm giữ cố định retrieval trace, P2-1S, depth 5 và cùng 281 câu development; chỉ thay generator. Gemini 3.1 Flash-Lite được dùng làm mốc so sánh. Đây là ablation để quan sát trade-off, không phải vòng chọn winner; không chạy held-out riêng cho từng model và không thay đổi cấu hình đã khóa.

Bảng 21: Generator ablation với P2-1S-depth5 trên development.

Generator	Token F1	AC	Faith.	AR	Cit. F1	Cit. Valid.
Gemini 3.1 Flash-Lite	0,6267	0,8015	0,9603	0,5251	0,8441	0,9786
Gemini 3.5 Flash-Lite	0,6803	0,8164	0,9557	0,4351	0,8351	0,9680
Gemini 3.6 Flash	0,6934	0,8011	0,9472	0,3837	0,8248	0,9644

Bảng 22: Sai khác so với Gemini 3.1 Flash-Lite và tài nguyên generation trên 281 câu. CI95 là paired article-cluster bootstrap (2.000 mẫu).

Generator	Δ AC	Δ Cit. F1	Δ Cit. Valid.	CI95 Δ AC	LLM P95	Token in/out
3.1 Lite	0	0	0	Đối chứng	1,02 s	666.604 / 3.847
3.5 Lite	+0,0149	-0,0090	-0,0107	[-0,0052; 0,0359]	0,89 s	666.604 / 3.112
3.6 Flash	-0,0003	-0,0193	-0,0142	[-0,0204; 0,0195]	3,50 s	666.604 / 3.249

- Gemini 3.5 Flash-Lite có Answer Correctness trung bình cao nhất, nhưng CI95 của sai khác so với 3.1 chứa 0; chưa đủ bằng chứng kết luận model này chính xác hơn trên quần thể mục tiêu. Model dùng ít output token và có LLM P95 thấp nhất trong các run đã ghi.
- Gemini 3.6 Flash có Token F1 cao nhất nhưng không tăng Answer Correctness so với 3.1; Citation F1 và Citation Validity thấp hơn, còn LLM P95 cao nhất.
- Gemini 3.1 Flash-Lite giữ Faithfulness, Answer Relevancy và hai citation metrics cao nhất trong ba model được khảo sát.
- Token là tổng usage của 281 lần generation, không gồm judge. P95 là độ trễ gọi LLM ghi trong từng run, chỉ để mô tả vận hành vì các run có thể chạy trên môi trường và thời điểm khác nhau. Không quy đổi ra tiền khi chưa cố định bảng giá API tại thời điểm thí nghiệm.
- Kết quả mô tả trade-off trên development; nhóm không dùng ablation này để chọn lại generator hoặc thay đổi pipeline đã khóa.

Phụ lục

A Prompt zero-shot

Các đoạn dưới đây là *system prompt* P0–P3 nguyên văn từ prompt registry của Giai đoạn 2. Câu hỏi và năm context được gửi riêng trong user prompt; phần này không đưa đáp án mẫu cho generator.

P0 — Đối chứng. Yêu cầu trả lời ngắn, dựa vào context và có citation cho từng phát biểu thực tế.

You are a helpful assistant answering questions based on provided context. Answer concisely and only based on the given context. Cite supporting context using its bracketed number, for example [1]. Every factual claim must have a citation, and you must not cite context that does not support the claim. If the answer is not in the context, say: 'I cannot find this information in the provided context.'

P1 — Siết grounding. Kiểm tra liệu cảm suy đoán và chỉ dẫn bằng chứng trực tiếp có tăng Faithfulness hay không.

Answer the question using only facts explicitly stated in the numbered context. Do not add background knowledge, assumptions, or plausible details. Give a concise answer and cite the supporting context with [n] after every factual claim. Cite only context that directly supports that claim. If the context does not contain the answer, say: 'I cannot find this information in the provided context.'

P2 — Đúng loại đáp án. Kiểm tra liệu đáp án một câu, chỉ chứa loại thông tin được hỏi, có tăng độ chính xác hay không.

Answer using only the numbered context. Give one short answer sentence containing only the information type requested by the question, such as a person, place, date, year, number, object, event, or explanation. Include multiple items only when the question explicitly asks for them. Do not repeat the question, list alternative answers, or add background details. Place a supporting citation [n] immediately after the answer. If the answer is not in the context, say: 'I cannot find this information in the provided context.'

P3 — Phân biệt sự kiện. Kiểm tra liệu chọn đoạn khớp chủ thể, sự kiện, địa điểm và thời gian có giảm nhầm lẫn giữa các bài hay không.

Answer using only facts explicitly stated in the numbered context. First identify the passage that best matches all identifying details in the question, including its subject, event, location, and time. Do not combine facts, figures, or dates from different events, articles, or reporting periods. Give one short answer sentence containing only the requested information type, and include multiple items only when explicitly asked. Place a supporting citation [n] immediately after the answer and cite only the passage that directly supports it. If no passage contains a defensible answer, say: 'I cannot find this information in the provided context.'

B Prompt one-shot P2-1S

P2-1S giữ nguyên P2 và nối thêm ví dụ dưới đây vào cùng system prompt. Ví dụ **hoàn toàn được tạo tổng hợp**: bảo tàng Northbridge, kế hoạch Riverside, ngữ cảnh, câu hỏi và đáp án đều không lấy từ NewsQA, corpus truy xuất, development hoặc held-out. Ví dụ chỉ minh họa cách trả lời ngắn và trở tới đúng số thứ tự context.

Demonstration (format example only):

Context [1]: The Northbridge museum opened a new gallery in 2018.

Context [2]: The city council approved the Riverside transit plan in March 2021.

Question: When was the Riverside transit plan approved?

Answer: March 2021 [2]

Now answer the user's question using the supplied numbered context and the same concise citation format.

Bản prompt đầy đủ là P2 ở Phụ lục A, hai dòng trống, rồi phần demonstration trên. Bản ghi nguyên văn và SHA-256 được lưu trong `results/phase2/1s_prompt_experiment/1s_dev_results/results/one_shot_prompt_contract.json`.

C Prompt judge RAGAS

Các file dưới đây được xuất bằng `scripts/export_report_ragas_prompts.py` từ **RAGAS 0.4.3**. Mỗi file chứa instruction nguyên văn, JSON output schema, toàn bộ ví dụ few-shot có sẵn trong thư viện và phần input cuối. Các giá trị trong dấu `<...>` ở input cuối là *giữ chỗ* để in template; khi chấm, RAGAS thay bằng dữ liệu của từng câu hỏi. Judge là GLM-5.3-Flash qua Fireworks, reasoning low. Citation metrics không sử dụng judge này.

Bảng 23: Template RAGAS được dùng cho năm metric.

Metric	Template / bước chấm
Faithfulness	Tách đáp án thành phát biểu; kiểm tra từng phát biểu với context.
Answer Correctness	Tách đáp án và gold thành phát biểu; phân loại TP/FP/FN.
Answer Relevancy	Sinh câu hỏi từ đáp án, phát hiện trả lời lảng tránh; so embedding với câu hỏi gốc.
Context Precision	Chấm từng context có hữu ích cho câu hỏi và gold không; xét thứ tự context.
Context Recall	Chấm từng phát biểu của gold có được context hỗ trợ không.

Tách phát biểu: Faithfulness và Answer Correctness

```
Given a question and an answer, analyze the complexity of each sentence in the answer. Break down each sentence into one or more fully understandable statements. Ensure that no pronouns are used in any statement. Format the outputs in JSON.

Please return the output in a JSON format that complies with the following schema as specified in JSON Schema:
{"properties": {"statements": {"description": "The generated statements", "items": {"type": "string"}, "title": "Statements", "type": "array"}}, "required": ["statements"], "title": "StatementGeneratorOutput", "type": "object"}Do not use single quotes in your response but double quotes, properly escaped with a backslash.

-----EXAMPLES-----
Example 1
Input: {
  "question": "Who was Albert Einstein and what is he best known for?",
  "answer": "He was a German-born theoretical physicist, widely acknowledged to be one of the greatest and most influential physicists of all time. He was best known for developing the theory of relativity, he also made important contributions to the development of the theory of quantum mechanics."
}
Output: {
  "statements": [
    "Albert Einstein was a German-born theoretical physicist.",
    "Albert Einstein is recognized as one of the greatest and most influential physicists of all time.",
    "Albert Einstein was best known for developing the theory of relativity.",
    "Albert Einstein also made important contributions to the development of the theory of quantum mechanics."
```

```

    ]
}
-----

```

Now perform the same with the following input

```

input: {
  "question": "<question>",
  "answer": "<answer or reference>"
}

```

Output:

Kiểm tra phát biểu: Faithfulness

Your task is to judge the faithfulness of a series of statements based on a given context. For each statement you must return verdict as 1 if the statement can be directly inferred based on the context or 0 if the statement can not be directly inferred based on the context.

Please return the output in a JSON format that complies with the following schema as specified in JSON Schema:
 {"\$defs": {"StatementFaithfulnessAnswer": {"properties": {"statement": {"description": "the original statement, word-by-word", "title": "Statement", "type": "string"}, "reason": {"description": "the reason of the verdict", "title": "Reason", "type": "string"}, "verdict": {"description": "the verdict(0/1) of the faithfulness.", "title": "Verdict", "type": "integer"}}, "required": ["statement", "reason", "verdict"], "title": "StatementFaithfulnessAnswer", "type": "object"}}, {"properties": {"statements": {"items": {"\$ref": "#/\$defs/StatementFaithfulnessAnswer"}, "title": "Statements", "type": "array"}}, "required": ["statements"], "title": "NLISentenceOutput", "type": "object"}Do not use single quotes in your response but double quotes, properly escaped with a backslash.

-----EXAMPLES-----

Example 1

```

Input: {
  "context": "John is a student at XYZ University. He is pursuing a degree in Computer Science. He is enrolled in several courses this semester, including Data Structures, Algorithms, and Database Management. John is a diligent student and spends a significant amount of time studying and completing assignments. He often stays late in the library to work on his projects.",
  "statements": [
    "John is majoring in Biology.",
    "John is taking a course on Artificial Intelligence.",
    "John is a dedicated student.",
    "John has a part-time job."
  ]
}

```

```

Output: {
  "statements": [
    {
      "statement": "John is majoring in Biology.",
      "reason": "John's major is explicitly mentioned as Computer Science. There is no information suggesting he is majoring in Biology.",
      "verdict": 0
    },
    {
      "statement": "John is taking a course on Artificial Intelligence.",
      "reason": "The context mentions the courses John is currently enrolled in, and Artificial Intelligence is not mentioned. Therefore, it cannot be deduced that John is taking a course on AI.",
      "verdict": 0
    },
    {
      "statement": "John is a dedicated student.",
      "reason": "The context states that he spends a significant amount of time studying and completing assignments. Additionally, it mentions that he often stays late in the library to work on his projects, which implies dedication.",
      "verdict": 1
    },
    {
      "statement": "John has a part-time job.",
      "reason": "There is no information given in the context about John having a part-time job.",
      "verdict": 0
    }
  ]
}

```

Example 2

```

Input: {
  "context": "Photosynthesis is a process used by plants, algae, and certain bacteria to convert light energy into chemical energy.",
  "statements": [
    "Albert Einstein was a genius."
  ]
}
Output: {
  "statements": [
    {
      "statement": "Albert Einstein was a genius.",
      "reason": "The context and statement are unrelated",
      "verdict": 0
    }
  ]
}

```

Now perform the same with the following input

```

input: {
  "context": "<retrieved contexts>",
  "statements": [
    "<statement>"
  ]
}
Output:

```

Phân loại TP/FP/FN: Answer Correctness

Given a ground truth and an answer statements, analyze each statement and classify them in one of the following categories: TP (true positive): statements that are present in answer that are also directly supported by the one or more statements in ground truth, FP (false positive): statements present in the answer but not directly supported by any statement in ground truth, FN (false negative): statements found in the ground truth but not present in answer. Each statement can only belong to one of the categories. Provide a reason for each classification.

Please return the output in a JSON format that complies with the following schema as specified in JSON Schema:

```

{"$defs": {"StatementsWithReason": {"properties": {"statement": {"title": "Statement", "type": "string"}, "reason": {"title": "Reason", "type": "string"}, "required": ["statement", "reason"], "title": "StatementsWithReason", "type": "object"}, "properties": {"TP": {"items": {"$ref": "#/$defs/StatementsWithReason"}, "title": "Tp", "type": "array"}, "FP": {"items": {"$ref": "#/$defs/StatementsWithReason"}, "title": "Fp", "type": "array"}, "FN": {"items": {"$ref": "#/$defs/StatementsWithReason"}, "title": "Fn", "type": "array"}, "required": ["TP", "FP", "FN"], "title": "ClassificationWithReason", "type": "object"}Do not use single quotes in your response but double quotes, properly escaped with a backslash.

```

-----EXAMPLES-----

Example 1

```

Input: {
  "question": "What powers the sun and what is its primary function?",
  "answer": [
    "The sun is powered by nuclear fission, similar to nuclear reactors on Earth.",
    "The primary function of the sun is to provide light to the solar system."
  ],
  "ground_truth": [
    "The sun is powered by nuclear fusion, where hydrogen atoms fuse to form helium.",
    "This fusion process in the sun's core releases a tremendous amount of energy.",
    "The energy from the sun provides heat and light, which are essential for life on Earth.",
    "The sun's light plays a critical role in Earth's climate system.",
    "Sunlight helps to drive the weather and ocean currents."
  ]
}
Output: {
  "TP": [
    {
      "statement": "The primary function of the sun is to provide light to the solar system.",
      "reason": "This statement is somewhat supported by the ground truth mentioning the sun providing light and its roles, though it focuses more broadly on the sun's energy."
    }
  ],
  "FP": [

```

```

    {
      "statement": "The sun is powered by nuclear fission, similar to nuclear reactors on Earth.",
      "reason": "This statement is incorrect and contradicts the ground truth which states that the sun is
powered by nuclear fusion."
    }
  ],
  "FN": [
    {
      "statement": "The sun is powered by nuclear fusion, where hydrogen atoms fuse to form helium.",
      "reason": "This accurate description of the 'suns power source is not included in the answer."
    },
    {
      "statement": "This fusion process in the sun's core releases a tremendous amount of energy.",
      "reason": "This process and its significance are not mentioned in the answer."
    },
    {
      "statement": "The energy from the sun provides heat and light, which are essential for life on Earth
.",
      "reason": "The answer only mentions light, omitting the essential aspects of heat and its necessity
for life, which the ground truth covers."
    },
    {
      "statement": "The sun's light plays a critical role in Earth's climate system.",
      "reason": "This broader impact of the 'suns light on Earth's climate system is not addressed in the
answer."
    },
    {
      "statement": "Sunlight helps to drive the weather and ocean currents.",
      "reason": "The effect of sunlight on weather patterns and ocean currents is omitted in the answer."
    }
  ]
}

```

Example 2

```

Input: {
  "question": "What is the boiling point of water?",
  "answer": [
    "The boiling point of water is 100 degrees Celsius at sea level"
  ],
  "ground_truth": [
    "The boiling point of water is 100 degrees Celsius (212 degrees Fahrenheit) at sea level.",
    "The boiling point of water can change with altitude."
  ]
}

Output: {
  "TP": [
    {
      "statement": "The boiling point of water is 100 degrees Celsius at sea level",
      "reason": "This statement is directly supported by the ground truth which specifies the boiling
point of water as 100 degrees Celsius at sea level."
    }
  ],
  "FP": [],
  "FN": [
    {
      "statement": "The boiling point of water can change with altitude.",
      "reason": "This additional information about how the boiling point of water can vary with altitude
is not mentioned in the answer."
    }
  ]
}

```

Now perform the same with the following input

```

input: {
  "question": "<question>",
  "answer": [
    "<answer statement>"
  ],
  "ground_truth": [
    "<reference statement>"
  ]
}

```

Output:

Sinh câu hỏi: Answer Relevancy

Generate a question for the given answer and Identify if answer is noncommittal. Give noncommittal as 1 if the answer is noncommittal and 0 if the answer is committal. A noncommittal answer is one that is evasive, vague, or ambiguous. For example, "I don't know" or "I'm not sure" are noncommittal answers. Please return the output in a JSON format that complies with the following schema as specified in JSON Schema: {"properties": {"question": {"title": "Question", "type": "string"}, "noncommittal": {"title": "Noncommittal", "type": "integer"}}, "required": ["question", "noncommittal"], "title": "ResponseRelevanceOutput", "type": "object"} Do not use single quotes in your response but double quotes, properly escaped with a backslash.

-----EXAMPLES-----

Example 1

Input: {
 "response": "Albert Einstein was born in Germany."
}

Output: {
 "question": "Where was Albert Einstein born?",
 "noncommittal": 0
}

Example 2

Input: {
 "response": "I don't know about the groundbreaking feature of the smartphone invented in 2023 as am unaware of information beyond 2022."
}

Output: {
 "question": "What was the groundbreaking feature of the smartphone invented in 2023?",
 "noncommittal": 1
}

Now perform the same with the following input

input: {
 "response": "<generated answer>"
}

Output:

Chấm từng context: Context Precision

Given question, answer and context verify if the context was useful in arriving at the given answer. Give verdict as "1" if useful and "0" if not with json output. Please return the output in a JSON format that complies with the following schema as specified in JSON Schema: {"properties": {"reason": {"description": "Reason for verification", "title": "Reason", "type": "string"}, "verdict": {"description": "Binary (0/1) verdict of verification", "title": "Verdict", "type": "integer"}}, "required": ["reason", "verdict"], "title": "Verification", "type": "object"} Do not use single quotes in your response but double quotes, properly escaped with a backslash.

-----EXAMPLES-----

Example 1

Input: {
 "question": "What can you tell me about Albert Einstein?",
 "context": "Albert Einstein (14 March 1879 – 18 April 1955) was a German-born theoretical physicist, widely held to be one of the greatest and most influential scientists of all time. Best known for developing the theory of relativity, he also made important contributions to quantum mechanics, and was thus a central figure in the revolutionary reshaping of the scientific understanding of nature that modern physics accomplished in the first decades of the twentieth century. His –massenergy equivalence formula $E = mc^2$, which arises from relativity theory, has been called 'the world's most famous equation'. He received the 1921 Nobel Prize in Physics 'for his services to theoretical physics, and especially for his discovery of the law of the photoelectric effect', a pivotal step in the development of quantum theory. His work is also known for its influence on the philosophy of science. In a 1999 poll of 130 leading physicists worldwide by the British journal Physics World, Einstein was ranked the greatest physicist of all time. His intellectual achievements and originality have made Einstein synonymous with genius.",
 "answer": "Albert Einstein, born on 14 March 1879, was a German-born theoretical physicist, widely held to be one of the greatest and most influential scientists of all time. He received the 1921 Nobel Prize in Physics for his services to theoretical physics."
}

```

}
Output: {
  "reason": "The provided context was indeed useful in arriving at the given answer. The context includes key information about Albert Einstein's life and contributions, which are reflected in the answer.",
  "verdict": 1
}

Example 2
Input: {
  "question": "who won 2020 icc world cup?",
  "context": "The 2022 ICC Men's T20 World Cup, held from October 16 to November 13, 2022, in Australia, was the eighth edition of the tournament. Originally scheduled for 2020, it was postponed due to the COVID-19 pandemic. England emerged victorious, defeating Pakistan by five wickets in the final to clinch their second ICC Men's T20 World Cup title.",
  "answer": "England"
}
Output: {
  "reason": "the context was useful in clarifying the situation regarding the 2020 ICC World Cup and indicating that England was the winner of the tournament that was intended to be held in 2020 but actually took place in 2022.",
  "verdict": 1
}

Example 3
Input: {
  "question": "What is the tallest mountain in the world?",
  "context": "The Andes is the longest continental mountain range in the world, located in South America. It stretches across seven countries and features many of the highest peaks in the Western Hemisphere. The range is known for its diverse ecosystems, including the high-altitude Andean Plateau and the Amazon rainforest.",
  "answer": "Mount Everest."
}
Output: {
  "reason": "the provided context discusses the Andes mountain range, which, while impressive, does not include Mount Everest or directly relate to the question about the world's tallest mountain.",
  "verdict": 0
}
}
-----

Now perform the same with the following input
input: {
  "question": "<question>",
  "context": "<one retrieved context>",
  "answer": "<reference>"
}
Output:

```

Kiểm tra độ phủ gold: Context Recall

```

Given a context, and an answer, analyze each sentence in the answer and classify if the sentence can be attributed to the given context or not. Use only 'Yes' (1) or 'No' (0) as a binary classification. Output json with reason.

Please return the output in a JSON format that complies with the following schema as specified in JSON Schema:
{"$defs": {"ContextRecallClassification": {"properties": {"statement": {"title": "Statement", "type": "string"}, "reason": {"title": "Reason", "type": "string"}, "attributed": {"title": "Attributed", "type": "integer"}}, "required": ["statement", "reason", "attributed"], "title": "ContextRecallClassification", "type": "object"}}, {"properties": {"classifications": {"items": {"$ref": "#/$defs/ContextRecallClassification"}, "title": "Classifications", "type": "array"}}, "required": ["classifications"], "title": "ContextRecallClassifications", "type": "object"}}Do not use single quotes in your response but double quotes ,properly escaped with a backslash.

-----EXAMPLES-----
Example 1
Input: {
  "question": "What can you tell me about albert Albert Einstein?",
  "context": "Albert Einstein (14 March 1879 – 18 April 1955) was a German-born theoretical physicist, widely held to be one of the greatest and most influential scientists of all time. Best known for developing the theory of relativity, he also made important contributions to quantum mechanics, and was thus a central figure in the revolutionary reshaping of the scientific understanding of nature that modern physics accomplished in the first decades of the twentieth century. His mass–energy equivalence formula  $E = mc^2$ ,

```

```

which arises from relativity theory, has been called 'the world's most famous equation'. He received the
1921 Nobel Prize in Physics 'for his services to theoretical physics, and especially for his discovery of
the law of the photoelectric effect', a pivotal step in the development of quantum theory. His work is also
known for its influence on the philosophy of science. In a 1999 poll of 130 leading physicists worldwide
by the British journal Physics World, Einstein was ranked the greatest physicist of all time. His
intellectual achievements and originality have made Einstein synonymous with genius.",
"answer": "Albert Einstein, born on 14 March 1879, was a German-born theoretical physicist, widely held to
be one of the greatest and most influential scientists of all time. He received the 1921 Nobel Prize in
Physics for his services to theoretical physics. He published 4 papers in 1905. Einstein moved to
Switzerland in 1895."
}
Output: {
  "classifications": [
    {
      "statement": "Albert Einstein, born on 14 March 1879, was a German-born theoretical physicist,
widely held to be one of the greatest and most influential scientists of all time.",
      "reason": "The date of birth of Einstein is mentioned clearly in the context.",
      "attributed": 1
    },
    {
      "statement": "He received the 1921 Nobel Prize in Physics for his services to theoretical physics.",
      "reason": "The exact sentence is present in the given context.",
      "attributed": 1
    },
    {
      "statement": "He published 4 papers in 1905.",
      "reason": "There is no mention about papers he wrote in the given context.",
      "attributed": 0
    },
    {
      "statement": "Einstein moved to Switzerland in 1895.",
      "reason": "There is no supporting evidence for this in the given context.",
      "attributed": 0
    }
  ]
}
}

-----

Now perform the same with the following input
input: {
  "question": "<question>",
  "context": "<retrieved contexts>",
  "answer": "<reference>"
}
Output:

```

D Cách chấm citation

Generator nhận các context đánh số [1]–[5]. Bộ chấm ánh xạ chỉ số trong đáp án về chunk ID theo đúng thứ tự context đã gửi. Ví dụ tổng hợp: [1]–[5] lần lượt là c1–c5, còn tập gold là {c2, c4}.

Bảng 24: Ví dụ phân biệt citation hợp lệ và citation đúng bằng chứng.

Citation	Chunk được cite	Validity	Precision	Recall	Giải thích
[2]	c2	1	1	0,5	Hợp lệ, đúng một trong hai gold.
[3]	c3	1	0	0	Hợp lệ nhưng sai bằng chứng.
[6]	Không có	0	0	0	Vượt số context đã gửi.
[2] [3]	c2, c3	1	0,5	0,5	Có một citation thừa.

- **Citation Validity** = $|C| / (|C| + |I|)$, với C là tập chunk ID được cite từ chỉ số hợp lệ và I là tập chỉ số citation ngoài phạm vi. Không có citation thì điểm bằng 0.

- **Citation Precision** = $|C \cap G|/|C|$: bao nhiêu chunk được cite thực sự thuộc gold G .
- **Citation Recall** = $|C \cap G|/|G|$: tỷ lệ gold chunks được cite.
- **Citation F1** = $2PR/(P + R)$ khi $P + R > 0$; nếu không thì bằng 0.
- Bộ chấm loại citation trùng trước khi tính và tính điểm từng câu rồi lấy trung bình. Validity chỉ kiểm tra chỉ số tồn tại, không xác nhận claim được context hỗ trợ về mặt ngữ nghĩa.

E Nguồn tái lập

- Prompt generator: `configs/experiments/phase2_generation_prompts.yaml`; prompt one-shot và SHA-256: `one_shot_prompt_contract.json` trong artifact development P2-1S.
- Prompt judge: các file `.txt` và `manifest.json` trong `docs/latex/report/appendix/ragas_prompts/`; chạy lại `scripts/export_report_ragas_prompts.py` với RAGAS 0.4.3 để đối chiếu.
- Bộ chấm citation: `common/newsqa_rag/evaluation/metrics.py`; ánh xạ [n] và loại chỉ số ngoài phạm vi: `common/newsqa_rag/response_parsing.py`.
- Mỗi `run_manifest.json` ghi model, question IDs, prompt hash và coverage. Bảng điểm đầy đủ ở `results/phase2/`.