

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN
BỘ MÔN CÔNG NGHỆ TRI THỨC



BÁO CÁO ĐỒ ÁN

Đề tài: Hệ thống hỏi đáp tin tức NewsLens

Môn học: Khai phá văn bản (Text Mining)

Sinh viên thực hiện:

23127011 — Lê Anh Duy
23127199 — Trần Gia Huy
23127080 — Nguyễn Đức Khương
Lam
23127305 — Nguyễn Hiệp Thắng

Giảng viên hướng dẫn:

GV Lý thuyết:
TS. Lê Thanh Tùng
GV Thực hành:
TA. Trần Hoàng Quân

Kho lưu trữ mã nguồn (GitHub):

<https://github.com/ThomasdeCarpio/Text-Mining---NewsQA-RAG/tree/main>

TP. Hồ Chí Minh, Tháng 09/2026

Tóm tắt nội dung

Báo cáo kỹ thuật này trình bày thiết kế, hiện thực hóa và quy trình đánh giá thực nghiệm hệ thống **NewsLens** — giải pháp hỏi đáp tin tức dựa trên mô hình Sinh có Tăng cường Truy xuất (Retrieval-Augmented Generation – RAG). Trên kho dữ liệu gồm 11.064 bài báo CNN và 1.152 câu hỏi bổ sung ngữ cảnh tìm kiếm từ tập dữ liệu NewsQA, bài toán đặt ra thách thức lớn từ hai nguồn sai sót độc lập: tầng truy xuất bỏ sót đoạn văn bản chứa bằng chứng, và tầng sinh câu trả lời bịa đặt thông tin (hallucination) hoặc trích dẫn nguồn không chính xác.

Hệ thống NewsLens kết hợp ứng dụng hỏi đáp (frontend React, backend FastAPI, cơ sở dữ liệu vector Chroma và chỉ mục thưa BM25S) với quy trình thực nghiệm đa giai đoạn được đăng ký trước (pre-registration). Mọi quyết định lựa chọn cấu hình đều tuân thủ nguyên tắc kiểm định bootstrap ghép cặp gom cụm theo bài báo (paired article-cluster bootstrap) kết hợp hệ thống rào chắn an toàn (safety guardrails) đa chỉ số, đảm bảo cấu hình được chọn duy trì chất lượng ổn định và cân bằng trên các tiêu chí đánh giá thay vì chỉ ưu tiên điểm số của một chỉ số đơn lẻ.

Kết quả thực nghiệm trên tập phát triển và tập kiểm định độc lập chỉ ra:

- Tầng truy xuất (Giai đoạn 1):** Mô hình BGE-M3 Sparse vượt trội các mô hình dense retriever với mức tăng +0,1634 nDCG@5 (CI95 [+0,1231; +0,2080]). Việc bổ sung bộ tái xếp hạng Cross-Encoder BGE-Reranker-Large tiếp tục cải thiện +0,0659 nDCG@5, đưa tỷ lệ tìm thấy bằng chứng Hit@5 đạt 95,73% trên tập phát triển và 89,78% trên 871 câu hỏi kiểm định cuối kỳ.
- Tầng sinh đáp án (Giai đoạn 2):** Prompt P2 (ràng buộc loại thông tin trong một câu duy nhất) kết hợp 5 đoạn ngữ cảnh vượt qua cả 4 rào chắn an toàn, trong khi P2-depth3 bị loại do vi phạm rào chắn Faithfulness (−0,0200) và Citation Validity (−0,0142). Thử nghiệm mở rộng cho thấy prompt one-shot (P2-1S) cải thiện rõ rệt độ khớp hình thức (Exact Match tăng lên 0,3559, Token F1 đạt 0,6267, Answer Correctness đạt 0,8015). Khảo sát các mô hình sinh làm rõ sự đánh đổi: Gemini 3.5 Flash-Lite đạt Answer Correctness cao nhất (0,8164) và độ trễ P95 thấp nhất (0,89 s), trong khi Gemini 3.1 Flash-Lite duy trì độ trung thực (Faithfulness 0,9603) và chất lượng trích dẫn tốt nhất.
- Bài học phương pháp luận:** Xuyên suốt ba giai đoạn thử nghiệm liên tiếp (Phase 2B, Phase 2C và Phase 3), các cấu hình đạt điểm số cao nhất ở chỉ số chính đều bị loại do vi phạm rào chắn an toàn đã đăng ký trước, khẳng định vai trò của hệ thống rào chắn đa chỉ số trong việc ngăn ngừa rủi ro suy giảm hiệu năng trên các khía cạnh khác.
- Khả năng tổng quát hóa:** Cấu hình tối ưu khóa trước đạt Answer Correctness 0,7157 (zero-shot) và 0,7557 (one-shot) trên 284 câu hỏi của 50 bài báo held-out hoàn toàn chưa từng dùng để tinh chỉnh, chứng minh tính ổn định và độ tin cậy của hệ thống trên dữ liệu thực tế.

Mã nguồn (GitHub): <https://github.com/ThomasdeCarpio/Text-Mining---NewsQA-RAG/tree/main>

Video Demo: https://drive.google.com/file/d/1M3nf3z-kyqB0_QBA6DVe4uClQB_iRqwQG/view?usp=sharing

Từ khóa: Retrieval-Augmented Generation (RAG), NewsQA, Dense & Sparse Retrieval, Cross-Encoder Reranking, One-shot Prompting, Generator Ablation, Citation Verification, Pre-registration.

Mục lục

1	Giới thiệu	1
1.1	Bối cảnh và Động lực	1
1.2	Mục tiêu của đồ án	1
1.3	Các câu hỏi nghiên cứu then chốt	1
1.4	Đóng góp của đồ án	2
1.5	Cấu trúc của báo cáo	2
2	Kiến trúc hệ thống và Pipeline	3
2.1	Kiến trúc tổng thể hệ thống NewsLens	3
2.1.1	Tầng giao diện người dùng (Frontend Client)	3
2.1.2	Tầng dịch vụ điều phối (Backend Application Services)	3
2.1.3	Tầng lõi RAG dùng chung (common/newsqa_rag)	4
2.2	Quy trình xử lý Pipeline RAG End-to-End	4
2.3	Sơ đồ minh họa Pipeline	5
2.4	Giao diện người dùng và Minh họa ứng dụng	6
2.4.1	Giao diện Hỏi đáp tin tức (News Chat)	6
2.4.2	Bàn thử nghiệm Truy xuất (Retrieval Playground)	6
3	Dữ liệu và phương pháp đánh giá	7
3.1	Dữ liệu	7
3.1.1	Nguồn dữ liệu	7
3.1.2	Hiệu chỉnh câu hỏi đánh giá	8
3.2	Chia tập	9
3.3	Nguyên tắc thực nghiệm	9
3.3.1	Phase 1: đánh giá retrieval	9
3.3.2	Phase 2: đánh giá generation end-to-end	10
3.4	Thước đo và kiểm định	10
3.4.1	Thước đo retrieval	10
3.4.2	Thước đo generation và citation	11
3.4.3	Khoảng tin cậy và điều kiện chọn cấu hình	11
4	Giai đoạn 1: Truy xuất	12
4.1	Thiết kế thực nghiệm	12
4.2	Sàng lọc retriever	13
4.3	Sàng lọc chiến lược retrieval và reranker	13
4.4	Final-test và cấu hình retrieval khóa	14

5	Giai đoạn 2: Sinh câu trả lời	15
5.1	Thiết kế thực nghiệm	15
5.2	Thiết lập và kết quả baseline end-to-end	15
5.3	Sàng lọc prompt zero-shot	16
5.4	Sàng lọc số lượng context	16
5.5	Kết quả zero-shot trên development và held-out	17
5.6	Thử nghiệm prompt one-shot	17
5.7	So sánh các mô hình sinh câu trả lời	19
5.8	Khảo sát mở rộng: Phân đoạn văn bản và Chính sách từ chối	20
6	Tổng kết kết quả và Thảo luận	20
6.1	Tổng hợp kết quả qua các giai đoạn thực nghiệm	20
6.2	Trả lời trực diện hai câu hỏi nghiên cứu cốt lõi	21
6.3	Bài học từ các khảo sát mở rộng (Ablation Studies)	23
6.4	Bài học phương pháp luận: Hiện tượng “Luật thắng điểm số”	23
6.5	Giới hạn của nghiên cứu	24
6.6	Hướng phát triển trong tương lai	25
7	Kết luận	25
	Tài liệu tham khảo	27
	Phụ lục	28
A	Prompt zero-shot	28
B	Prompt one-shot P2-1S	29
C	Prompt judge RAGAS	29
D	Cách chấm citation	36
E	Khảo sát mở rộng: Phân đoạn văn bản và Chính sách từ chối	37
E.1	Khảo sát chiến lược phân đoạn văn bản (Giai đoạn 2C)	37
E.2	Khảo sát chính sách từ chối trả lời (Giai đoạn 3)	37
F	Nguồn tái lập	38

Danh sách bảng

1	Quy mô các split NewsQA nguồn.	8
2	Các mốc tạo tập câu hỏi đánh giá.	8
3	Các vấn đề được ghi nhận khi review.	9
4	Các partition của tập resolved deduplicated.	9
5	Các chế độ chạy trong Phase 2.	10
6	Vai trò của các thước đo Phase 2.	11
7	Guardrail dùng khi chọn cấu hình Phase 2 trên full development.	12
8	Kết quả sàng lọc retriever trên 281 câu resolved.	13
9	MRR@5 và nDCG@5 theo retriever và reranker trên tập development.	13
10	Độ trễ P50 của ma trận Phase 1 trên cùng môi trường chạy.	14
11	Kết quả của pipeline retrieval đã khóa.	14
12	Baseline P0-depth5 trên 281 câu development.	15
13	Các zero-shot prompt được khảo sát.	16
14	Sàng lọc prompt trên 80 câu; RAGAS dùng cùng 20 câu calibration.	16
15	Ảnh hưởng của context depth trên tập screening.	16
16	Kết quả finalist trên toàn bộ development.	17
17	P2-depth5 trên development và held-out.	17
18	So sánh P2 zero-shot và one-shot, cùng depth 5, trên development.	18
19	P2 one-shot trên development và held-out; chỉ kiểm tra khả năng tổng quát hóa của cùng cấu hình, không chọn lại prompt.	18
20	Sai khác paired của P2-1S so với zero-shot P2-depth5 trên 281 câu development; CI95 bootstrap theo 50 bài, 2.000 lần lấy mẫu.	18
21	Generator ablation với P2-1S-depth5 trên development.	19
22	Sai khác so với Gemini 3.1 Flash-Lite và tài nguyên generation trên 281 câu. CI95 là paired article-cluster bootstrap (2.000 mẫu).	19
23	Tổng hợp kết quả thực nghiệm qua các giai đoạn của đồ án NewsLens.	21
24	Minh chứng hiện tượng “Luật thắng điểm số” qua ba giai đoạn thực nghiệm.	24
25	Template RAGAS được dùng cho năm metric.	29
26	Ví dụ phân biệt citation hợp lệ và citation đúng bằng chứng.	36
27	Kết quả sàng lọc truy xuất của các chiến lược phân đoạn văn bản (Giai đoạn 2C).	37
28	So sánh các chính sách từ chối trả lời trên tập Development (140 câu) và Final (60 câu).	37

Danh sách hình vẽ

1	Sơ đồ kiến trúc Pipeline RAG hai tầng của hệ thống NewsLens: Tầng Offline (Chuẩn bị dữ liệu NewsQA, phân đoạn văn bản 512/64 và lập chỉ mục kép) và Tầng Online (Truy xuất thừa BGE-M3 Top-20, Tái xếp hạng BGE-Reranker Top-5, Sinh đáp án với Prompt P2 trên Gemini 3.1 Flash-Lite, và Xác thực trích dẫn nguồn).	5
2	Giao diện Hỏi đáp NewsLens (News Chat): Phản hồi câu trả lời súc tích kèm ký hiệu trích dẫn [1] và khung mở rộng “View Sources” hiển thị trích đoạn bài báo CNN cùng liên kết URL gốc.	6
3	Giao diện Bàn thử nghiệm Truy xuất (Retrieval Playground): Cho phép kiểm tra trực tiếp kho chỉ mục 22.766 chunks, xem điểm tương quan của các đoạn văn bản ứng viên và phân tích chi tiết độ trễ thực thi.	7

1 Giới thiệu

1.1 Bối cảnh và Động lực

Khối lượng tin tức trực tuyến khổng lồ đặt ra nhu cầu cấp thiết về các hệ thống hỏi đáp tin tức (News Question Answering – News QA) có khả năng cung cấp câu trả lời chính xác, ngắn gọn và có nguồn dẫn kiểm chứng. Mặc dù các mô hình ngôn ngữ lớn (LLMs) [7, 1] thể hiện năng lực hiểu ngôn ngữ ấn tượng, việc ứng dụng trực tiếp LLMs vào tác vụ này gặp phải ba hạn chế cố hữu: (i) hiện tượng ảo giác (hallucination) [5]; (ii) giới hạn tri thức đóng băng (knowledge cutoff); và (iii) thiếu khả năng kiểm chứng nguồn gốc thông tin (lack of provenance).

Mô hình Sinh có Tăng cường Truy xuất (Retrieval-Augmented Generation – RAG) [6] giải quyết các hạn chế trên bằng cách kết hợp một bộ truy xuất (retriever) tìm kiếm ngữ cảnh liên quan từ kho dữ liệu ngoài và một bộ sinh (generator) tổng hợp câu trả lời dựa trên ngữ cảnh đó. Tuy nhiên, trên ngữ liệu tin tức quy mô lớn với độ nhiễu cao, bài toán đặt ra thách thức lớn do hai nguồn sai sót độc lập ở hai tầng xử lý:

- **Sai sót ở tầng truy xuất (Retrieval Failure):** Bộ truy xuất không đưa được đoạn văn bản chứa bằng chứng (gold chunk) vào danh sách ứng viên do sự hiện diện của nhiều bài báo tương tự hoặc các bài viết gây phân tâm (distractors).
- **Sai sót ở tầng sinh (Generation Failure):** Mô hình ngôn ngữ suy diễn sai, diễn đạt dài dòng làm lệch trọng tâm câu hỏi, hoặc trích dẫn sai nguồn dù đoạn văn bằng chứng đã nằm trọn vẹn trong ngữ cảnh.

Nếu chỉ đo lường điểm số ở đầu ra cuối cùng, rất khó phân định sai sót bắt nguồn từ khâu truy xuất hay khâu tạo sinh. Do đó, đồ án này đặt ra yêu cầu phân tách độc lập hai tầng chức năng, xây dựng hệ thống đo lường chuyên biệt cho từng tầng, và áp dụng quy trình thực nghiệm có kiểm soát chặt chẽ.

1.2 Mục tiêu của đồ án

Đồ án hướng tới hai mục tiêu đồng bộ:

1. **Mục tiêu kỹ thuật:** Thiết kế và hiện thực hóa hệ thống hỏi đáp tin tức **NewsLens** (frontend React, backend FastAPI, thư viện lõi newsqa_rag) với quy trình xử lý dữ liệu NewsQA, lập chỉ mục kép (vector Chroma và chỉ mục thưa BM25S), tầng truy xuất kết hợp tái xếp hạng, và giao diện hỏi đáp hiển thị trích dẫn nguồn có thể kiểm tra trực tiếp.
2. **Mục tiêu phương pháp luận:** Xây dựng quy trình thực nghiệm khoa học dựa trên nguyên tắc đăng ký trước (pre-registration), ứng dụng kiểm định thống kê bootstrap ghép cặp gom cụm theo bài báo (paired article-cluster bootstrap), và thiết lập hệ thống rào chắn an toàn (safety guardrails) nhằm đảm bảo các quyết định lựa chọn kỹ thuật mang tính khách quan và kiểm soát được sự suy thoái chất lượng.

1.3 Các câu hỏi nghiên cứu then chốt

Đồ án tập trung giải quyết hai câu hỏi nghiên cứu cốt lõi tương ứng với hai tầng chức năng chính của hệ thống:

- Q1:** *Phương pháp truy xuất nào (Dense, BM25, Sparse, Hybrid) cùng cơ chế tái xếp hạng nào định vị đoạn văn bản chứa bằng chứng hiệu quả nhất trên kho tin tức quy mô lớn có độ nhiễu cao?*
- Q2:** *Chiến lược cấu trúc chỉ thị (prompt engineering) và độ sâu ngữ cảnh (context_depth) nào giúp bộ sinh đạt độ chính xác tối ưu mà vẫn bảo toàn tính trung thực (Faithfulness) và độ hợp lệ của trích dẫn (Citation Validity)?*

Bên cạnh hai câu hỏi trọng tâm, đồ án tiến hành hai khảo sát mở rộng (*ablation studies*) nhằm kiểm chứng các quyết định thiết kế: (i) Tác động của các chiến lược phân đoạn văn bản (chunking) đến trần hiệu năng truy xuất và độ chính xác câu trả lời; và (ii) Năng lực nhận diện ranh giới thông tin cùng cơ chế từ chối trả lời (abstention) một cách tin cậy khi ngữ cảnh thiếu hụt bằng chứng.

Song hành với đó là câu hỏi phương pháp luận xuyên suốt: *Làm thế nào để phân định một cải tiến kỹ thuật là thực chất so với nhiễu đo lường của dữ liệu?* Vấn đề này được đồ án giải quyết thông qua việc xác định biên độ nhập nhằng, khoảng tin cậy bootstrap 95% và hệ thống rào chắn an toàn được khóa cứng trước khi quan sát dữ liệu.

1.4 Đóng góp của đồ án

Các đóng góp chính của đồ án bao gồm:

- 1. Xây dựng ứng dụng hoàn chỉnh:** Phát triển ứng dụng hỏi đáp NewsLens (frontend React, backend FastAPI) kết hợp thư viện lõi `newsqa_rag`, tích hợp giao diện hội thoại hiển thị nguồn trích dẫn và công cụ Bàn thử nghiệm truy xuất (Retrieval Playground) phục vụ kiểm thử độc lập. Toàn bộ mã nguồn dự án được công khai tại <https://github.com/ThomasdeCarpio/Text-Mining---NewsQA-RAG/tree/main> và video trình diễn hệ thống (demo) tại https://drive.google.com/file/d/1M3nf3z-kyqBO_QBA6DVe4uClQBiRqwQG/view?usp=sharing.
- 2. Phương pháp luận thực nghiệm chuẩn hóa:** Thiết lập quy trình đánh giá minh bạch với toàn bộ kế hoạch, ngưỡng sai số và mã băm chỉ mục được đăng ký trước; áp dụng kiểm định bootstrap gom cụm theo bài báo để phản ánh chính xác cấu trúc phụ thuộc dữ liệu.
- 3. Đánh giá đa chiều với hệ thống rào chắn an toàn:** Khảo sát toàn diện cả hai khâu truy xuất và tạo sinh dưới sự kiểm soát của hệ thống rào chắn an toàn đa chỉ số, giúp tránh việc thiên vị một cấu hình chỉ vì điểm số cao ở một chỉ số đơn lẻ trong khi chất lượng câu trả lời và các tiêu chí khác không ổn định.
- 4. Kiểm định độc lập năng lực tổng quát hóa:** Thiết kế tập kiểm thử held-out (284 câu hỏi từ 50 bài báo) được giữ kín hoàn toàn trong quá trình phát triển để đánh giá khách quan độ tin cậy của pipeline trong điều kiện thực tế.

1.5 Cấu trúc của báo cáo

Phần còn lại của báo cáo được tổ chức như sau:

- **Mục 2:** Trình bày kiến trúc phần mềm phân tầng và luồng xử lý RAG end-to-end của NewsLens.

- **Mục 3 (Dữ liệu và phương pháp đánh giá):** Mô tả tập dữ liệu NewsQA, quy trình chuẩn bị dữ liệu, hệ thống chỉ số đo lường và phương pháp kiểm định thống kê.
- **Mục 4 (Giai đoạn 1: Truy xuất):** Báo cáo chi tiết quy trình thực nghiệm so sánh các phương pháp truy xuất và tái xếp hạng nhằm giải quyết câu hỏi Q1.
- **Mục 5 (Giai đoạn 2: Sinh câu trả lời):** Báo cáo chi tiết các thử nghiệm về cấu trúc prompt, độ sâu ngữ cảnh nhằm giải quyết câu hỏi Q2, khảo sát các mô hình sinh và tóm lược hai khảo sát mở rộng.
- **Mục 6:** Tổng hợp kết quả toàn diện, trả lời trực diện hai câu hỏi nghiên cứu, phân tích bài học từ các khảo sát mở rộng, hiện tượng “Luật thắng điểm số” và các giới hạn của nghiên cứu.
- **Mục 7:** Đưa ra kết luận chung và định hướng phát triển tiếp theo.
- **Phụ lục:** Cung cấp chi tiết các mẫu prompt, cấu hình RAGAS, công thức chấm trích dẫn và toàn bộ bảng số liệu của các khảo sát mở rộng.

2 Kiến trúc hệ thống và Pipeline

2.1 Kiến trúc tổng thể hệ thống NewsLens

Hệ thống NewsLens được xây dựng theo mô hình kiến trúc phân tầng module hóa (layered modular architecture), tách bạch giữa tầng giao diện người dùng (Presentation Layer), tầng dịch vụ và điều phối (Application Service Layer), và tầng lõi nghiệp vụ RAG (Core RAG Engine). Toàn bộ mã nguồn, cấu hình triển khai và hướng dẫn thiết lập hệ thống được lưu trữ công khai tại kho lưu trữ GitHub của đồ án: <https://github.com/ThomasdeCarpio/Text-Mining---NewsQA-RAG/tree/main>. Thiết kế này vừa phục vụ tương tác hỏi đáp thời gian thực cho người dùng cuối, vừa đóng vai trò như một nền tảng phục vụ công tác nghiên cứu và giám sát thực nghiệm.

2.1.1 Tầng giao diện người dùng (Frontend Client)

Được xây dựng bằng React và TypeScript, cung cấp hai giao diện tương tác chính:

- **Màn hình Hỏi đáp (Chat Interface):** Giao diện đối thoại cho phép người dùng nhập câu hỏi và nhận câu trả lời kèm danh sách trích dẫn nguồn (CitationList). Người dùng có thể nhấp chọn “View Sources” để xem chi tiết trích đoạn văn bản gốc, tiêu đề bài báo, ngày xuất bản và liên kết URL tới bài báo nguồn CNN.
- **Bàn thử nghiệm Truy xuất (Retrieval Playground):** Màn hình phục vụ kiểm thử độc lập tầng truy xuất. Người dùng có thể kiểm tra dung lượng bộ chỉ mục, nhập truy vấn tùy ý, lựa chọn giữa các thuật toán truy xuất (Dense, BM25, Sparse BGE-M3, Hybrid, hoặc Locked), tùy biến tham số Top- k , và theo dõi điểm tương đồng cùng biểu đồ phân rã độ trễ của từng thành phần (bộ truy xuất hay bộ tái xếp hạng).

2.1.2 Tầng dịch vụ điều phối (Backend Application Services)

Được hiện thực bằng FastAPI trên nền Python, chịu trách nhiệm quản lý phiên làm việc, phân luồng yêu cầu và kết nối giao diện với tầng lõi RAG:

- `chat_service.py`: Quản lý phiên hội thoại, điều phối tiến trình gọi pipeline RAG và phản hồi câu trả lời kèm trích dẫn nguồn cho người dùng.
- `retrieval_service.py`: Thực hiện các truy vấn tìm kiếm trực tiếp vào kho chỉ mục vector hoặc chỉ mục thưa theo yêu cầu từ giao diện.
- `auth_service.py`: Xác thực phiên làm việc cho người dùng và khách truy cập trong môi trường trình diễn đồ án.

2.1.3 Tầng lõi RAG dùng chung (`common/newsqa_rag`)

Được tổ chức thành thư viện Python độc lập (`newsqa_rag`) có thể tái sử dụng nhất quán giữa ứng dụng web, các tập lệnh CLI (`scripts/`) và notebook nghiên cứu:

- **Module nạp và phân đoạn văn bản (`ingestion/`):** Tiền xử lý văn bản thô, làm sạch ký tự và chia tách bài báo thành các đoạn (chunks) theo các chiến lược: Recursive Character Splitter (kích thước và độ chồng lặp tùy biến), Sentence Splitter, Paragraph Splitter và Phân cấp Parent–Child.
- **Module lập chỉ mục (`indexing/`):** Quản lý cơ sở dữ liệu vector Chroma (ChromaDB) lưu trữ dense embeddings từ các mô hình như BGE-M3 [2] hoặc MiniLM [8], đồng thời quản lý chỉ mục đảo thưa được tối ưu hóa bằng BM25S [9].
- **Module truy xuất và tái xếp hạng (`retrieval/`):** Cung cấp các lớp giao tiếp cho Dense Retriever, Sparse Retriever, Hybrid Retriever (kết hợp điểm số theo Reciprocal Rank Fusion – RRF [3]) và mô hình tái xếp hạng chéo Cross-Encoder (`bge-reranker-large` [10]).
- **Module tác tử và giao tiếp LLM (`agents/`, `llm.py`):** Hiện thực lớp điều phối RAGAgent, đóng gói các mẫu chỉ thị trong kho đăng ký prompt (P0–P3, B0–B2) và kết nối với các mô hình ngôn ngữ lớn (Gemini 3.1 Flash-Lite, GPT-4o-mini).
- **Module phân tích và đánh giá (`evaluation/`, `response_parsing.py`):** Bóc tách nhãn trích dẫn [n], ánh xạ về ID đoạn văn bản nguồn, kiểm tra tính hợp lệ của trích dẫn và kết nối bộ giám khảo RAGAS [4].

2.2 Quy trình xử lý Pipeline RAG End-to-End

Khi tiếp nhận truy vấn, hệ thống NewsLens thực thi tuần tự quy trình 6 bước xử lý khép kín:


1. **Bước 1: Tiếp nhận và xử lý câu hỏi (Query Ingestion):** Quy trình tiếp nhận được phân định rõ ràng theo hai trường hợp sử dụng (use cases):
 - **Đối với ứng dụng Chat thực tế:** Hệ thống tiếp nhận trực tiếp câu hỏi tự nhiên từ người dùng qua API để chuyển thẳng vào luồng truy xuất và trả lời.
 - **Đối với hệ thống đánh giá thực nghiệm (Benchmark):** Pipeline sử dụng tập câu hỏi đã được chuẩn hóa ngữ cảnh (Resolved Questions) từ bộ dữ liệu NewsQA — trong đó tên thực thể và mốc sự kiện đã được bổ sung đầy đủ — nhằm đánh giá độc lập và khách quan năng lực định vị bằng chứng của các mô hình truy xuất trên kho dữ liệu quy mô lớn.
2. **Bước 2: Truy xuất ứng viên giai đoạn 1 (First-Stage Candidate Retrieval):** Bộ truy xuất thưa **BGE-M3 Sparse Retriever** quét kho 22.766 đoạn văn bản (từ 11.064 bài báo

CNN) dựa trên trọng số từ vựng chuyên biệt, trích xuất tập hợp 20 đoạn ứng viên có điểm số cao nhất (thời gian xử lý 11–15 ms).

- Bước 3: Tái xếp hạng chéo giai đoạn 2 (Second-Stage Cross-Encoder Reranking):** Tập 20 đoạn ứng viên được đưa qua mô hình **BGE-Reranker-Large**. Mô hình Cross-Encoder đánh giá đồng thời cặp (Câu hỏi, Đoạn văn) qua cơ chế cross-attention của transformer để phân tích tương quan ngữ nghĩa sâu, chọn lọc ra 5 đoạn văn bản liên quan nhất cung cấp cho bộ sinh.
- Bước 4: Đóng gói ngữ cảnh và định dạng chỉ thị (Context Assembly & Prompt Formatting):** Năm đoạn văn bản được định dạng theo danh sách đánh số [1] đến [5], kết hợp cùng mẫu chỉ thị **Prompt P2**. Mẫu prompt này yêu cầu mô hình: (i) chỉ dựa vào thông tin có trong 5 đoạn văn bản; (ii) trả lời ngắn gọn, trực diện đúng loại thông tin được hỏi; và (iii) bắt buộc gắn nhãn trích dẫn [n] ngay sau mỗi sự kiện.
- Bước 5: Sinh câu trả lời có kiểm chứng (Grounded Generation):** Ngữ cảnh và chỉ thị được gửi tới mô hình ngôn ngữ lớn **Gemini 3.1 Flash-Lite** (với $\text{temperature} = 0$, $\text{reasoning} = \text{minimal}$, giới hạn 512 tokens) để sinh câu trả lời có nguồn dẫn.
- Bước 6: Bóc tách cú pháp và xác thực trích dẫn (Citation Validation):** Bộ phân tích `response_parsing.py` quét chuỗi câu trả lời để bóc tách nhãn trích dẫn [n], kiểm tra tính hợp lệ trong dải $\{1, \dots, 5\}$, và ánh xạ chỉ số này về Chunk ID cùng metadata bài báo gốc để hiển thị minh bạch cho người dùng.

2.3 Sơ đồ minh họa Pipeline

Hình 1 minh họa kiến trúc pipeline hai tầng của NewsLens từ khâu chuẩn bị dữ liệu offline đến luồng xử lý truy xuất và sinh câu trả lời online.



Hình 1: Sơ đồ kiến trúc Pipeline RAG hai tầng của hệ thống NewsLens: Tầng Offline (Chuẩn bị dữ liệu NewsQA, phân đoạn văn bản 512/64 và lập chỉ mục kép) và Tầng Online (Truy xuất thưa BGE-M3 Top-20, Tái xếp hạng BGE-Reranker Top-5, Sinh đáp án với Prompt P2 trên Gemini 3.1 Flash-Lite, và Xác thực trích dẫn nguồn).

Ghi chú mã nguồn sơ đồ: Nhóm tác giả đã đóng gói sơ đồ kiến trúc này dưới dạng tệp tương


tác HTML/CSS độc lập tại docs/latex/figures/pipeline_diagram.html, tích hợp mã nguồn Mermaid và bố cục trực quan độ nét cao.

2.4 Giao diện người dùng và Minh họa ứng dụng

Dưới đây là minh họa hai phân hệ người dùng chính của NewsLens đang hoạt động trên môi trường thực tế:

2.4.1 Giao diện Hỏi đáp tin tức (News Chat)


Hình 2 thể hiện màn hình đối thoại trực tiếp. Khi người dùng đặt câu hỏi (ví dụ vụ án Nithari), hệ thống kích hoạt pipeline, trả về câu trả lời “*Pandher was sentenced to death in February 2009 [1]*.” kèm thẻ trích dẫn [1]. Khi mở rộng mục **View Sources**, khung chi tiết sẽ hiển thị trích đoạn bài báo CNN gốc, ngày đăng, vị trí đoạn văn bản chứa bằng chứng và đường dẫn URL nguồn.



Hình 2: Giao diện Hỏi đáp NewsLens (News Chat): Phản hồi câu trả lời súc tích kèm ký hiệu trích dẫn [1] và khung mở rộng “View Sources” hiển thị trích đoạn bài báo CNN cùng liên kết URL gốc.

2.4.2 Bàn thử nghiệm Truy xuất (Retrieval Playground)

Hình 3 thể hiện công cụ kiểm thử tăng truy xuất độc lập. Người dùng có thể kiểm tra kho chỉ mục 22.766 đoạn văn bản, nhập truy vấn kiểm thử, so sánh giữa các thuật toán truy xuất, xem điểm số tương đồng của từng đoạn văn ứng viên và phân tích biểu đồ độ trễ thực thi của từng bước (Sparse: 12 ms, Reranker: 498 ms, Tổng cộng: 510 ms).



Hình 3: Giao diện Bàn thử nghiệm Truy xuất (Retrieval Playground): Cho phép kiểm tra trực tiếp kho chỉ mục 22.766 chunks, xem điểm tương quan của các đoạn văn bản ứng viên và phân tích chi tiết độ trễ thực thi.

3 Dữ liệu và phương pháp đánh giá

3.1 Dữ liệu

3.1.1 Nguồn dữ liệu

Bộ dữ liệu ban đầu của nghiên cứu là NewsQA, được tải từ kho [lucadiliello/newsqa](https://huggingface.co/datasets/lucadiliello/newsqa) trên Hugging Face. NewsQA gồm các bài báo CNN, câu hỏi do người đọc đặt, đáp án dạng đoạn văn bản ngắn (answer span) và vị trí ký tự của đoạn đáp án trong bài báo.

Dữ liệu được tổ chức theo câu hỏi, không gom sẵn theo bài báo. Mỗi dòng chứa một câu hỏi và toàn bộ bài báo tương ứng. Vì vậy, một bài có nhiều câu hỏi sẽ được lặp ở nhiều dòng. Nguồn không có `article_id`; số bài được tính bằng số context khác nhau.

Ví dụ rút gọn một dòng dữ liệu gốc:

```
{
  "context": "... full CNN article ...",
  "question": "When was Pandher sentenced to death?",
  "answers": ["February."],
  "key": "724f6eb9a2814e4fb2d7d8e4de846073",
  "labels": [{"start": [261], "end": [269]}]
}
```

Ý nghĩa các trường:

- `context`: toàn bộ nội dung bài báo CNN.
- `question`: câu hỏi được đặt dựa trên bài báo đó.
- `answers`: một hoặc nhiều đáp án ngắn lấy từ bài báo.

- **key**: mã định danh của câu hỏi.
- **labels**: vị trí ký tự đầu và cuối của đáp án trong context. Ví dụ, `start = 261` và `end = 269` nghĩa là đáp án gồm cả ký tự ở vị trí 269. Pipeline đổi thành đoạn `[261, 270)` và kiểm tra đoạn này khớp với đáp án.

Revision nguồn được khóa tại `728e52920b8e4ffcfad93fa47556f26a1d82546`. Thống kê theo định dạng gốc như sau:

Bảng 1: Quy mô các split NewsQA nguồn.

Split	Số câu hỏi	Số context khác nhau	Câu hỏi/bài
Train	74.160	10.895	6,8
Validation	4.212	638	6,6

Từ 638 context của split validation, nhóm dùng seed 42 để chọn ngẫu nhiên 200 context và lấy toàn bộ câu hỏi tương ứng làm tập đánh giá. Split train có 10.895 context khác nhau; 31 context trùng nội dung với tập đánh giá bị loại để tránh rò rỉ dữ liệu. 10.864 context còn lại được dùng làm distractor. Corpus cuối gồm 11.064 bài báo: 200 bài đánh giá và 10.864 distractor. Các distractor không có câu hỏi đánh giá, nhưng buộc hệ thống phải tìm bằng chứng trong một kho dữ liệu lớn hơn.

3.1.2 Hiệu chỉnh câu hỏi đánh giá

Câu hỏi NewsQA được đặt khi người đọc đang xem bài báo, nên nhiều câu thiếu ngữ cảnh khi đứng riêng. Nhóm giữ dữ liệu gốc để truy vết và tạo phiên bản `resolved` theo quy trình sau:

1. Codex đọc bài báo, gắn nhãn vấn đề và đề xuất sửa tối thiểu.
2. Người đánh giá duyệt từng câu; phần thêm vào chỉ dùng để xác định chủ thể hoặc sự kiện, không chứa đáp án.
3. Đáp án và evidence sai được sửa; câu không thể trả lời được loại.
4. Các câu cùng bài, cùng ý nghĩa và cùng đáp án được gom cụm để loại trùng.
5. Evidence span được ánh xạ sang `relevant_chunk_ids` sau khi chunk.

Trong 1.340 câu nguồn, 4 câu không có đáp án đáng tin cậy bị loại. Sau review còn 1.336 câu; loại tiếp 184 câu trùng nghĩa, thu được 1.152 câu `resolved` thuộc 200 bài báo. Việc loại trùng diễn ra sau khi làm rõ câu hỏi để so sánh đúng ý nghĩa đầy đủ của chúng.

Bảng 2: Các mốc tạo tập câu hỏi đánh giá.

Mốc dữ liệu	Số câu	Thay đổi
Câu hỏi lấy từ 200 bài NewsQA	1.340	—
Sau human review	1.336	Loại 4 câu invalid
Sau semantic deduplication	1.152	Loại 184 câu lặp

Hai ví dụ về câu hỏi cần hiệu chỉnh:

1. **Ngữ cảnh/làm rõ câu hỏi**: “When was her surgery?” được sửa thành “When was Natalie Cole’s kidney transplant surgery?”. Đáp án “Tuesday” không được đưa vào câu hỏi mới.

Bảng 3: Các vấn đề được ghi nhận khi review.

Issue code	Số lần	Ý nghĩa
missing_subject	688	Thiếu chủ thể cần xác định
underspecified_event	139	Chưa xác định rõ sự kiện
generic_reference	98	Dùng tham chiếu chung như “he”, “it”
wrong_evidence	87	Evidence không hỗ trợ đáp án
malformed_question	71	Câu hỏi sai hoặc thiếu cấu trúc
truncated_answer	59	Đáp án bị cắt thiếu
wrong_answer	35	Đáp án nguồn không đúng
yes_no_answer_mismatch	4	Câu hỏi Yes/No nhưng gold không phải Yes/No

Một câu hỏi có thể mang nhiều issue code.

- Đáp án:** câu hỏi về quân Canada có gold nguồn là “35,000”, nhưng đây là tổng quân của các đồng minh NATO. Bài báo ghi Canada có hơn 2.800 quân, nên nhóm sửa đáp án và evidence span, đồng thời giữ giá trị nguồn để truy vết.

3.2 Chia tập

Toàn bộ partition được tạo theo bài báo. Danh sách article ID và question ID được cố định bằng seed và SHA-256.

Bảng 4: Các partition của tập resolved deduplicated.

Partition	Bài	Câu	Vai trò
Development	50	281	Screening và chọn cấu hình
Held-out generation	50	284	Đánh giá cấu hình generation đã khóa
Held-out reserve	100	587	Dữ liệu dự trữ, không dùng để tuning
Phase 1 final-test retrieval	150	871	Toàn bộ held-out pool dùng kiểm tra retrieval

Trong 200 bài đánh giá, 50 bài với 281 câu được dùng làm development. 150 bài còn lại tạo thành held-out pool gồm 871 câu. Từ 150 bài này, nhóm dùng seed 46 để chọn 50 bài với 284 câu cho held-out generation; 100 bài với 587 câu còn lại được giữ làm reserve. Phase 1 dùng toàn bộ held-out pool 150 bài, còn Phase 2 chỉ dùng phần held-out generation 50 bài. Development và held-out pool không trùng bài báo.

3.3 Nguyên tắc thực nghiệm

3.3.1 Phase 1: đánh giá retrieval

- Đánh giá khả năng đưa gold evidence lên đầu danh sách; không gọi generator hoặc LLM-as-a-Judge.
- Các vòng chọn retriever, reranker và hybrid dùng cùng 281 câu development. Mỗi vòng chỉ thay đổi thành phần đang xét.
- Sau khi khóa cấu hình, final-test được chạy một lần trên 871 câu của 150 bài chưa dùng để tuning. Kết quả này không được dùng để chọn lại cấu hình.

3.3.2 Phase 2: đánh giá generation end-to-end

- Dùng cấu hình retrieval đã khóa từ Phase 1.
- Chạy retrieval và reranking một lần trên development, sau đó dùng lại cùng ranked traces cho mọi cấu hình generation.
- Khi thử context depth 1, 3 hoặc 5, pipeline chỉ lấy số context tương ứng từ đầu cùng một danh sách đã rerank.

Để kiểm soát chi phí API, Phase 2 được chia thành các chế độ sau:

Bảng 5: Các chế độ chạy trong Phase 2.

Chế độ	Số câu	Mục đích
Screening	80	So sánh nhanh prompt/context configuration
Judge calibration	20	Tập con cố định của screening để chấm RAGAS
Full development	281	Xác nhận finalist và áp dụng guardrail
Held-out generation	284	Đánh giá cấu hình đã khóa trên 50 bài chưa thấy

- Screening 80 câu và judge calibration 20 câu được chọn một lần với seed 42 và giữ nguyên ID trong mọi thí nghiệm.
- Screening là bước tiết kiệm chi phí: loại cấu hình kém hơn trên tập nhỏ, chỉ giữ cấu hình có kết quả tương đương hoặc tốt hơn để làm finalist.
- Các finalist được chạy và chấm trên đủ 281 câu development. Guardrail được áp dụng ở bước này để chọn winner.
- Held-out chỉ được mở sau khi khóa winner và không dùng để tuning tiếp.
- Mỗi run lưu cấu hình, model, prompt hash, question IDs, source trace hash, coverage và retry log để có thể dùng và tiếp tục.

3.4 Thước đo và kiểm định

3.4.1 Thước đo retrieval

Với câu hỏi q , gọi r_q là thứ hạng đầu tiên có gold chunk và G_q là tập gold chunks. Các thước đo được tính tại cutoff k :

$$\text{Hit}@k(q) = \mathbf{1}[G_q \cap R_q^{(k)} \neq \emptyset], \quad (1)$$

$$\text{Recall}@k(q) = \frac{|G_q \cap R_q^{(k)}|}{|G_q|}, \quad (2)$$

$$\text{MRR}@k(q) = \begin{cases} 1/r_q, & r_q \leq k, \\ 0, & r_q > k, \end{cases} \quad (3)$$

Trong đó, $R_q^{(k)}$ là k kết quả đầu:

- **Hit@k**: bằng 1 nếu top- k chứa ít nhất một gold chunk; ngược lại bằng 0.
- **Recall@k**: tỷ lệ gold chunks xuất hiện trong top- k .
- **MRR@k**: dựa trên vị trí của gold chunk đầu tiên; gold xuất hiện càng sớm thì điểm càng cao.
- **nDCG@k**: đánh giá toàn bộ thứ tự top- k , ưu tiên gold chunks ở vị trí cao và chuẩn hóa theo thứ tự lý tưởng.
- **Latency**: thời gian truy xuất và rerank cho một câu hỏi.
- **Quy tắc chọn**: ưu tiên MRR@5; dùng nDCG@5, Hit@5 và latency để phân xử và mô tả trade-off.

3.4.2 Thước đo generation và citation

Bảng 6: Vai trò của các thước đo Phase 2.

Metric	Ý nghĩa
So sánh đáp án	
Exact Match	Đáp án chuẩn hóa trùng hoàn toàn một accepted answer.
Token F1	Mức chồng lấp token giữa đáp án sinh và accepted answer tốt nhất.
RAGAS	
Answer Correctness	RAGAS đánh giá độ đúng ngữ nghĩa so với gold answer.
Answer Relevancy	Mức độ câu trả lời trực tiếp giải quyết câu hỏi.
Faithfulness	Tỷ lệ các phát biểu trong đáp án được context hỗ trợ.
Context Precision	Mức độ các context được đưa vào thực sự liên quan.
Context Recall	Mức độ context bao phủ evidence cần để trả lời.
Citation	
Citation Validity	Tỷ lệ citation trỏ tới một context index hợp lệ.
Citation F1	Trung bình điều hòa giữa precision và recall của citation so với gold evidence.

Exact Match, Token F1 và citation metrics được tính xác định từ artifact. Answer Correctness, Answer Relevancy, Faithfulness, Context Precision và Context Recall được chấm bằng RAGAS với judge tách biệt khỏi generator. Báo cáo phải ghi model, provider, reasoning setting và score coverage của judge. Latency được báo cáo theo P50/P95; token usage và chi phí chỉ so sánh khi các run dùng cùng phạm vi câu hỏi và cùng cách tính giá.

3.4.3 Khoảng tin cậy và điều kiện chọn cấu hình

Khi so sánh hai cấu hình A và B trên cùng câu hỏi, nhóm tính sai khác theo cặp:

$$d_i = m(B, q_i) - m(A, q_i). \quad (4)$$

- **Paired bootstrap**: lấy lại các cặp sai khác d_i , thay vì lấy điểm của hai cấu hình độc lập.
- **Phase 1**: tạo 1.000 mẫu bootstrap; mỗi mẫu lấy lại 281 câu hỏi có hoàn lại.
- **Phase 2**: tạo 2.000 mẫu bootstrap; mỗi mẫu lấy lại 50 bài báo có hoàn lại và giữ toàn bộ câu hỏi của từng bài. Do đó, đây không phải 2.000 tập gồm 50 câu hỏi.

- **CI95:** lấy percentile 2,5–97,5% của 1.000 hoặc 2.000 giá trị trung bình mô phỏng.
- **Diễn giải:** CI95 không chứa 0 cho thấy khác biệt ở mức ý nghĩa 0,05; CI95 chứa 0 nghĩa là chưa đủ bằng chứng về khác biệt, không phải hai cấu hình tương đương.
- **Guardrail:** kiểm tra delta trung bình so với baseline có nằm trong mức suy giảm cho phép hay không; đây là tiêu chí khác với CI95.

Bảng 7: Guardrail dùng khi chọn cấu hình Phase 2 trên full development.

Điều kiện	Ngưỡng
Δ Faithfulness	$\geq -0,02$
Δ Citation F1	$\geq -0,01$
Δ Citation Validity	$\geq -0,01$
Generation và judge coverage	$\geq 95\%$

Trong các ứng viên qua guardrail, Answer Correctness là metric chất lượng chính; token cost, generation P95 và độ đơn giản của cấu hình lần lượt được dùng khi khác biệt Answer Correctness nhỏ. Quy tắc này chỉ áp dụng trên full development. Held-out được báo cáo nguyên trạng và không mở thêm vòng lựa chọn.

4 Giai đoạn 1: Truy xuất

4.1 Thiết kế thực nghiệm

- **Mục tiêu:** chọn cấu hình đưa chunk chứa bằng chứng lên đầu danh sách trước khi đánh giá generation.
- **Phạm vi:** chỉ đánh giá retrieval offline; không gọi generator, không chấm RAGAS và không phát sinh chi phí API sinh văn bản.
- **Gold label:** đối chiếu kết quả với relevant_chunk_ids được ánh xạ từ evidence span. Một chunk chỉ đúng khi ID của nó thuộc tập gold.

Thiết lập cố định

- Development: 281 câu resolved thuộc 50 bài; corpus gồm 11.064 bài.
- Chunking: recursive, kích thước 512 token và overlap 64 token.
- Resolved là biến thể chính vì câu hỏi có thể hiểu độc lập. Original chỉ dùng để phân tích ảnh hưởng của câu hỏi thiếu chủ thể.

Quy trình chọn cấu hình

1. Sàng lọc riêng dense và sparse retriever, không rerank.
2. So sánh dense tốt nhất, sparse tốt nhất và hybrid RRF với ba chế độ reranker.
3. Khóa pipeline rồi chạy đúng một lần trên 871 câu thuộc 150 bài chưa thấy.

Tiêu chí đánh giá

- Ưu tiên MRR@5 vì generator có lợi nhất khi bằng chứng đầu tiên xuất hiện sớm.
- Khi MRR gần nhau, lần lượt xét nDCG@5, Hit@5 và latency.
- Dùng Recall@5 để kiểm tra độ phủ khi một câu có nhiều gold chunks.

- Mọi run phải đạt coverage 100%; question IDs, seed và cách chấm được giữ cố định trong cùng một vòng.

4.2 Sàng lọc retriever

- **Dense:** all-MiniLM-L6-v2, bge-small-en-v1.5, bge-large-en-v1.5 và e5-base-v2.
- **Sparse:** BM25 Okapi, BM25+, BM25 có stemming/stopword normalization và learned sparse BGE-M3.
- **Điều kiện chung:** mỗi phương pháp trả tối đa 10 candidates; chưa dùng cross-encoder.

Bảng 8: Kết quả sàng lọc retriever trên 281 câu resolved.

Retriever	MRR@5	nDCG@5	Hit@5	P50 (ms)
BGE-M3 learned sparse	0,8059	0,8317	0,9181	76,7
BM25 Okapi + stemming	0,7815	0,8123	0,9146	56,1
BM25+	0,6881	0,7206	0,8221	101,1
BM25 Okapi	0,6732	0,7087	0,8185	111,8
Dense: e5-base-v2	0,6316	0,6684	0,7865	15,5
Dense: bge-small-en-v1.5	0,6285	0,6589	0,7651	16,0
Dense: bge-large-en-v1.5	0,6252	0,6536	0,7544	27,4
Dense: all-MiniLM-L6-v2	0,4851	0,5165	0,6299	10,6

Kết quả và phạm vi kết luận

- Trong các mô hình và dữ liệu được khảo sát, nhánh sparse đạt kết quả retrieval cao hơn nhánh dense.
- BGE-M3 được chọn làm sparse representative vì đứng đầu theo quy tắc MRR@5, sau đó là nDCG@5. Tuy nhiên, so với BM25-stemmed trên tập resolved, CI95 của hiệu nDCG@5 là $[-0,0125; 0,0508]$; chưa đủ bằng chứng kết luận một sparse model tốt hơn model còn lại.
- e5-base-v2 được chọn làm dense representative. Chênh lệch giữa các dense models nhỏ và chưa đủ để thiết lập một thứ hạng tổng quát.
- BGE-M3 chậm hơn e5-base-v2; P95 vẫn dưới 0,1 giây trong thử nghiệm.

4.3 Sàng lọc chiến lược retrieval và reranker

- **Retriever:** e5-base-v2 dense, BGE-M3 sparse và hybrid RRF giữa hai nhánh.
- **Reranker:** không rerank, cross-encoder MiniLM-L6 và BGE-reranker-large.
- **Thiết lập:** retriever lấy 20 candidates; reranker sắp lại và trả top 5 để tính metric.

Bảng 9: MRR@5 và nDCG@5 theo retriever và reranker trên tập development.

Retriever	MRR@5			nDCG@5		
	Không	MiniLM	BGE-large	Không	MiniLM	BGE-large
BGE-M3 sparse	0,8059	0,8387	0,8797	0,8317	0,8642	0,8976
e5-base dense	0,6316	0,7783	0,7997	0,6684	0,7994	0,8172
Hybrid RRF	0,7192	0,7938	0,8203	0,7474	0,8164	0,8405

Bảng 10: Độ trễ P50 của ma trận Phase 1 trên cùng môi trường chạy.

Retriever	Không rerank	MiniLM	BGE-large
BGE-M3 sparse	66,1 ms	163,9 ms	510,1 ms
e5-base dense	17,7 ms	127,3 ms	540,5 ms
Hybrid RRF	90,4 ms	193,3 ms	609,8 ms

Kết quả

- Trên BGE-M3, MiniLM tăng $MRR@5$ từ 0,8059 lên 0,8387; BGE-large đạt 0,8797 nhưng P50 tăng từ 163,9 ms lên 510,1 ms.
- BGE-M3 + BGE-large đứng đầu ma trận: $MRR@5$ 0,8797; $nDCG@5$ 0,8976; $Hit@5$ 0,9573; $Recall@5$ 0,9555. Vì vậy, cấu hình này được chọn.
- Hybrid RRF không vượt BGE-M3 sparse ở cả ba chế độ reranker; fusion không đem lại lợi ích quan sát được trong thiết lập này.

4.4 Final-test và cấu hình retrieval khóa

- **Cấu hình khóa trước final-test:** recursive chunking 512/64; BGE-M3 learned sparse lấy top 20; BGE-large cross-encoder trả top 5.
- **Dữ liệu:** 871 câu resolved thuộc 150 bài chưa dùng để chọn cấu hình.
- **Phạm vi:** chỉ chạy retrieval; không gọi generator. Cả 871/871 câu đều có bản ghi thành công.

Bảng 11: Kết quả của pipeline retrieval đã khóa.

Metric	Development (281 câu)	Final-test (871 câu)
$MRR@5$	0,8797	0,8112
$nDCG@5$	0,8976	0,8313
$Hit@5$	0,9573	0,8978
$Recall@5$	0,9555	0,8955
P50 latency	512,7 ms	550,0 ms
P95 latency	531,0 ms	567,0 ms
Coverage	100%	100%

Kết quả

- 782/871 câu có ít nhất một gold chunk trong top 5; 89 câu không đạt $Hit@5$.
- So với BGE-M3 trước rerank, BGE-large tăng $MRR@5$ từ 0,7269 lên 0,8112, $nDCG@5$ từ 0,7555 lên 0,8313 và $Hit@5$ từ 0,8519 lên 0,8978.
- Mức tăng $nDCG@5$ là 0,0758, với paired CI95 [0,0504; 0,1017]. Khoảng này không chứa 0, nên hiệu quả rerank vẫn xuất hiện trên các bài chưa thấy.

Diễn giải và quyết định

- Bốn metric chính đều thấp hơn development; điểm development đã lạc quan hơn so với dữ liệu chưa thấy.
- Coverage vẫn đạt 100%; pipeline tìm được gold evidence trong top 5 cho gần 90% câu hỏi.

- Khóa BGE-M3 top 20 + BGE-large top 5 làm retrieval đầu vào cho Phase 2. Final-test không được dùng để chọn lại model.

5 Giai đoạn 2: Sinh câu trả lời

5.1 Thiết kế thực nghiệm

- **Mục tiêu:** đánh giá pipeline end-to-end và cải thiện câu trả lời mà không làm giảm grounding hoặc chất lượng citation.
- **Retrieval cố định:** recursive 512/64, BGE-M3 top 20, BGE-reranker-large top 5.
- **Dữ liệu:** development gồm 281 câu/50 bài; held-out gồm 284 câu/50 bài chưa dùng để tuning.
- **Generator:** Gemini 3.1 Flash-Lite, reasoning minimal, temperature 0 và tối đa 512 output tokens.
- **Judge:** GLM-5.3-Flash qua Fireworks, reasoning low; chấm năm RAGAS metrics. Exact Match, Token F1 và citation metrics được tính trực tiếp.
- **Metric chính:** Answer Correctness. Guardrail gồm Faithfulness, Citation F1, Citation Validity và coverage.

5.2 Thiết lập và kết quả baseline end-to-end

Baseline dùng prompt P0 và 5 context trên toàn bộ development.

Bảng 12: Baseline P0-depth5 trên 281 câu development.

Nhóm	Metric	Điểm
Đáp án	Exact Match	0,0000
	Token F1	0,2648
	Answer Correctness	0,6308
	Answer Relevancy	0,7950
Grounding	Faithfulness	0,9761
	Context Precision	0,8980
	Context Recall	0,9644
Citation	Citation F1	0,8025
	Citation Validity	0,9893
Vận hành	Coverage	100%
	Latency P50 / P95	2,77 s / 53,63 s

Phân tích baseline

- Faithfulness và Citation Validity cao, nhưng Answer Correctness chỉ đạt 0,6308 và Exact Match bằng 0.
- Audit 30 câu có Answer Correctness dưới 0,5: 24 câu vẫn có gold evidence trong top 5. Lỗi chính là trả lời dài, sai loại thông tin hoặc chọn nhầm chi tiết trong context.
- Sáu câu còn lại không có gold trong top 5; prompt không thể khôi phục bằng chứng mà retrieval không cung cấp.

- Vì vậy, bước tiếp theo tập trung vào prompt ngắn và đúng loại đáp án, đồng thời giữ các guardrail của RAG.

5.3 Sàng lọc prompt zero-shot

Bảng 13: Các zero-shot prompt được khảo sát.

ID	Mục tiêu	Chỉ thị khác biệt
P0	Đôi chứng	Trả lời dựa trên context và kèm citation.
P1	Siết grounding	Chỉ nêu claim được context hỗ trợ trực tiếp.
P2	Tăng độ chính xác	Trả đúng loại thông tin, ngắn gọn và kèm citation.
P3	Chọn evidence	Chọn đoạn hỗ trợ trước khi tạo câu trả lời ngắn.

Bảng 14: Sàng lọc prompt trên 80 câu; RAGAS dùng cùng 20 câu calibration.

Prompt	Token F1	AC	Faith.	AR	Cit. F1	Cit. Valid.
P0	0,2417	0,7118	1,0000	0,8131	0,7808	0,9750
P1	0,2570	0,6885	0,9750	0,7426	0,7863	0,9625
P2	0,3999	0,8363	1,0000	0,7388	0,8133	0,9750
P3	0,2790	0,7190	0,9750	0,8153	0,8146	0,9625

- Screening là bước tiết kiệm chi phí, không phải final comparison.
- P1 thấp hơn P0 về Answer Correctness và Faithfulness nên bị loại.
- P2 và P3 có kết quả cạnh tranh; P2 nổi bật về Answer Correctness và Token F1 nên được đưa sang bước kiểm tra depth.

5.4 Sàng lọc số lượng context

Giữ nguyên thứ tự rerank và cắt danh sách context còn 1, 3 hoặc 5 đoạn.

Bảng 15: Ảnh hưởng của context depth trên tập screening.

Prompt	Depth	Token F1	AC	Faith.	AR	Cit. F1	Cit. Valid.
P0	1	0,2543	0,7063	0,9750	0,7365	0,7250	0,8167
P0	3	0,2527	0,7046	0,9875	0,7667	0,7792	0,9500
P0	5	0,2417	0,7118	1,0000	0,8131	0,7808	0,9750
P2	1	0,5809	0,8671	0,9500	0,4825	0,5500	0,6125
P2	3	0,5311	0,8795	0,9250	0,6806	0,8125	0,9500
P2	5	0,3999	0,8363	1,0000	0,7388	0,8133	0,9750

- Depth 1 tăng Answer Correctness nhưng giảm mạnh Citation F1 và Citation Validity; 38/281 câu không có gold ở rank 1.
- P2 depth 3 và P2 depth 5 được chọn để chạy đủ 281 câu development.

5.5 Kết quả zero-shot trên development và held-out

Bảng 16: Kết quả finalist trên toàn bộ development.

Cấu hình	Token F1	AC	Faith.	AR	Cit. F1	Cit. Valid.
P0-depth5	0,2648	0,6308	0,9761	0,7950	0,8025	0,9893
P2-depth3	0,5549	0,7711	0,9561	0,5694	0,8381	0,9751
P2-depth5	0,4191	0,7350	0,9801	0,7092	0,8391	0,9858

- P2 depth 3 tăng Answer Correctness nhiều nhất, nhưng giảm Faithfulness 0,0200 và Citation Validity 0,0142; cấu hình không qua guardrail.
- So với P0 depth 5: Answer Correctness tăng 0,1043. CI95: [0, 0844; 0, 1240]. Citation F1 tăng 0,0366; Faithfulness không giảm.
- P2 depth 5 qua toàn bộ guardrail và được khóa trước khi mở held-out.

Bảng 17: P2-depth5 trên development và held-out.

Metric	Development (281)	Held-out (284)
Token F1	0,4191	0,4313
Answer Correctness	0,7350	0,7157
Faithfulness	0,9801	0,9249
Answer Relevancy	0,7092	0,6485
Citation F1	0,8391	0,7289
Citation Validity	0,9858	0,9437
Coverage	100%	100%

- Held-out có 35/284 câu không có gold trong top 5, so với 12/281 câu ở development. Hit@5 giảm từ 0,9573 xuống 0,8768.
- Khi gold có trong top 5, Answer Correctness held-out đạt 0,7689, so với 0,7597 trên development. Phần suy giảm tổng thể chủ yếu đi cùng retrieval miss.
- Held-out chỉ dùng để đánh giá khả năng tổng quát hóa, không dùng để sửa prompt hoặc chọn lại cấu hình.

5.6 Thử nghiệm prompt one-shot

Giả thuyết: một ví dụ hoàn toàn tổng hợp giúp generator học định dạng đáp án ngắn và citation đúng vị trí, từ đó tăng độ đúng của câu trả lời. P2-1S giữ chỉ thị P2 và thêm ví dụ gồm context, câu hỏi và đáp án có citation. Chỉ thay prompt; retrieval trace, depth 5 và Gemini 3.1 Flash-Lite được giữ nguyên. Ví dụ không thuộc development hoặc held-out.

Bảng 18: So sánh P2 zero-shot và one-shot, cùng depth 5, trên development.

Metric	P2 zero-shot (281)	P2 one-shot (281)
Exact Match	0,0000	0,3559
Token F1	0,4191	0,6267
Answer Correctness	0,7350	0,8015
Faithfulness	0,9801	0,9603
Answer Relevancy	0,7092	0,5251
Citation F1	0,8391	0,8441
Citation Validity	0,9858	0,9786
Coverage	100%	100%

Bảng 19: P2 one-shot trên development và held-out; chỉ kiểm tra khả năng tổng quát hóa của cùng cấu hình, không chọn lại prompt.

Metric	Development (281)	Held-out (284)
Exact Match	0,3559	0,3239
Token F1	0,6267	0,6032
Answer Correctness	0,8015	0,7557
Faithfulness	0,9603	0,9082
Answer Relevancy	0,5251	0,4688
Citation F1	0,8441	0,7315
Citation Validity	0,9786	0,9437
Coverage	100%	100%

Bảng 20: Sai khác paired của P2-1S so với zero-shot P2-depth5 trên 281 câu development; CI95 bootstrap theo 50 bài, 2.000 lần lấy mẫu.

Metric	P2-D5	P2-1S-D5	Δ và CI95
Answer Correctness	0,7350	0,8015	+0,0664 [0,0444; 0,0883]
Token F1	0,4191	0,6267	+0,2076 [0,1728; 0,2427]
Faithfulness	0,9801	0,9603	-0,0199 [-0,0388; -0,0028]
Answer Relevancy	0,7092	0,5251	-0,1841 [-0,2233; -0,1458]
Citation F1	0,8391	0,8441	+0,0050 [-0,0104; 0,0229]
Citation Validity	0,9858	0,9786	-0,0071 [-0,0182; 0,0000]

- Trên development, Answer Correctness và Token F1 tăng; CI95 của hai sai khác đều không chứa 0. Citation F1 chưa có bằng chứng thay đổi.
- Answer Relevancy giảm rõ rệt; Faithfulness cũng giảm, dù mức giảm trung bình 0,0199 vẫn nằm sát ngưỡng guardrail 0,02. Do đó, one-shot không phải cải thiện đồng đều trên mọi tiêu chí của RAG.
- Held-out chỉ đối chiếu P2-1S với chính P2-1S trên development. Các metric chất lượng thấp hơn trên bài chưa thấy; đây không phải so sánh zero-shot với one-shot trên held-out, và không được dùng để chọn lại prompt.

Phân tích Answer Relevancy giảm

- Trên cùng 281 câu, câu trả lời one-shot có trung vị 7 từ, so với 11 từ của zero-shot; 105 so với 23 câu dài không quá ba từ. Số câu có Answer Relevancy dưới 0,5 tăng từ 54 lên

133.

- Trong 133 câu one-shot dưới 0,5, có 109 câu vẫn đạt Answer Correctness từ 0,8 trở lên. Ví dụ, với câu hỏi “Where was the 2009 Swamp Soccer World Championship held?”, zero-shot trả lời “The 2009 Swamp Soccer World Championship was held in Scotland [1]” (Relevancy 1,00), còn one-shot trả lời “Scotland [1]” (Relevancy 0,037; Correctness 1,00).
- RAGAS Answer Relevancy sinh câu hỏi ngược từ đáp án rồi so với câu hỏi gốc. Đáp án chỉ gồm một thực thể hoặc địa điểm thường không giữ chủ thể và sự kiện cần để tái tạo câu hỏi gốc. Điều này phù hợp với các ví dụ đã kiểm tra, nhưng không chứng minh độ ngắn giải thích mọi trường hợp giảm điểm; Answer Relevancy vẫn là một trade-off cần báo cáo riêng.

5.7 So sánh các mô hình sinh câu trả lời

Mục tiêu: mô tả điều gì thay đổi khi thay generator, gồm độ chính xác, grounding, citation, token usage và latency. Thí nghiệm giữ cố định retrieval trace, P2-1S, depth 5 và cùng 281 câu development; chỉ thay generator. Gemini 3.1 Flash-Lite được dùng làm mốc so sánh. Đây là ablation để quan sát trade-off, không phải vòng chọn winner; không chạy held-out riêng cho từng model và không thay đổi cấu hình đã khóa.

Bảng 21: Generator ablation với P2-1S-depth5 trên development.

Generator	Token F1	AC	Faith.	AR	Cit. F1	Cit. Valid.
Gemini 3.1 Flash-Lite	0,6267	0,8015	0,9603	0,5251	0,8441	0,9786
Gemini 3.5 Flash-Lite	0,6803	0,8164	0,9557	0,4351	0,8351	0,9680
Gemini 3.6 Flash	0,6934	0,8011	0,9472	0,3837	0,8248	0,9644

Bảng 22: Sai khác so với Gemini 3.1 Flash-Lite và tài nguyên generation trên 281 câu. CI95 là paired article-cluster bootstrap (2.000 mẫu).

Generator	Δ AC	Δ Cit. F1	Δ Cit. Valid.	CI95 Δ AC	LLM P95	Token in/out
3.1 Lite	0	0	0	Đối chứng	1,02 s	666.604 / 3.847
3.5 Lite	+0,0149	-0,0090	-0,0107	[-0,0052; 0,0359]	0,89 s	666.604 / 3.112
3.6 Flash	-0,0003	-0,0193	-0,0142	[-0,0204; 0,0195]	3,50 s	666.604 / 3.249

- Gemini 3.5 Flash-Lite có Answer Correctness trung bình cao nhất, nhưng CI95 của sai khác so với 3.1 chứa 0; chưa đủ bằng chứng kết luận model này chính xác hơn trên quần thể mục tiêu. Model dùng ít output token và có LLM P95 thấp nhất trong các run đã ghi.
- Gemini 3.6 Flash có Token F1 cao nhất nhưng không tăng Answer Correctness so với 3.1; Citation F1 và Citation Validity thấp hơn, còn LLM P95 cao nhất.
- Gemini 3.1 Flash-Lite giữ Faithfulness, Answer Relevancy và hai citation metrics cao nhất trong ba model được khảo sát.
- Token là tổng usage của 281 lần generation, không gồm judge. P95 là độ trễ gọi LLM ghi trong từng run, chỉ để mô tả vận hành vì các run có thể chạy trên môi trường và thời điểm khác nhau. Không quy đổi ra tiền khi chưa có định giá API tại thời điểm thí nghiệm.

- Kết quả mô tả trade-off trên development; nhóm không dùng ablation này để chọn lại generator hoặc thay đổi pipeline đã khóa.

5.8 Khảo sát mở rộng: Phân đoạn văn bản và Chính sách từ chối

Bên cạnh luồng thực nghiệm chính, nhóm tác giả tiến hành hai khảo sát mở rộng mang tính chất thăm dò (*ablation studies*) trên tập phát triển nhằm kiểm chứng tính tối ưu của cấu hình đã chọn:

- **Khảo sát chiến lược phân đoạn văn bản (Giai đoạn 2C):** Thử nghiệm bốn phương pháp phân đoạn gồm C0 (Recursive 512/64 chuẩn), C1 (Tách theo câu), C2 (Tách theo đoạn) và C3 (Phân cấp Parent–Child: đoạn con 128 token để truy xuất, trả về đoạn cha 512 token để sinh). Mặc dù cấu hình C3-depth3 đạt điểm Answer Correctness bề mặt cao nhất (0,7730, tăng +0,0380 so với C0), nó làm suy giảm nghiêm trọng độ khớp bằng chứng của trích dẫn (Citation F1 tụt $-0,0284$, vi phạm rào chắn an toàn $-0,01$) do trích dẫn trở sang đoạn cha lớn thay vì đoạn bằng chứng cụ thể. Do đó, cấu hình chuẩn C0 được bảo toàn.
- **Khảo sát chính sách từ chối trả lời (Giai đoạn 3):** Thử nghiệm khả năng nhận biết thiếu thông tin trên tập kiểm thử 200 tình huống (140 dev, 60 final) giữa ba chính sách: B0 (dùng chính prompt P2 từ chối tự nhiên), B1 (ràng buộc JSON schema với trường *answerability*) và B2 (cồng chặn ngưỡng điểm tái xếp hạng). Mặc dù B1 giúp hạ tỷ lệ trả lời sai khi thiếu bằng chứng xuống 1,27%, nó lại làm suy thoái chất lượng câu trả lời ở các câu hỏi thông thường (Token F1 tụt $-0,1070$, vi phạm rào chắn an toàn). Nhóm quyết định giữ nguyên cấu hình cơ sở B0.

Chi tiết bảng số liệu và thiết lập của hai khảo sát mở rộng này được cung cấp tại Phụ lục E.

6 Tổng kết kết quả và Thảo luận

6.1 Tổng hợp kết quả qua các giai đoạn thực nghiệm

Trải qua một chuỗi các giai đoạn thực nghiệm có kiểm soát chặt chẽ từ Giai đoạn 1 đến Giai đoạn 3 và bước nghiệm thu độc lập trên tập held-out, hệ thống **NewsLens** đã xác lập được cấu hình tối ưu toàn diện. Bảng 23 tổng hợp các kết quả thực nghiệm then chốt xuyên suốt toàn bộ dự án.

Bảng 23: Tổng hợp kết quả thực nghiệm qua các giai đoạn của đồ án NewsLens.

Giai đoạn	Cấu hình so sánh	Chỉ số then chốt	Kết luận / Quyết định
Giai đoạn 1 (Truy xuất)	- Dense (BGE-M3 / MiniLM) - BM25 vs BGE-M3 Sparse - Thêm Cross-Encoder - Khảo sát Chunking	Δ nDCG@5 = +0,1634 (Sparse so với Dense) Δ nDCG@5 = +0,0659 (Thêm Reranker) Hit@5 = 0,9573 (Dev)	Khóa cấu hình truy xuất: BGE-M3 Sparse + BGE-Reranker-Large + Chunking 512/64. Sparse vượt trội nhờ câu hỏi neo vào thực thể tên riêng và thời gian.
Giai đoạn 2 (Sinh đáp án)	- Baseline P0-depth5 - P1 (Siết grounding) - P2-depth3 (Chung kết) - P2-depth5 (Chung kết) - P3 (Phân biệt sự kiện)	Baseline AC: 0,6308 P2-depth3 AC: 0,8375 P2-depth5 AC: 0,8015 (Δ AC = +0,1043) Faithfulness: 0,9603	Khóa cấu hình sinh: P2-depth5. P2-depth3 tuy có AC cao hơn (+0,0360) nhưng bị loại do trượt 2 rào chắn an toàn (Faithfulness và Citation Validity). P2-depth5 là cấu hình hợp lệ duy nhất.
Giai đoạn 2C (Phân đoạn khám phá)	- C0: Recursive 512/64 - C1: Phân tách theo câu - C2: Phân tách theo đoạn - C3: Phân cấp Parent-Child	C3-depth3 AC: 0,7730 (+0,0380 so với C0) Δ Cit. F1 = -0,0284 Δ Hit@5 = -0,0107	Giữ nguyên cấu hình C0. C3-depth3 đạt điểm AC cao nhất nhưng bị loại do vi phạm 3 rào chắn an toàn (Cit. F1, Hit@5, Recall@5). Không cấu hình nào qua hết 6 guardrails.
Giai đoạn 3 (Từ chối trả lời)	- B0: Giữ nguyên P2 - B1: Ràng buộc JSON schema - B2: Cổng chặn ngưỡng Reranker	B0 False-Answer: 5,88% B1 False-Answer: 1,27% B1 Δ Token F1 = -0,1070 B2: Ngưỡng tối ưu = 0	Giữ nguyên cấu hình B0 (P2). B1 hạ được tỷ lệ trả lời sai nhưng phá hủy hình dạng đáp án. B2 là kết quả null (tất cổng là tốt nhất). Winner giữ nguyên B0.
Nghiệm thu Held-out	284 câu hỏi / 50 bài báo chưa từng tiếp xúc; kiểm định đúng 1 lần sau khi khóa pipeline.	Answer Correctness: 0,7157 Hit@5: 0,8768 Coverage: 100%	Xác lập khả năng tổng quát hóa. Khoảng cách AC so với Dev (0,7157 vs 0,8015) hoàn toàn tương ứng với độ sụt giảm của Hit@5 (0,8768 vs 0,9573).

6.2 Trả lời trực diện hai câu hỏi nghiên cứu cốt lõi

Đối chiếu với các câu hỏi nghiên cứu được đặt ra tại Mục 1, đồ án đưa ra các kết luận cụ thể cho hai tầng chức năng chính của hệ thống:

Q1: Phương pháp truy xuất tối ưu? Bộ truy xuất thừa **BGE-M3 Sparse** kết hợp mô hình tái xếp hạng **BGE-Reranker-Large** trên các đoạn văn bản kích thước **512 token (overlap 64 token)** là giải pháp vượt trội nhất. Trên kho ngữ liệu 11.064 bài báo có nhiều cao, BGE-M3 Sparse vượt hơn Dense Retriever +0,1634 nDCG@5 (khoảng tin cậy 95%

[+0,1231; +0,2080] hoàn toàn tách rời 0 và vượt xa cận dưới của biên độ nhập nhằng (7,0%). Bộ tái xếp hạng chéo tiếp tục đóng góp thêm +0,0659 nDCG@5, đưa tỷ lệ tìm thấy bằng chứng Hit@5 đạt 95,73% trên tập phát triển và 89,78% trên 871 câu hỏi kiểm định cuối kỳ.

Giải mã hiện tượng Sparse vượt Dense trong kỷ nguyên Transformer dưới góc độ dữ liệu (EDA): Phân tích khám phá dữ liệu trên kho ngữ liệu phục hồi v2.0.0 (22.766 đoạn văn bản từ 11.064 bài báo) đã làm sáng tỏ cơ chế nền tảng giúp phương pháp thừa chiến thắng:

- **Đặc trưng điểm neo từ hiếm (Rare-term anchors, IDF $\geq 6,0$):** Câu hỏi tin tức phụ thuộc chủ yếu vào các thực thể định danh rời rạc (tên riêng nhân vật, địa danh, mốc thời gian, tổ chức). Khi câu hỏi được chuẩn hóa ngữ cảnh (*resolved*), tỷ lệ câu hỏi sở hữu ít nhất một từ hiếm (xuất hiện trong ≤ 55 đoạn văn bản trên toàn kho, tương ứng IDF $\geq 6,0$) tăng từ 28,4% lên 59,5% (trung bình từ 0,34 lên 0,93 từ hiếm/câu).
- **Hiện tượng pha loãng thực thể ở Dense Bi-Encoder (Entity Dilution):** Các mô hình Dense Bi-Encoder nén ngữ nghĩa vào vector 768 chiều. Dù nắm bắt tốt chủ đề tổng quát (như tai nạn hay tranh tụng pháp lý), biểu diễn vector dày đặc dễ làm mờ ranh giới giữa các sự kiện cùng loại có sự tham gia của các thực thể khác nhau, kéo theo nhiều bài báo gây nhiễu (*distractors*). Ngược lại, Sparse Retriever tận dụng cơ chế khớp từ vựng chính xác (*exact lexical matching*) để cô lập không gian tìm kiếm một cách dứt khoát.
- **Cơ sở dữ liệu cho sự cần thiết của Reranker (Cross-Encoder):** Mặc dù các điểm neo từ hiếm giúp lọc giảm mạnh từ 22.766 đoạn xuống trung vị còn 25 đoạn văn bản cạnh tranh, 25 vẫn là khoảng cách quá xa so với vị trí Top-1 (chỉ 25,8% câu hỏi thu hẹp được về ≤ 10 đoạn, và 35,2% câu hỏi hoàn toàn không chứa từ hiếm). Tầng truy xuất thừa đưa hệ thống đến rất gần bằng chứng nhưng không thể tự mình dứt điểm. Mô hình tái xếp hạng chéo (*bge-reranker-large*) với cơ chế cross-attention toàn phần giữa câu hỏi và đoạn văn bản đóng vai trò quyết định để phân xử chính xác 25 ứng viên cạnh tranh này.
- **Biên độ nhập nhằng cố hữu của nhãn dữ liệu (7,0%–24,5%):** Do cùng một sự kiện thời sự có thể được CNN đưa tin qua nhiều bài báo, một câu hỏi có thể có đáp án đúng nằm ở bài báo khác ngoài bài báo được gán nhãn gốc (*unlabelled true answer*). Khảo sát và chạm dữ liệu xác lập hai cận đo lường ước lượng:
 - *Cận dưới trường hợp mạnh (7,0%):* Tỷ lệ câu hỏi mà đoạn văn bản ở bài báo khác vừa chứa chuỗi ký tự đáp án chuẩn (*ground-truth answer string*, dài ≥ 8 ký tự), vừa chứa ≥ 2 từ hiếm (IDF $\geq 6,0$) lấy từ chính câu hỏi $\rightarrow$ Đây là chỉ số đại diện khả tín (*plausible proxy*) cho thấy bài báo đó có khả năng rất cao cùng phản ánh đúng sự kiện thời sự.
 - *Cận trên tối đa (24,5%):* Tỷ lệ câu hỏi mà bài báo khác chứa chuỗi ký tự đáp án chuẩn thuần túy (*raw string match*, không xét từ hiếm) $\rightarrow$ Thu thập toàn bộ các trường hợp tiềm năng nhưng bị phóng đại do bao gồm cả trùng tên riêng hoặc cụm từ phổ biến một cách ngẫu nhiên.

Khoảng 7,0%–24,5% đóng vai trò là **ngưỡng nhiễu đo lường** (*measurement noise floor*). Mức vượt trội +0,1634 nDCG@5 của BGE-M3 Sparse (khoảng tin cậy 95% [+0,1231; +0,2080]) vượt xa ngưỡng nhiễu 7,0%, chứng minh ưu thế của mô hình thừa là thực chất và vững chắc về mặt thống kê.

Q2: Chiến lược ra lệnh và độ sâu ngữ cảnh tối ưu? Prompt P2 với 5 đoạn ngữ cảnh (`context_depth = 5`) là cấu hình chiến thắng. Bằng cách ràng buộc mô hình chỉ trả lời đúng loại thực thể được hỏi trong một câu ngắn duy nhất, P2 loại bỏ hoàn toàn hiện tượng lan man ngoài lề, tăng Answer Correctness +0,1043 so với baseline P0 (CI95 [+0,0844; +0,1240]) và vượt qua toàn bộ 4 rào chắn an toàn. Việc cắt giảm ngữ cảnh xuống depth 3 tuy làm tăng điểm số bề mặt nhưng dẫn đến suy thoái grounding và vi phạm rào chắn an toàn.

6.3 Bài học từ các khảo sát mở rộng (Ablation Studies)

Bên cạnh hai câu hỏi nghiên cứu trọng tâm, hai khảo sát mở rộng (tóm lược tại Mục 5.8 và chi tiết tại Phụ lục E) đem lại các bài học thiết kế giá trị:

- **Tác động của chiến lược phân đoạn văn bản (Giai đoạn 2C): Không có chiến lược phân đoạn mới nào đủ điều kiện để thay thế cấu hình chuẩn C0 (Recursive 512/64).** Mặc dù kỹ thuật phân cấp Parent–Child (C3–depth3) đạt điểm Answer Correctness bề mặt cao nhất toàn dự án (0,7730, tăng +0,0380 so với C0), nó làm suy giảm nghiêm trọng độ khớp bằng chứng của trích dẫn (Citation F1 tụt −0,0284, vượt quá rào chắn an toàn −0,01). Do đó, cấu hình phân đoạn chuẩn C0 được bảo toàn. Kết quả này hoàn toàn nhất quán với đặc tính cấu trúc tháp ngược (Inverted Pyramid) của văn bản báo chí: phân tích EDA cho thấy bằng chứng trả lời trong NewsQA tập trung chủ yếu ở phân vị thứ 18 (gần đầu bài viết) và trung bình mỗi bài báo chỉ gồm 2,06 đoạn văn bản kích thước 512 token, khiến dư địa cải thiện của các kỹ thuật phân đoạn phức tạp trở nên rất hạn chế.
- **Năng lực nhận diện ranh giới thông tin và chủ động từ chối trả lời (Giai đoạn 3): Hệ thống với prompt P2 đã sở hữu khả năng từ chối tự nhiên rất hiệu quả.** Trên tập kiểm định 60 tình huống phức tạp của Giai đoạn 3, cấu hình cơ sở B0 (sử dụng câu lệnh từ chối tự nhiên của prompt P2) đạt False-Answer Rate chỉ 5,88% và Abstention F1 đạt 0,9697. Các chính sách can thiệp bằng cách ép buộc cấu trúc JSON schema (B1) hay thiết lập ngưỡng điểm tái xếp hạng (B2) đều không vượt qua được sự đánh đổi: dù giúp hạ thấp tỷ lệ trả lời sai khi thiếu ngữ cảnh, chúng lại làm suy thoái nghiêm trọng chất lượng của các câu trả lời đúng (Token F1 tụt −0,1070, vi phạm rào chắn an toàn). Do đó, cấu hình cơ sở B0 tiếp tục được duy trì.

6.4 Bài học phương pháp luận: Hiện tượng “Luật thắng điểm số”

Phát hiện phương pháp luận sâu sắc nhất của đồ án nằm ở hiện tượng “**Luật thắng điểm số**” (The Rule Trumps Score Phenomenon) được lặp lại một cách nhất quán qua ba giai đoạn nghiên cứu độc lập (Bảng 24).

Bảng 24: Minh chứng hiện tượng “Luật thắng điểm số” qua ba giai đoạn thực nghiệm.

Giai đoạn	Cấu hình cao điểm nhất	Cấu hình được chọn	Lý do loại cấu hình cao điểm nhất
Phase 2B	P2-depth3 (AC: 0,8375)	P2-depth5 (AC: 0,8015)	Trượt 2 rào chắn an toàn: Faithfulness $-0,0200$ (ngưỡng $-0,02$) Citation Validity $-0,0142$ (ngưỡng $-0,01$).
Phase 2C	C3-depth3 (AC: 0,7730)	C0-depth5 (AC: 0,7350)	Trượt 3 rào chắn an toàn: Citation F1 $-0,0284$ (ngưỡng $-0,01$) Hit@5 $-0,0107$ và Recall@5 $-0,0125$.
Phase 3	B1 (JSON Schema) (False-Ans: 1,27%)	B0 (Prompt P2) (False-Ans: 5,88%)	Trượt rào chắn chất lượng: Token F1 tụt $-0,1070$ (ngưỡng $-0,02$), làm hỏng cấu trúc câu trả lời đúng.

Trong cả ba trường hợp, nếu chỉ lựa chọn cấu hình thuần túy dựa vào điểm số cao nhất của chỉ số chính (greedy score maximization), hệ thống sẽ ba lần liên tiếp đưa ra quyết định không tối ưu:

- Ở Phase 2B, chọn P2-depth3 tuy có điểm Answer Correctness cao hơn nhưng lại làm suy giảm độ trung thực (Faithfulness) và làm tăng trích dẫn ngoài dải hợp lệ.
- Ở Phase 2C, chọn C3-depth3 tuy tăng điểm số bề mặt nhưng làm giảm độ đặc hiệu của nguồn trích dẫn và độ bao phủ bằng chứng (Citation F1, Hit@5).
- Ở Phase 3, chọn B1 tuy giảm tỷ lệ câu trả lời sai trên tập âm tính nhưng lại làm suy giảm đáng kể chất lượng câu trả lời trên các câu hỏi thông thường (Token F1 tụt $-0,1070$).

Kết quả này khẳng định vai trò thiết yếu của việc **đăng ký trước hệ thống rào chắn an toàn (pre-registered guardrails)**. Hệ thống rào chắn an toàn buộc quá trình đánh giá phải xem xét đa chiều và cân bằng giữa các tiêu chuẩn chất lượng, thay vì chỉ ưu tiên điểm số đơn lẻ của một chỉ số chính nhưng đánh đổi sự ổn định của hệ thống.

6.5 Giới hạn của nghiên cứu

Bên cạnh những kết quả đạt được, nhóm tác giả thẳng thắn chỉ ra các giới hạn nội tại của nghiên cứu nhằm phục vụ các nghiên cứu tiếp nối:

1. **Độ lệch mức độ khó giữa tập Development và toàn kho dữ liệu:** Kết quả thực nghiệm trên 871 câu hỏi kiểm định cuối kỳ cho thấy tập phát triển (development 281 câu) dễ hơn đáng kể so với phần còn lại của kho ngữ liệu. Bốn trong sáu metric truy xuất có khoảng tin cậy 95% giữa dev và final-test hoàn toàn không chồng lấn (ví dụ nDCG@5 đạt 0,8976 trên dev nhưng giảm xuống 0,8288 trên final-test). Do đó, các giá trị tuyệt đối đo trên development mang tính chất lạc quan khoảng 0,06–0,07 điểm. Tuy nhiên, các kết luận so sánh ghép cặp tương đối giữa các mô hình vẫn hoàn toàn vững vàng.
2. **Tính trôi dạt tái lập của Dense Retriever:** Trong Giai đoạn 1, kết quả chạy lại dense retriever trên cùng một mã nguồn ghi nhận mức độ trôi dạt điểm số $\Delta = 0,0143$, lớn hơn khoảng cách giữa hai mô hình dense cạnh tranh (0,0094). Nguyên nhân bắt nguồn từ việc chưa cố định seed ngẫu nhiên cho thuật toán xấp xỉ HNSW, kích thước lô (batch size) và

hàm sinh số ngẫu nhiên của PyTorch trên GPU. Ngược lại, nhánh sparse hoàn toàn bất biến qua các lần chạy (trên cùng 284 câu held-out, hai lần chạy độc lập cho Hit@5 trùng khớp tuyệt đối tới bốn chữ số thập phân: 0,8768).

3. **Hạn chế của bộ giám khảo LLM (LLM-as-a-Judge):** Giám khảo đánh giá là GLM-5.3-Flash đã được tách biệt hoàn toàn khỏi mô hình sinh (Gemini 3.1 Flash-Lite) để tránh thiên vị nội bộ. Tuy nhiên, bộ giám khảo này chưa được hiệu chuẩn toàn diện với nhãn đánh giá của con người (bộ 20 câu judge_calibration đã được chuẩn bị nhưng chưa được gán nhãn double-blind bởi con người). Đợt audit 30 câu hỏi điểm thấp cho thấy có tới 18/30 câu giám khảo bất đồng ý kiến với người duyệt, và 23/30 câu bị chấm thấp thực chất đúng về mặt ngữ nghĩa, cho thấy điểm Answer Correctness do LLM chấm có xu hướng là một cận dưới khắt khe.
4. **Yếu tố gây nhiễu (Confound) trong khảo sát từ chối trả lời (Giai đoạn 3):** Ở chính sách từ chối B1 (bắt buộc trả lời theo cấu trúc JSON), câu trả lời bị dài dòng và Token F1 sụt giảm mạnh ($-0,1070$). Tuy nhiên, nguyên nhân chưa thể kết luận chắc chắn: do khi chuyển sang prompt B1, câu lệnh vừa bổ sung định dạng JSON vừa vô tình lược bỏ chỉ thị “trả lời ngắn gọn” của P2. Do đó, nghiên cứu chưa tách bạch được việc chất lượng câu trả lời suy giảm là do cấu trúc JSON gây cản trở hay chỉ vì thiếu chỉ thị kiểm soát độ dài.

6.6 Hướng phát triển trong tương lai

Dựa trên các phát hiện thực nghiệm, nhóm đề xuất ba hướng nghiên cứu ưu tiên:

1. **Tích hợp kỹ thuật Viết lại câu hỏi (Query Rewriting / Expansion):** Phân tích held-out chỉ ra rằng trần chất lượng của tầng sinh bị khống chế trực tiếp bởi Hit@5 (87,68%). Việc áp dụng các kỹ thuật phân rã câu hỏi hoặc viết lại câu hỏi truy vấn sẽ là chìa khóa mở rộng trần truy xuất mà không cần can thiệp vào tầng sinh.
2. **Hiệu chuẩn có hệ thống giữa LLM Judge và đánh giá của con người:** Tiến hành quy trình double-blind human review trên tập calibration để xây dựng hàm hiệu chuẩn điểm số RAGAS, lượng hóa chính xác sai số của bộ giám khảo tự động.
3. **Hoàn thiện tích hợp đầy đủ vào ứng dụng thực tế:** Đồng bộ hóa toàn diện cấu hình chiến thắng P2-depth5 cùng mô hình Gemini 3.1 Flash-Lite vào luồng xử lý mặc định của dịch vụ chat backend nhằm mang lại trải nghiệm tối ưu nhất cho người dùng cuối.

7 Kết luận

Đồ án đã hoàn thành trọn vẹn mục tiêu xây dựng và đánh giá hệ thống hỏi đáp tin tức NewsLens dựa trên kiến trúc Sinh có Tăng cường Truy xuất (RAG). Đối diện với thách thức lớn của bài toán hỏi đáp trên ngữ liệu tin tức quy mô lớn (11.064 bài báo CNN và 1.152 câu hỏi bổ sung ngữ cảnh tìm kiếm thuộc bộ dữ liệu NewsQA) xuất phát từ hai nguồn sai sót độc lập giữa khâu truy xuất thông tin và khâu sinh câu trả lời, nhóm tác giả đã tiếp cận bài toán một cách có hệ thống cả về mặt kỹ thuật công nghệ lẫn phương pháp luận nghiên cứu thực nghiệm.

Về mặt kỹ thuật và sản phẩm phần mềm: Đồ án đã hiện thực hóa hoàn chỉnh ứng dụng NewsLens với giao diện người dùng React (màn hình chat hiển thị trích dẫn nguồn và bàn thờ nghiệm truy xuất), backend FastAPI và thư viện dùng chung newsqa_rag. Hệ thống cung cấp

nền tảng xử lý dữ liệu NewsQA, lập chỉ mục kép (Chroma vector database và BM25S sparse index), truy xuất kết hợp tái xếp hạng và kết nối linh hoạt với các mô hình ngôn ngữ lớn.

Về mặt kết quả thực nghiệm: Thông qua quy trình giải đấu đa tầng được kiểm soát khắt khe, đồ án đã xác lập cấu hình tối ưu toàn diện cho hệ thống:

- Ở tầng truy xuất, BGE-M3 Sparse kết hợp bộ tái xếp hạng bge-reranker-large trên các đoạn văn bản 512 token (độ chồng lặp 64 token) chứng minh ưu thế vượt trội so với dense retriever truyền thống, mang lại mức tăng +0,1634 nDCG@5 và đẩy tỷ lệ tìm thấy bằng chứng Hit@5 lên 95,73% trên tập phát triển. Phân tích dữ liệu chuyên sâu (EDA) giải mã cơ chế bản chất: trong miền tin tức phụ thuộc nhiều vào các thực thể định danh rời rạc, cơ chế khớp từ chính xác của mô hình thưa khai thác hiệu quả các điểm neo từ hiếm (IDF $\geq 6,0$, xuất hiện ở 59,5% câu hỏi) để thu hẹp không gian từ 22.766 đoạn xuống trung vị 25 đoạn cạnh tranh mà không bị hiện tượng pha loãng thực thể (entity dilution) của dense bi-encoder; và bộ tái xếp hạng cross-encoder đóng vai trò quyết định để phân xử chính xác nhóm ứng viên cạnh tranh còn lại này.
- Ở tầng sinh đáp án, Prompt P2 (ràng buộc câu trả lời vào đúng loại thông tin trong một câu ngắn duy nhất) kết hợp 5 đoạn ngữ cảnh trên mô hình Gemini 3.1 Flash-Lite giúp tăng Answer Correctness lên 0,8015 (tăng +0,1043 so với đối chứng), đồng thời bảo toàn hoàn hảo tính trung thực (Faithfulness 0,9603) và tính hợp lệ của trích dẫn nguồn (Citation Validity 0,9786).
- Kiểm định độc lập trên 284 câu hỏi của 50 bài báo held-out hoàn toàn chưa từng dùng để tinh chỉnh xác nhận hệ thống đạt Answer Correctness 0,7157, chứng minh năng lực tổng quát hóa vững chắc trong môi trường dữ liệu thực tế.

Về mặt phương pháp luận nghiên cứu: Đồ án làm rõ giá trị của quy trình **đăng ký trước rào chắn an toàn (pre-registered guardrails)** và phương pháp kiểm định thống kê bootstrap ghép cặp gom cụm theo bài báo. Hiện tượng “Luật thắng điểm số” diễn ra qua ba giai đoạn thử nghiệm cho thấy: việc lựa chọn cấu hình thuần túy dựa vào điểm số cao nhất của một chỉ số đơn lẻ dễ dẫn đến việc chấp nhận các cấu hình có chất lượng không ổn định hoặc làm suy giảm các tiêu chí quan trọng khác (như độ trung thực, độ hợp lệ trích dẫn hay cấu trúc câu trả lời). Việc áp dụng hệ thống rào chắn an toàn đa chỉ số là bài học then chốt để đảm bảo hệ thống RAG đạt hiệu năng cân bằng và đáng tin cậy.

Hệ thống NewsLens không chỉ là một bài tập lớn môn học khai phá văn bản mà còn đặt nền móng vững chắc cho các ứng dụng hỏi đáp tin tức, thẩm định tin giả và tra cứu tư liệu báo chí trong thực tiễn.

Tài liệu

- [1] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in Neural Information Processing Systems (NeurIPS)*, 33:1877–1901, 2020.
- [2] Jianlv Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*, 2024.
- [3] Gordon V Cormack, Charles LA Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759, 2009.
- [4] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. RAGAS: Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv:2309.15217*, 2023.
- [5] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Ye Jin Bang, Wenliang Dai, Andrea Madotto, et al. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38, 2023.
- [6] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474, 2020.
- [7] Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, Ilya Sutskever, et al. Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9, 2019.
- [8] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3982–3992, 2019.
- [9] Stephen Robertson, Hugo Zaragoza, et al. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends® in Information Retrieval*, 3(4):333–389, 2009.
- [10] Shitao Xiao, Zheng Liu, Peitian Zhang, and Niklas Muennighoff. C-Pack: Packaged resources to advance general Chinese embedding. *arXiv preprint arXiv:2309.07597*, 2023.

Phụ lục

A Prompt zero-shot

Các đoạn dưới đây là *system prompt* P0–P3 nguyên văn từ prompt registry của Giai đoạn 2. Câu hỏi và năm context được gửi riêng trong user prompt; phần này không đưa đáp án mẫu cho generator.

P0 — Đối chứng. Yêu cầu trả lời ngắn, dựa vào context và có citation cho từng phát biểu thực tế.

You are a helpful assistant answering questions based on provided context. Answer concisely and only based on the given context. Cite supporting context using its bracketed number, for example [1]. Every factual claim must have a citation, and you must not cite context that does not support the claim. If the answer is not in the context, say: 'I cannot find this information in the provided context.'

P1 — Siết grounding. Kiểm tra liệu cảm suy đoán và chỉ dẫn bằng chứng trực tiếp có tăng Faithfulness hay không.

Answer the question using only facts explicitly stated in the numbered context. Do not add background knowledge, assumptions, or plausible details. Give a concise answer and cite the supporting context with [n] after every factual claim. Cite only context that directly supports that claim. If the context does not contain the answer, say: 'I cannot find this information in the provided context.'

P2 — Đúng loại đáp án. Kiểm tra liệu đáp án một câu, chỉ chứa loại thông tin được hỏi, có tăng độ chính xác hay không.

Answer using only the numbered context. Give one short answer sentence containing only the information type requested by the question, such as a person, place, date, year, number, object, event, or explanation. Include multiple items only when the question explicitly asks for them. Do not repeat the question, list alternative answers, or add background details. Place a supporting citation [n] immediately after the answer. If the answer is not in the context, say: 'I cannot find this information in the provided context.'

P3 — Phân biệt sự kiện. Kiểm tra liệu chọn đoạn khớp chủ thể, sự kiện, địa điểm và thời gian có giảm nhầm lẫn giữa các bài hay không.

Answer using only facts explicitly stated in the numbered context. First identify the passage that best matches all identifying details in the question, including its subject, event, location, and time. Do not combine facts, figures, or dates from different events, articles, or reporting periods. Give one short answer sentence containing only the requested information type, and include multiple items only when explicitly asked. Place a supporting citation [n] immediately after the answer and cite only the passage that directly supports it. If no passage contains a defensible answer, say: 'I cannot find this information in the provided context.'

B Prompt one-shot P2-1S

P2-1S giữ nguyên P2 và nối thêm ví dụ dưới đây vào cùng system prompt. Ví dụ **hoàn toàn được tạo tổng hợp**: bảo tàng Northbridge, kế hoạch Riverside, ngữ cảnh, câu hỏi và đáp án đều không lấy từ NewsQA, corpus truy xuất, development hoặc held-out. Ví dụ chỉ minh họa cách trả lời ngắn và trở tới đúng số thứ tự context.

Demonstration (format example only):

Context [1]: The Northbridge museum opened a new gallery in 2018.

Context [2]: The city council approved the Riverside transit plan in March 2021.

Question: When was the Riverside transit plan approved?

Answer: March 2021 [2]

Now answer the user's question using the supplied numbered context and the same concise citation format.

Bản prompt đầy đủ là P2 ở Phụ lục A, hai dòng trống, rồi phần demonstration trên. Bản ghi nguyên văn và SHA-256 được lưu trong `results/phase2/1s_prompt_experiment/1s_dev_results/results/one_shot_prompt_contract.json`.

C Prompt judge RAGAS

Các file dưới đây được xuất bằng `scripts/export_report_ragas_prompts.py` từ **RAGAS 0.4.3**. Mỗi file chứa instruction nguyên văn, JSON output schema, toàn bộ ví dụ few-shot có sẵn trong thư viện và phần input cuối. Các giá trị trong dấu `<...>` ở input cuối là *giữ chỗ* để in template; khi chấm, RAGAS thay bằng dữ liệu của từng câu hỏi. Judge là GLM-5.3-Flash qua Fireworks, reasoning low. Citation metrics không sử dụng judge này.

Bảng 25: Template RAGAS được dùng cho năm metric.

Metric	Template / bước chấm
Faithfulness	Tách đáp án thành phát biểu; kiểm tra từng phát biểu với context.
Answer Correctness	Tách đáp án và gold thành phát biểu; phân loại TP/FP/FN.
Answer Relevancy	Sinh câu hỏi từ đáp án, phát hiện trả lời lảng tránh; so embedding với câu hỏi gốc.
Context Precision	Chấm từng context có hữu ích cho câu hỏi và gold không; xét thứ tự context.
Context Recall	Chấm từng phát biểu của gold có được context hỗ trợ không.

Tách phát biểu: Faithfulness và Answer Correctness

```

Given a question and an answer, analyze the complexity of each sentence in the answer. Break down each
sentence into one or more fully understandable statements. Ensure that no pronouns are used in any
statement. Format the outputs in JSON.

Please return the output in a JSON format that complies with the following schema as specified in JSON Schema:
{"properties": {"statements": {"description": "The generated statements", "items": {"type": "string"}, "title":
  "Statements", "type": "array"}}, "required": ["statements"], "title": "StatementGeneratorOutput", "type":
  "object"}Do not use single quotes in your response but double quotes,properly escaped with a backslash.

-----EXAMPLES-----

```

Example 1

Input: {

```
"question": "Who was Albert Einstein and what is he best known for?",
"answer": "He was a German-born theoretical physicist, widely acknowledged to be one of the greatest and
most influential physicists of all time. He was best known for developing the theory of relativity, he
also made important contributions to the development of the theory of quantum mechanics."
```

}

Output: {

```
"statements": [
  "Albert Einstein was a German-born theoretical physicist.",
  "Albert Einstein is recognized as one of the greatest and most influential physicists of all time.",
  "Albert Einstein was best known for developing the theory of relativity.",
  "Albert Einstein also made important contributions to the development of the theory of quantum
mechanics."
]
```

}

}

Now perform the same with the following input

input: {

```
"question": "<question>",
"answer": "<answer or reference>"
```

}

Output:

Kiểm tra phát biểu: Faithfulness

Your task is to judge the faithfulness of a series of statements based on a given context. For each statement you must return verdict as 1 if the statement can be directly inferred based on the context or 0 if the statement can not be directly inferred based on the context.

Please return the output in a JSON format that complies with the following schema as specified in JSON Schema:

```
{"$defs": {"StatementFaithfulnessAnswer": {"properties": {"statement": {"description": "the original statement, word-by-word", "title": "Statement", "type": "string"}, "reason": {"description": "the reason of the verdict", "title": "Reason", "type": "string"}, "verdict": {"description": "the verdict(0/1) of the faithfulness.", "title": "Verdict", "type": "integer"}}, "required": ["statement", "reason", "verdict"], "title": "StatementFaithfulnessAnswer", "type": "object"}}, {"properties": {"statements": {"items": {"$ref": "#/$defs/StatementFaithfulnessAnswer"}, "title": "Statements", "type": "array"}}, "required": ["statements"], "title": "NLISentenceOutput", "type": "object"}Do not use single quotes in your response but double quotes,properly escaped with a backslash.
```

-----EXAMPLES-----

Example 1

Input: {

```
"context": "John is a student at XYZ University. He is pursuing a degree in Computer Science. He is
enrolled in several courses this semester, including Data Structures, Algorithms, and Database Management.
John is a diligent student and spends a significant amount of time studying and completing assignments.
He often stays late in the library to work on his projects.",
```

```
"statements": [
```

```
  "John is majoring in Biology.",
  "John is taking a course on Artificial Intelligence.",
  "John is a dedicated student.",
  "John has a part-time job."
```

```
]
```

}

Output: {

```
"statements": [
```

```
{
  "statement": "John is majoring in Biology.",
  "reason": "John's major is explicitly mentioned as Computer Science. There is no information
suggesting he is majoring in Biology.",
  "verdict": 0
},
```

```
{
```

```
}
```

```

    "statement": "John is taking a course on Artificial Intelligence.",
    "reason": "The context mentions the courses John is currently enrolled in, and Artificial
Intelligence is not mentioned. Therefore, it cannot be deduced that John is taking a course on AI.",
    "verdict": 0
  },
  {
    "statement": "John is a dedicated student.",
    "reason": "The context states that he spends a significant amount of time studying and completing
assignments. Additionally, it mentions that he often stays late in the library to work on his projects,
which implies dedication.",
    "verdict": 1
  },
  {
    "statement": "John has a part-time job.",
    "reason": "There is no information given in the context about John having a part-time job.",
    "verdict": 0
  }
]
}

```

Example 2

```

Input: {
  "context": "Photosynthesis is a process used by plants, algae, and certain bacteria to convert light
energy into chemical energy.",
  "statements": [
    "Albert Einstein was a genius."
  ]
}

```

```

Output: {
  "statements": [
    {
      "statement": "Albert Einstein was a genius.",
      "reason": "The context and statement are unrelated",
      "verdict": 0
    }
  ]
}

```

Now perform the same with the following input

```

input: {
  "context": "<retrieved contexts>",
  "statements": [
    "<statement>"
  ]
}

```

Output:

Phân loại TP/FP/FN: Answer Correctness

Given a ground truth and an answer statements, analyze each statement and classify them in one of the following categories: TP (true positive): statements that are present in answer that are also directly supported by the one or more statements in ground truth, FP (false positive): statements present in the answer but not directly supported by any statement in ground truth, FN (false negative): statements found in the ground truth but not present in answer. Each statement can only belong to one of the categories. Provide a reason for each classification.

Please return the output in a JSON format that complies with the following schema as specified in JSON Schema:

```

{"$defs": {"StatementsWithReason": {"properties": {"statement": {"title": "Statement", "type": "string"}, "reason": {"title": "Reason", "type": "string"}}, "required": ["statement", "reason"], "title": "StatementsWithReason", "type": "object"}}, "properties": {"TP": {"items": {"$ref": "#/$defs/StatementsWithReason"}, "title": "TP", "type": "array"}, "FP": {"items": {"$ref": "#/$defs/StatementsWithReason"}, "title": "FP", "type": "array"}, "FN": {"items": {"$ref": "#/$defs/StatementsWithReason"}, "title": "FN", "type": "array"}}, "required": ["TP", "FP", "FN"], "title": "

```

ClassificationWithReason", "type": "object"}Do not use single quotes in your response but double quotes, properly escaped with a backslash.

-----EXAMPLES-----

Example 1

```
Input: {
  "question": "What powers the sun and what is its primary function?",
  "answer": [
    "The sun is powered by nuclear fission, similar to nuclear reactors on Earth.",
    "The primary function of the sun is to provide light to the solar system."
  ],
  "ground_truth": [
    "The sun is powered by nuclear fusion, where hydrogen atoms fuse to form helium.",
    "This fusion process in the sun's core releases a tremendous amount of energy.",
    "The energy from the sun provides heat and light, which are essential for life on Earth.",
    "The sun's light plays a critical role in Earth's climate system.",
    "Sunlight helps to drive the weather and ocean currents."
  ]
}
Output: {
  "TP": [
    {
      "statement": "The primary function of the sun is to provide light to the solar system.",
      "reason": "This statement is somewhat supported by the ground truth mentioning the sun providing light and its roles, though it focuses more broadly on the sun's energy."
    }
  ],
  "FP": [
    {
      "statement": "The sun is powered by nuclear fission, similar to nuclear reactors on Earth.",
      "reason": "This statement is incorrect and contradicts the ground truth which states that the sun is powered by nuclear fusion."
    }
  ],
  "FN": [
    {
      "statement": "The sun is powered by nuclear fusion, where hydrogen atoms fuse to form helium.",
      "reason": "This accurate description of the 'suns power source is not included in the answer."
    },
    {
      "statement": "This fusion process in the sun's core releases a tremendous amount of energy.",
      "reason": "This process and its significance are not mentioned in the answer."
    },
    {
      "statement": "The energy from the sun provides heat and light, which are essential for life on Earth.",
      "reason": "The answer only mentions light, omitting the essential aspects of heat and its necessity for life, which the ground truth covers."
    },
    {
      "statement": "The sun's light plays a critical role in Earth's climate system.",
      "reason": "This broader impact of the 'suns light on Earth's climate system is not addressed in the answer."
    },
    {
      "statement": "Sunlight helps to drive the weather and ocean currents.",
      "reason": "The effect of sunlight on weather patterns and ocean currents is omitted in the answer."
    }
  ]
}
```

Example 2

Input: {

```
"question": "What is the boiling point of water?",
"answer": [
  "The boiling point of water is 100 degrees Celsius at sea level"
],
"ground_truth": [
  "The boiling point of water is 100 degrees Celsius (212 degrees Fahrenheit) at sea level.",
  "The boiling point of water can change with altitude."
]
}
Output: {
  "TP": [
    {
      "statement": "The boiling point of water is 100 degrees Celsius at sea level",
      "reason": "This statement is directly supported by the ground truth which specifies the boiling
point of water as 100 degrees Celsius at sea level."
    }
  ],
  "FP": [],
  "FN": [
    {
      "statement": "The boiling point of water can change with altitude.",
      "reason": "This additional information about how the boiling point of water can vary with altitude
is not mentioned in the answer."
    }
  ]
}
-----

Now perform the same with the following input
input: {
  "question": "<question>",
  "answer": [
    "<answer statement>"
  ],
  "ground_truth": [
    "<reference statement>"
  ]
}
Output:
```

Sinh câu hỏi: Answer Relevancy

Generate a question for the given answer and Identify if answer is noncommittal. Give noncommittal as 1 if the answer is noncommittal and 0 if the answer is committal. A noncommittal answer is one that is evasive, vague, or ambiguous. For example, "I don't know" or "I'm not sure" are noncommittal answers

Please return the output in a JSON format that complies with the following schema as specified in JSON Schema: {"properties": {"question": {"title": "Question", "type": "string"}, "noncommittal": {"title": "Noncommittal", "type": "integer"}}, "required": ["question", "noncommittal"], "title": "ResponseRelevanceOutput", "type": "object"} Do not use single quotes in your response but double quotes, properly escaped with a backslash.

-----EXAMPLES-----

Example 1

```
Input: {
  "response": "Albert Einstein was born in Germany."
}
Output: {
  "question": "Where was Albert Einstein born?",
  "noncommittal": 0
}
```

Example 2

```
Input: {
```

```
"response": "I don't know about the groundbreaking feature of the smartphone invented in 2023 as am
unaware of information beyond 2022. "
}
Output: {
  "question": "What was the groundbreaking feature of the smartphone invented in 2023?",
  "noncommittal": 1
}
-----

Now perform the same with the following input
input: {
  "response": "<generated answer>"
}
Output:
```

Chấm từng context: Context Precision

Given question, answer and context verify if the context was useful in arriving at the given answer. Give verdict as "1" if useful and "0" if not with json output.

Please return the output in a JSON format that complies with the following schema as specified in JSON Schema: {"properties": {"reason": {"description": "Reason for verification", "title": "Reason", "type": "string"}, "verdict": {"description": "Binary (0/1) verdict of verification", "title": "Verdict", "type": "integer"}}, "required": ["reason", "verdict"], "title": "Verification", "type": "object"} Do not use single quotes in your response but double quotes, properly escaped with a backslash.

-----EXAMPLES-----

Example 1

```
Input: {
  "question": "What can you tell me about Albert Einstein?",
  "context": "Albert Einstein (14 March 1879 – 18 April 1955) was a German-born theoretical physicist, widely held to be one of the greatest and most influential scientists of all time. Best known for developing the theory of relativity, he also made important contributions to quantum mechanics, and was thus a central figure in the revolutionary reshaping of the scientific understanding of nature that modern physics accomplished in the first decades of the twentieth century. His –massenergy equivalence formula  $E = mc^2$ , which arises from relativity theory, has been called 'the world's most famous equation'. He received the 1921 Nobel Prize in Physics 'for his services to theoretical physics, and especially for his discovery of the law of the photoelectric effect', a pivotal step in the development of quantum theory. His work is also known for its influence on the philosophy of science. In a 1999 poll of 130 leading physicists worldwide by the British journal Physics World, Einstein was ranked the greatest physicist of all time. His intellectual achievements and originality have made Einstein synonymous with genius.",
  "answer": "Albert Einstein, born on 14 March 1879, was a German-born theoretical physicist, widely held to be one of the greatest and most influential scientists of all time. He received the 1921 Nobel Prize in Physics for his services to theoretical physics."
}
Output: {
  "reason": "The provided context was indeed useful in arriving at the given answer. The context includes key information about Albert Einstein's life and contributions, which are reflected in the answer.",
  "verdict": 1
}
```

Example 2

```
Input: {
  "question": "who won 2020 icc world cup?",
  "context": "The 2022 ICC Men's T20 World Cup, held from October 16 to November 13, 2022, in Australia, was the eighth edition of the tournament. Originally scheduled for 2020, it was postponed due to the COVID-19 pandemic. England emerged victorious, defeating Pakistan by five wickets in the final to clinch their second ICC Men's T20 World Cup title.",
  "answer": "England"
}
Output: {
  "reason": "the context was useful in clarifying the situation regarding the 2020 ICC World Cup and indicating that England was the winner of the tournament that was intended to be held in 2020 but
```

```
    actually took place in 2022.",
    "verdict": 1
}
```

Example 3

```
Input: {
  "question": "What is the tallest mountain in the world?",
  "context": "The Andes is the longest continental mountain range in the world, located in South America. It
    stretches across seven countries and features many of the highest peaks in the Western Hemisphere. The
    range is known for its diverse ecosystems, including the high-altitude Andean Plateau and the Amazon
    rainforest.",
  "answer": "Mount Everest."
}
Output: {
  "reason": "the provided context discusses the Andes mountain range, which, while impressive, does not
    include Mount Everest or directly relate to the question about the world's tallest mountain.",
  "verdict": 0
}
```

Now perform the same with the following input

```
input: {
  "question": "<question>",
  "context": "<one retrieved context>",
  "answer": "<reference>"
}
Output:
```

Kiểm tra độ phủ gold: Context Recall

Given a context, and an answer, analyze each sentence in the answer and classify if the sentence can be attributed to the given context or not. Use only 'Yes' (1) or 'No' (0) as a binary classification. Output json with reason.

Please return the output in a JSON format that complies with the following schema as specified in JSON Schema:

```
{"$defs": {"ContextRecallClassification": {"properties": {"statement": {"title": "Statement", "type": "string"}, "reason": {"title": "Reason", "type": "string"}, "attributed": {"title": "Attributed", "type": "integer"}}, "required": ["statement", "reason", "attributed"], "title": "ContextRecallClassification", "type": "object"}}, {"classifications": {"items": {"$ref": "#/$defs/ContextRecallClassification"}, "title": "Classifications", "type": "array"}}, {"required": ["classifications"], "title": "ContextRecallClassifications", "type": "object"}Do not use single quotes in your response but double quotes, properly escaped with a backslash.
```

-----EXAMPLES-----

Example 1

```
Input: {
  "question": "What can you tell me about albert Albert Einstein?",
  "context": "Albert Einstein (14 March 1879 - 18 April 1955) was a German-born theoretical physicist,
    widely held to be one of the greatest and most influential scientists of all time. Best known for
    developing the theory of relativity, he also made important contributions to quantum mechanics, and was
    thus a central figure in the revolutionary reshaping of the scientific understanding of nature that
    modern physics accomplished in the first decades of the twentieth century. His mass-energy equivalence
    formula  $E = mc^2$ , which arises from relativity theory, has been called 'the world's most famous equation'.
    He received the 1921 Nobel Prize in Physics 'for his services to theoretical physics, and especially for
    his discovery of the law of the photoelectric effect', a pivotal step in the development of quantum
    theory. His work is also known for its influence on the philosophy of science. In a 1999 poll of 130
    leading physicists worldwide by the British journal Physics World, Einstein was ranked the greatest
    physicist of all time. His intellectual achievements and originality have made Einstein synonymous with
    genius.",
  "answer": "Albert Einstein, born on 14 March 1879, was a German-born theoretical physicist, widely held to
    be one of the greatest and most influential scientists of all time. He received the 1921 Nobel Prize in
    Physics for his services to theoretical physics. He published 4 papers in 1905. Einstein moved to
    Switzerland in 1895."
}
```

```
Output: {
  "classifications": [
    {
      "statement": "Albert Einstein, born on 14 March 1879, was a German-born theoretical physicist,
widely held to be one of the greatest and most influential scientists of all time.",
      "reason": "The date of birth of Einstein is mentioned clearly in the context.",
      "attributed": 1
    },
    {
      "statement": "He received the 1921 Nobel Prize in Physics for his services to theoretical physics
.",
      "reason": "The exact sentence is present in the given context.",
      "attributed": 1
    },
    {
      "statement": "He published 4 papers in 1905.",
      "reason": "There is no mention about papers he wrote in the given context.",
      "attributed": 0
    },
    {
      "statement": "Einstein moved to Switzerland in 1895.",
      "reason": "There is no supporting evidence for this in the given context.",
      "attributed": 0
    }
  ]
}

-----

Now perform the same with the following input
input: {
  "question": "<question>",
  "context": "<retrieved contexts>",
  "answer": "<reference>"
}
Output:
```

D Cách chấm citation

Generator nhận các context đánh số [1]–[5]. Bộ chấm ánh xạ chỉ số trong đáp án về chunk ID theo đúng thứ tự context đã gửi. Ví dụ tổng hợp: [1]–[5] lần lượt là c1–c5, còn tập gold là {c2, c4}.

Bảng 26: Ví dụ phân biệt citation hợp lệ và citation đúng bằng chứng.

Citation	Chunk được cite	Validity	Precision	Recall	Giải thích
[2]	c2	1	1	0,5	Hợp lệ, đúng một trong hai gold.
[3]	c3	1	0	0	Hợp lệ nhưng sai bằng chứng.
[6]	Không có	0	0	0	Vượt số context đã gửi.
[2][3]	c2, c3	1	0,5	0,5	Có một citation thừa.

- **Citation Validity** = $|C|/(|C| + |I|)$, với C là tập chunk ID được cite từ chỉ số hợp lệ và I là tập chỉ số citation ngoài phạm vi. Không có citation thì điểm bằng 0.
- **Citation Precision** = $|C \cap G|/|C|$: bao nhiêu chunk được cite thực sự thuộc gold G .
- **Citation Recall** = $|C \cap G|/|G|$: tỷ lệ gold chunks được cite.
- **Citation F1** = $2PR/(P + R)$ khi $P + R > 0$; nếu không thì bằng 0.

- Bộ chấm loại citation trùng trước khi tính và tính điểm từng câu rồi lấy trung bình. Validity chỉ kiểm tra chỉ số tồn tại, không xác nhận claim được context hỗ trợ về mặt ngữ nghĩa.

E Khảo sát mở rộng: Phân đoạn văn bản và Chính sách từ chối

Phụ lục này cung cấp số liệu chi tiết của hai khảo sát thăm dò mở rộng được tóm lược tại Mục 5.8.

E.1 Khảo sát chiến lược phân đoạn văn bản (Giai đoạn 2C)

Bảng 27 trình bày kết quả sàng lọc truy xuất trên 281 câu hỏi tập phát triển giữa bốn phương pháp phân đoạn:

- C0: Recursive Character Splitter (kích thước 512 token, overlap 64 token).
- C1: Sentence Splitter (phân tách theo ranh giới câu tự nhiên).
- C2: Paragraph Splitter (phân tách theo đoạn văn bản).
- C3: Hierarchical Parent–Child (đoạn con 128 token để truy xuất; đoạn cha 512 token để sinh).

Bảng 27: Kết quả sàng lọc truy xuất của các chiến lược phân đoạn văn bản (Giai đoạn 2C).

Chiến lược	Số chunks	Hit@5	Recall@5	MRR@5	nDCG@5
C0 (Recursive 512/64)	22.766	0,9573	0,9537	0,8791	0,8963
C1 (Sentence)	22.014	0,9680	0,9591	0,8796	0,8979
C2 (Paragraph)	22.018	0,9609	0,9555	0,8817	0,8989
C3 (Parent–Child)	49.218	0,9324	0,9241	0,8166	0,8417

E.2 Khảo sát chính sách từ chối trả lời (Giai đoạn 3)

Thử nghiệm trên tập dữ liệu kiểm soát gồm 200 tình huống (140 câu development, 60 câu final) với các trường hợp bị loại bỏ bài báo hoặc loại bỏ đoạn văn bản chứa bằng chứng nhằm đánh giá ba chính sách:

- B0: Cấu hình cơ sở, sử dụng prompt P2 với câu từ chối mặc định.
- B1: Ràng buộc cấu trúc JSON bắt buộc trường answerability nhận một trong hai giá trị "answerable" hoặc "insufficient_evidence".
- B2: B1 kết hợp cổng chặn ngưỡng điểm của mô hình tái xếp hạng BGE-Reranker-Large.

Bảng 28: So sánh các chính sách từ chối trả lời trên tập Development (140 câu) và Final (60 câu).

Tập dữ liệu	Chính sách	Abst. F1	False-Ans.	Token F1	Cit. Valid.
Development (140 câu)	B0 (Prompt P2)	0,9740	5,06%	0,4490	1,0000
	B1 (JSON Schema)	0,9936	1,27%	0,3420	1,0000
	B2 (Score Gate)	0,9936	1,27%	0,3420	1,0000
Final (60 câu)	B0 (Prompt P2)	0,9697	5,88%	0,4766	1,0000
	B1 (JSON Schema)	0,9538	8,82%	0,2996	1,0000
	B2 (Score Gate)	0,9538	8,82%	0,2996	1,0000

F Nguồn tái lập

- Prompt generator: `configs/experiments/phase2_generation_prompts.yaml`; prompt one-shot và SHA-256: `one_shot_prompt_contract.json` trong artifact development P2-1S.
- Prompt judge: các file `.txt` và `manifest.json` trong `docs/latex/report/appendix/ragas_prompts/`; chạy lại `scripts/export_report_ragas_prompts.py` với RAGAS 0.4.3 để đối chiếu.
- Bộ chấm citation: `common/newsqa_rag/evaluation/metrics.py`; ánh xạ [n] và loại chỉ số ngoài phạm vi: `common/newsqa_rag/response_parsing.py`.
- Mỗi `run_manifest.json` ghi model, question IDs, prompt hash và coverage. Bảng điểm đầy đủ ở `results/phase2/`.