

NewsQA RAG

Chọn cách lấy đoạn văn, và chọn cách hỏi LLM

Nhóm Text Mining

Học kỳ 3 – Năm 3


Mọi con số trong bộ slide này sinh tự động từ artifact đã commit
(`scripts/build_latex_numbers.py`).

Nội dung

1. Bài toán và cách chia việc
2. Dữ liệu: cái EDA phát hiện
3. **Phase 1** — chọn cách lấy đoạn văn
4. **Phase 2** — chọn cách hỏi LLM
5. Chỗ Phase 1 giúp Phase 2
6. Chưa được phép kết luận gì

Bài toán

Hỏi–đáp có trích dẫn trên 11.064 bài báo CNN



Người dùng hỏi một câu. Hệ thống phải tìm đúng đoạn văn chứa câu trả lời trong 22.766 đoạn, rồi để LLM viết đáp án *chỉ dựa trên* các đoạn đó và chỉ ra nó lấy từ đoạn nào.

Hai việc, hai kiểu hỏng, hai loại thước đo — nên tách làm hai phase.

Vì sao phải tách hai phase

	Phase 1 — lấy đoạn văn	Phase 2 — hỏi LLM
Hỏng kiểu gì	Không tìm ra đoạn chứa đáp án	Tìm ra rồi nhưng trả lời sai, hoặc bịa
Đo bằng gì	Hit@k, nDCG@5, MRR@5	Answer Correctness, Faithfulness, Citation
Chi phí	GPU, không gọi API	Tốn tiền API mỗi lần chạy
Tái lập	Có (chỉ mục cố định)	Chỉ trong giới hạn nhiễu của LLM

Thứ tự bắt buộc: khóa Phase 1 trước. Nếu vừa đổi cách lấy đoạn vừa đổi cách hỏi, không cách nào biết được cải thiện đến từ đâu.

Phase 2 chạy trên một vết truy xuất đóng băng: mọi khác biệt quy hết về tăng sinh.

EDA phát hiện gì trước khi chạy thí nghiệm

Phát hiện	Hệ quả lên thiết kế
Nhấn nhiều 7,0%–24,5%	Chênh lệch dưới 7,0% không được coi là thắng
Trung vị 25 đoạn đối thủ mỗi câu hỏi	Reranker là bắt buộc, không phải tùy chọn
Câu hỏi neo vào tên riêng, ngày, số	Dự đoán sparse thắng dense — <i>trước</i> khi đo
4.603 bài bị cắt đuôi	Dựng lại kho: 19.263 → 22.766 đoạn
Notebook cũ đặt judge = generator	Tách judge sang nhà cung cấp khác

EDA không phải bước trang trí: nó viết sẵn giả thuyết cho từng vòng thí nghiệm.

Hai cách đọc cùng một tập câu hỏi

original và resolved

Nhiều câu hỏi NewsQA không đứng độc lập được — chúng viết như đang nói tiếp một cuộc hội thoại:

original *“How many were killed?”*

resolved *“How many people were killed in the Kandahar bombing?”*

- Tỷ lệ câu phụ thuộc ngữ cảnh giảm từ **57,5%** xuống **11,3%** sau khi resolve.
- Bản original **thiên vị sparse**: câu cụt thì khớp từ vựng càng có lợi thế giả tạo. Đo trên đó là tự khen mình.
- Hệ thống thật luôn nhận câu hỏi đầy đủ ngữ cảnh → resolved là tập **sát thực tế triển khai**.

Mọi số chính báo cáo theo resolved; original chỉ dùng làm cận dưới.

PHASE 1

Chọn cách lấy đoạn văn

Trong 22.766 đoạn, tìm 5 đoạn nhiều khả năng chứa đáp án nhất.
Không gọi LLM. Không tốn tiền API.

Thiết kế: giải đấu phân tầng

23 cấu hình thay vì 72 tổ hợp

Vòng	Thử gì	Thắng
1	4 mô hình dense $\times$ 4 mô hình sparse	BGE-M3 sparse
2	3 retriever $\times$ 3 reranker	+ bge-reranker-large
3	3 kích thước chunk (256 / 512 / 1024)	512/64 — không ai thắng rõ

Quán quân mỗi vòng mới được đi tiếp. Đây là đánh đổi có ý thức: rẻ hơn nhiều lần so với lưới đầy đủ, nhưng **không phát hiện được tương tác** giữa các lựa chọn ở hai vòng khác nhau.

Luật phán quyết khóa trước: chênh lệch phải (1) vượt biên độ nhiễu 7,0%, và (2) có CI95 của hiệu theo cặp không chứa 0.

Hai điều kiện, không phải một. Có ý nghĩa thống kê chưa đủ để đổi cấu hình.

Vòng 1 — Sparse áp đảo dense

So sánh (nDCG@5, resolved)	Δ	CI95
BGE-M3 sparse vs e5-base-v2 dense	+0,1634	[+0,1231; +0,2080]
BGE-M3 vs BM25-okapi-stemmed	+0,0194	[−0,0125; +0,0508]
e5-base-v2 vs bge-small-en-v1.5	+0,0094	[−0,0261; +0,0448]

- **Chỉ dòng đầu vượt được cả hai điều kiện.** Khoảng cách +0,1634 lớn hơn biên độ nhiễu 7,0% và CI95 không chứa 0.
- Hai dòng sau: CI95 **chứa 0** → không phân định được. Không có “mô hình dense tốt nhất”, và *đó cũng là một kết quả*.
- **Vì sao sparse thắng:** EDA đã dự báo — câu hỏi bám vào tên riêng, ngày tháng, con số. Khớp từ vựng bắt được đúng thứ đó; embedding làm nhòe nó đi.

Giả thuyết từ EDA, kiểm bằng bootstrap theo cặp, kết luận khớp dự báo.

Vòng 2 và 3 — Reranker cần, chunk size thì không

Vòng 2 — reranker thêm +0,0659 nDCG@5. EDA đã đo trung vị 25 đoạn đối thủ cùng chủ đề cho mỗi câu hỏi, nên việc lọc lại top 20 xuống top 5 là bắt buộc. Hybrid dense+sparse: không chứng minh được có lợi.

Vòng 3 — kết quả null, và nó trung thực.

Chunk 512 / 64	0,8976
Chunk 1024 / 128	0,8862
Chunk 256 / 32	0,8507
Khoảng cách cao nhất – thấp nhất	0,0469

0,0469 nằm **dưới** biên độ nhiễu 7,0%, và cả ba khoảng CI95 chồng lẫn nhau. Chọn 512/64 vì **lý do vận hành**, không phải vì nó thắng.

Báo cáo một kết quả null đúng như nó là, thay vì tô nó thành chiến thắng.

Ablation — Contextual chunking

Ba vòng đầu đổi retriever. Vòng này đổi cách biểu diễn dữ liệu.

Mọi chỉ mục ở Vòng 1–3 đều dựng từ chunk["text"] và không gì khác. Nên “sparse thắng dense” thực ra là “sparse thắng dense *trên cách biểu diễn này*”.

Giả thuyết: chunk tiếp nối đến tay retriever mà không mang dấu hiệu nào cho biết nó thuộc bài nào.

```
chunk 0  "LOS ANGELES (CNN) -- Natalie Cole's search for a kidney ended..."
chunk 1  "...she said. The transplant was performed Tuesday..."   thuộc bài nào?
```

Can thiệp: nối 160 ký tự đầu bài báo vào trước mỗi chunk tiếp nối.

22.766 chunk – 11.064 chunk đầu bài = **11.702** = đúng số chunk được sửa (51,4%)

nDCG@5 (resolved, 1.152 câu)	plain	contextual
Dense (e5-base-v2)	0,6598	0,6891
Sparse (BGE-M3)	0,7741	0,7533

Dense +0,0293, sparse –0,0208 — hai hiệu ứng ngược chiều.

Ablation — đọc kết quả cho đúng

- Dense **+0,0293** [+0,0184; +0,0406] — ngữ cảnh cho embedding thứ nó thiếu: biết chunk này thuộc bài nào.
- Sparse **−0,0208** [−0,0288; −0,0136] — chính 160 ký tự đó lặp trên mọi chunk cùng bài, **làm loãng tần suất từ hiếm**.
- Khoảng cách sparse–dense thu hẹp 0,1143 → 0,0641, nhưng **không đảo ngược**.

Và kết luận này mạnh hơn bằng Vòng 1, chứ không yếu hơn: nhánh dense ở đây dùng **tìm kiếm chính xác** thay vì HNSW — vừa tái lập được (bỏ đúng nguồn nhiễu làm số dense trôi 0,0143), vừa **công bằng hơn với dense** vì không mất recall do xấp xỉ. Sparse vẫn thắng trong điều kiện đó.

Hai chỗ phải nói rõ:

- Đây là *contextual chunking*, **không phải metadata indexing**. Dataset không có metadata thật — url, author, publish_date rỗng; title là 160 ký tự đầu của chính body (kiểm 200/200 bài).
- CI ở đây bootstrap theo *câu hỏi*, chưa gom cụm theo bài báo — nhất quán với Phase 1, nhưng lỏng hơn chuẩn Phase 2.

Cả hai hiệu ứng đều dưới ngưỡng 7,0% — đo được, nhưng không đổi quyết định.

Cấu hình khóa

BGE-M3 learned sparse, top_k=20 → BAAI/bge-reranker-large, top 5 → chunk 512/64

Hit@1	Hit@3	Hit@5	nDCG@5	Latency P50
0,8221	0,9324	0,9573	0,8976	512,7 ms

Chỉ mục được đóng băng và băm (fc5d67b7acf6e8be...). Toàn bộ Phase 2 chạy lại đúng vết truy xuất này — **không truy xuất lại lần nào.**

Hit@5 = 0,9573 sẽ trở thành *trần* của Phase 2. Giữ con số này trong đầu.

PHASE 2

Chọn cách hỏi LLM

Với 5 đoạn Phase 1 đưa sang, ra lệnh cho Gemini thế nào để nó trả lời đúng mà không bịa?

Không huấn luyện lại gì cả. Chỉ đổi hai thứ: nội dung prompt, và số đoạn context.

Baseline — và chẩn đoán từ ba con số

P0 (prompt gốc), 5 đoạn context, 281 câu development:

Answer Correctness	Exact Match	Token F1	Faithfulness
0,6308	0,0000	0,2648	0,9761

Đọc ba số này cùng nhau ra một chẩn đoán duy nhất:

Hệ thống không bịa. Nó chỉ nói dài.

Faithfulness 0,9761 nghĩa là gần như mọi câu đều bám bằng chứng. Nhưng Exact Match 0,0000 nghĩa là **không một câu nào** trùng khớp đáp án chuẩn — vì gold NewsQA là một span rất ngắn: một cái tên, một mốc thời gian, một con số.

Vấn đề là hình dạng câu trả lời, không phải độ trung thực của nó.

Bốn prompt, mỗi cái nhắm một nhóm lỗi đã đếm được

Audit tay **30 câu** có Answer Correctness thấp nhất, phân loại lỗi, rồi mới viết prompt.

ID	Nhắm nhóm lỗi	Cỡ nhóm	Kết quả
P0	control	—	baseline
P1	Hallucination	~0	Nhắm vào vấn đề không tồn tại
P2	Đúng nhưng quá dài	11/30	Thắng
P3	Trộn bài, trộn mốc thời gian	3/30	Đúng hướng, chưa đủ mạnh

P1 thất bại là bài học đắt nhất. Baseline đã đạt Faithfulness 0,9761 — không còn dư địa để siết grounding. P1 siết thêm và *mất* correctness khi làm vậy.

Prompt phải nhắm vào nhóm lỗi có số đo. Trục giác “siết chặt hơn thì tốt hơn” là sai.

context_depth là gì

Thứ được tính chỉnh song song với prompt

Đúng một phép cắt danh sách trên vết đã xếp hạng sẵn:

```
generation_chunks = ranked_chunks[:context_depth]
```

Không truy xuất lại, không xếp hạng lại — nên chênh lệch giữa các mức depth quy hết được cho tầng sinh.

Model nhận được khối context đánh số, và chính các số này là số nó trích dẫn:

Context: [1] ... [2] ... [3] ...
Question: ... Answer:

depth	Model thấy	Đánh đổi
1	[1]	Ít token nhất — nhưng 38/281 câu mất sạch bằng chứng
3	[1] [2] [3]	Cân bằng — nhưng 7/281 câu mất sạch bằng chứng
5	[1]...[5]	Không mất bằng chứng — tốn token nhất

Cột bên phải *không* đến từ ước lượng — Phase 1 đã đo sẵn nó.

Quyết định winner — guardrail chạy trước, điểm số chạy sau

Bốn điều kiện khóa trước khi nhìn thấy bất kỳ kết quả nào: $\text{Faithfulness} \geq -0,02$ • $\text{Citation F1} \geq -0,01$ • $\text{Citation Validity} \geq -0,01$ • $\text{coverage} \geq 95\%$. *Chỉ khi qua cả bốn mới xét Answer Correctness cao nhất.*

	P0	P2-depth3	P2-depth5
Answer Correctness	0,6308	0,7711	0,7350
Exact Match	0,0000	+0,2633	+0,0925
Faithfulness Δ	—	-0,0200	+0,0040
Citation F1 Δ	—	+0,0356	+0,0366
Citation Validity Δ	—	-0,0142	-0,0036
Phán quyết	—	LOẠI	CHỌN

P2-depth3 **điểm cao hơn** nhưng trượt 2 trong 4 guardrail. Kiểm định theo cặp xác nhận **cả hai mức tụt đều là thật** ($\text{Faithfulness} -0,0200$ [$-0,0372$; $-0,0048$], CI95 không chứa 0).

Nới ngưỡng lúc này chính là hành vi mà việc đăng ký trước sinh ra để ngăn.

Winner: P2-depth5

So với baseline P0	Δ	CI95
Answer Correctness	+0,1043	[+0,0844; +0,1240]
Exact Match	+0,0925	[+0,0596; +0,1296]
Token F1	+0,1542	[+0,1317; +0,1786]
Faithfulness	+0,0040	[−0,0127; +0,0189]
Citation F1	+0,0366	[+0,0127; +0,0616]

- Correctness tăng +0,1043, CI95 không chứa 0 — **thật**.
- Faithfulness +0,0040 [−0,0127; +0,0189]: *không tách được khỏi 0*. Đây là kết quả **tốt** — không mất grounding.
- Cái giá: tốn input token nhiều hơn depth 3 khoảng **60%**.

Vì sao P2 thắng: nó khớp với *hình dạng của nhãn*. Cũng chính là lý do Answer Relevancy giảm — metric đó thưởng câu trả lời đầy đủ ngữ cảnh, còn dữ liệu này thưởng câu trả lời cụt.

Bootstrap theo cặp gom theo bài báo, 2.000 mẫu — câu cùng một bài không độc lập.

HELD-OUT

284 câu chưa từng bị chạm tới

Chạy **đúng một lần**, bằng cấu hình đã khóa từ trước.
Đây — và chỉ đây — là con số được phép công bố.

Vì sao phải có tập held-out

Mọi con số ở các slide trước đó trên 281 câu development — chính tập mà nhóm đã thử **4 prompt × 3 mức depth** rồi chọn cái điểm cao nhất.

Chọn ra cái tốt nhất trong 12 lần thử, rồi báo cáo điểm của nó trên chính tập đã dùng để chọn, là **lệch lạc quan theo cấu trúc**.

Quy trình đã tuân thủ, có dấu vết kiểm chứng được:

- Tập 284 câu / 50 bài chốt từ đầu bằng seed 46, băm lại khớp.
- Quyết định winner ký duyệt lúc 2026-09-06 13:31:30Z (e2fa5915c45a7722...).
- Run held-out bắt đầu 2026-09-06 14:23:24 UTC — **sau** khi quyết định đã đóng băng.
- Coverage 100%: 284/284 câu, 0 lỗi.

Thứ tự thời gian là bằng chứng: không thể chọn winner sau khi đã thấy điểm held-out.

Kết quả công bố — P2-depth5 trên 284 câu held-out

	Dev (281)	Held-out (284)	macro
Answer Correctness	0,7350	0,7157	0,7230
Exact Match	0,0925	0,1092	—
Token F1	0,4191	0,4313	0,4370
Faithfulness	0,9801	0,9249	0,9318
Citation F1	0,8391	0,7289	0,7315
Citation Validity	0,9858	0,9437	0,9483
Hit@5 (truy xuất)	0,9573	0,8768	—

Correctness chỉ tụt **0,0193**. Nhưng Hit@5 tụt **−0,0805** — tập held-out **khó hơn hẳn** ở tầng truy xuất.

Micro và macro lệch nhau dưới 0,008 ở mọi metric → không bài báo nào chi phối.

Chi phí toàn bộ run: \$0,94. Latency P50 1957,5 ms.

Phát hiện quan trọng nhất: prompt *không* bị overfit

Tách 284 câu held-out theo việc truy xuất có đưa được bằng chứng ra hay không:

	n	Answer Corr.	Citation F1
Held-out, gold_in_top5	249	0,7689	0,8313
Held-out, gold_not_in_top5	35	0,3375	0,0000
Dev, gold_in_top5	269	0,7597	—

- Trên các câu truy xuất làm đúng việc, held-out (0,7689) **cao hơn** dev (0,7597) — prompt tổng quát hóa được.
- Cái tụt là tỉ lệ truy xuất trượt: 12/281 $\rightarrow$ 35/284, gần **ba lần**.
- Citation F1 nhóm trượt = **0,0000** theo định nghĩa — không có đoạn đúng nào để mà trích dẫn.

Toàn bộ khoảng cách dev $\rightarrow$ held-out là câu chuyện của truy xuất, không phải của prompt.

Chỗ Phase 1 trả lời sẵn một câu hỏi của Phase 2

Phase 2 cần biết: *cắt bớt context thì mất gì?* Đường cong Hit@k mà Phase 1 đã đo trả lời chính xác điều đó — **miễn phí**, trước khi tiêu một đồng API nào.

Số context	Hit@k	Số câu mất sạch bằng chứng
1	0,8221	38
3	0,9324	7
5	0,9573	0

Phase 2 quan sát được **đúng 7 câu** trả về “*không tìm thấy thông tin*” ở depth 3 — 2 trong đó có bằng chứng ở hạng 4, bị cắt mất. Con số dự báo và con số quan sát khớp nhau.

Đọc Hit@k trước, rồi mới chọn depth để thử. Đỡ được cả một vòng chi tiền API.

Trần của tầng sinh nằm ở tầng truy xuất

Cùng một hiện tượng, đo được ở cả hai tập:

Answer Correctness của P2-depth5	gold_in_top5	gold_not_in_top5
Development (281 câu)	0,7597	0,1829
Held-out (284 câu)	0,7689	0,3375

- Khi truy xuất trượt, đổi prompt gần như **không cứu được gì**: trên dev, cả 4 prompt đều loanh quanh 0,15–0,19.
- Nghĩa là Answer Correctness bị chặn trên bởi Hit@5. Trên held-out, $\text{Hit@5} = 0,8768 \rightarrow$ khoảng 12% số câu không có đường nào để trả lời đúng.

Đầu tư tiếp vào prompt sẽ cho lợi ích giảm dần.
Đòn bẩy còn lại nằm ở **query rewriting** và **truy xuất**.

Kết luận này rút ra được vì hai phase dùng chung một vết truy xuất đóng băng.

Chưa được phép kết luận gì

Phase 1

- Không phân định được mô hình dense nào tốt nhất (CI95 chồng lấn).
- Dense **chưa tái lập được** giữa các lần chạy: độ trôi 0,0143 *lớn hơn* khoảng cách giữa các mô hình 0,0094. Thiếu seed HNSW và seed torch.
- Chunk size là kết quả **null**. Hybrid là “không chứng minh được có lợi”, *không phải* “đã chứng minh có hại”.

Phase 2

- Answer Correctness 0,7157 là **cận dưới**: EDA đo được 7,0%–24,5% câu bị chấm sai oan; người duyệt thấy **23/30** câu điểm thấp thực ra đúng.
- Judge cũng là một LLM. Đã tách sang nhà cung cấp khác generator, nhưng **chưa hiệu chuẩn với nhãn người**.
- Answer Relevancy giảm (0,7092 $\rightarrow$ 0,6485) là **hệ quả có chủ đích** của P2, không phải suy thoái — metric đó thường câu trả lời dài, dữ liệu này thường câu trả lời cụt.
- Giải đấu phân tầng **không phát hiện được tương tác** giữa các lựa chọn ở hai vòng khác nhau.

Nói rõ cái chưa chứng minh được cũng là một phần của kết quả.

Còn thiếu gì

#	Việc	Phase	Ghi chú
1	Audit mù 30 cặp P0 ↔ winner, hai người chấm độc lập	2	Cần chia việc
2	Lập 25 câu × 2 cấu hình đo độ ổn định API	2	
3	Chạy held-out 150 bài final-test	1	Nghiem thu Phase 1
4	Chạy lại vòng 1 trên chỉ mục đã đóng gói	1	Cố định số dense
5	Bốn biểu đồ 300 DPI theo test plan §6	1	Chưa có cái nào
6	Duyệt tay dataset abstention 200 case	3	3 loại cần re- viewer thứ hai

Đã xong trong đợt này: phân tầng gold_in_top5, article-level macro, bản ghi quyết định winner, ablation contextual chunking, và **run held-out 284 câu**.

Phase 3 — dạy hệ thống biết từ chối trả lời — là bước tiếp theo.

Tóm lại

1. **Sparse thắng dense** vì câu hỏi NewsQA neo vào tên riêng, ngày tháng, con số — EDA dự báo trước, thực nghiệm xác nhận.
2. **Prompt đúng *dạng* là đòn bẩy lớn nhất ở tầng sinh** — không phải vì khéo, mà vì nó khớp hình dạng của nhãn.
3. **Guardrail đăng ký trước đã loại một cấu hình điểm cao hơn** — và đó chính là việc của nó.
4. **Prompt không bị overfit**: khoảng cách dev $\rightarrow$ held-out là câu chuyện của truy xuất.

Số công bố: Answer Correctness **0,7157** trên 284 câu held-out.