

ĐỒ ÁN MÔN HỌC

NEWSLENS

Hệ thống hỏi đáp tin tức có dẫn nguồn

Ứng dụng RAG trên bộ dữ liệu NewsQA

Môn học: Khai thác dữ liệu và văn bản

Giảng viên: Lê Thanh Tùng


Nhóm thực hiện: Nhóm 9

Tìm bằng chứng trong kho tin tức, sinh đáp án có trích dẫn
và đánh giá từng bước của hệ thống.

Thuật ngữ: dữ liệu và bằng chứng

Phân biệt văn bản được tìm kiếm, bằng chứng được gán nhãn và câu hỏi dùng để đánh giá.

Thuật ngữ	Nghĩa trong dự án
Corpus / distractor	Kho bài báo để tìm kiếm / bài không được gán bằng chứng cho bộ câu hỏi đánh giá.
Chunk	Đoạn văn cắt từ bài báo để lập chỉ mục và truy xuất.
Evidence span	Vị trí đoạn bằng chứng trong văn bản gốc.
Gold chunk	Chunk được gán nhãn chứa bằng chứng trả lời câu hỏi.
Đáp án chuẩn	Câu trả lời tham chiếu dùng để chấm điểm.
Original / resolved	Câu hỏi gốc / câu hỏi được bổ sung ngữ cảnh để hiểu độc lập.



Original: “Ai thắng?” → **Resolved:** “Ai thắng cuộc bầu cử tổng thống Gabon?”

Ví dụ minh họa cách bổ sung ngữ cảnh; không phải kết quả thực nghiệm.

Thước đo đánh giá

Mô hình sinh gemini-3.1-flash-lite

Truy xuất đoạn đúng

Thước đo	Nội dung đo
Hit Rate@5	Có ít nhất một gold chunk trong top 5?
Recall@5	Tìm được bao nhiêu phần gold chunks?
MRR@5	Gold chunk đầu tiên đứng cao đến đâu?
nDCG@5	Toàn bộ gold chunks được xếp hạng tốt đến đâu?

Giám khảo glm-5p3-flash

Sinh câu trả lời có kiểm chứng

Thước đo	Nội dung đo
Answer Correctness	Nội dung có khớp đáp án chuẩn?
Exact Match	Khớp hoàn toàn sau chuẩn hóa?
Token F1	Token đáp án khớp đúng và đủ?
Faithfulness	Khẳng định có được context hỗ trợ?
Citation F1	Trích đúng và đủ gold chunks?
Citation Validity	Số citation có tồn tại trong context?

Phase 1: ưu tiên MRR@5, đối chiếu nDCG@5 và Hit@5. **Phase 2:** ưu tiên Answer Correctness; Faithfulness và citation là guardrail.

Gold chunk: đoạn chứa evidence chuẩn. Context: các đoạn đưa cho generator. Mọi điểm chất lượng nằm trong khoảng 0–1; cao hơn tốt hơn.

Giải thích thước đo dẫn nguồn: Validity và F1

Đánh giá dẫn nguồn theo hai tầng độc lập: tính hợp lệ cú pháp và độ chính xác đối chiếu với bằng chứng chuẩn.

1. Citation Validity (Hợp lệ cú pháp)

Kiểm tra các chỉ số $[i]$ trong câu trả lời có thuộc phạm vi ngữ cảnh được cấp $\{1, \dots, k\}$ hay không:

$$\text{Validity} = \frac{|C_{\text{hợp lệ}}|}{|C_{\text{hợp lệ}}| + |C_{\text{không hợp lệ}}|}$$

- **Mục đích:** Phát hiện ảo giác cú pháp (chỉ số ngoài dải, ví dụ dẫn [8] khi chỉ cấp $k = 5$ đoạn).
- **Ý nghĩa:** Validity = 1,0 chỉ bảo đảm chỉ số tồn tại, *chưa bảo đảm* dẫn đúng sự thật.

2. Citation F1 (Khớp bằng chứng chuẩn)

Ánh xạ các chỉ số hợp lệ sang tập Chunk ID $\mathcal{C}$ và đối chiếu với tập chunk chuẩn $\mathcal{G}$ (gold evidence):

$$P_{\text{cit}} = \frac{|\mathcal{C} \cap \mathcal{G}|}{|\mathcal{C}|}, \quad R_{\text{cit}} = \frac{|\mathcal{C} \cap \mathcal{G}|}{|\mathcal{G}|}$$

$$\text{Citation F1} = \frac{2 \cdot P_{\text{cit}} \cdot R_{\text{cit}}}{P_{\text{cit}} + R_{\text{cit}}}$$

- **Mục đích:** Đảm bảo câu trả lời neo đúng bằng chứng thực tế, không dẫn đoạn gây nhiễu (distractor).
- **Đặc điểm:** Tính tất định theo tập hợp; bằng 0 nếu dẫn nhầm đoạn dù cú pháp hợp lệ.

Validity kiểm tra trích dẫn có tồn tại trong context; **Citation F1** đo lường trích dẫn có trở đúng bằng chứng chuẩn.

Cả hai thước đo đều được tính tất định (deterministic), không phụ thuộc vào LLM judge.

Kiểm định và điều kiện chọn cấu hình

Tách hai câu hỏi: chênh lệch có phân định được, và cấu hình có được phép chọn?

Kiểm định chênh lệch

$$d_i = m(B, q_i) - m(A, q_i)$$

$$H_0 : \mathbb{E}[d] = 0 \quad H_1 : \mathbb{E}[d] \neq 0$$

Bootstrap	Lấy mẫu lại có hoàn lại để ước lượng CI95.
Bác bỏ H_0	CI95 không chứa 0; mức ý nghĩa 0,05.
Phase 1	Theo câu, 1.000 mẫu.
Phase 2	Theo bài, 2.000 mẫu; giữ các câu cùng bài trong một cụm.

A: đối chứng; B: ứng viên; m: thước đo; q_i : câu hỏi.

Guardrail: điều kiện phải đạt

Dùng Δ trung bình, không dùng CI.


Điều kiện Phase 2	Ngưỡng
Δ Faithfulness	$\geq -0,02$
Δ Citation F1	$\geq -0,01$
Δ Citation Validity	$\geq -0,01$
Coverage sinh và chấm	$\geq 95\%$

Qua guardrail $\longrightarrow$ chọn AC cao nhất trong các ứng viên hợp lệ.

Bài toán và pipeline hệ thống



Đầu vào là câu hỏi; đầu ra là đáp án kèm trích dẫn để người dùng kiểm tra bằng chứng.



Context depth: số đoạn lấy từ đầu danh sách sau xếp hạng lại.


11.064 bài báo CNN · 22.766 chunk · 1.152 câu hỏi resolved

Tập	Số câu	Số bài	Vai trò
Development	281	50	Thử và chọn cấu hình
Held-out hỏi đáp	284	50	Đánh giá cấu hình đã chốt
Phản dự trữ	587	100	Dành cho đánh giá bổ sung

Chia tập theo bài báo để các câu cùng bài không lọt sang cả hai phía. Số chunk ứng với recursive 512/64.

Ví dụ truy vấn đầu-cuối

Một truy vấn thực tế từ tập development: hệ thống truy xuất bằng chứng, sinh câu trả lời và gắn citation có thể kiểm tra.




Ký hiệu	Chunk được dẫn	Bằng chứng trong bài báo
[1]	64646a6038ad_chunk_0	“Swedish golfer Henrik Stenson”; “Stenson stripped down to the bare essentials — a pair of white boxer shorts.”

Citation [1] trở tới context hạng 1 và cho phép kiểm tra trực tiếp bằng chứng.

Nguồn: prediction thành công của cấu hình finalist P2-depth5; question ID 0161b1de8e9944f58ba3663305c9759a.

Thực nghiệm dẫn tới cấu hình ứng dụng

Mỗi vòng chỉ thay đổi một tầng; cấu hình được chọn phải qua đánh giá trên tập chưa dùng để tinh chỉnh.



Quyết định	Giữ cố định	Đầu ra cần có
Retriever / reranker	Dữ liệu và câu hỏi đánh giá	Danh sách context có thứ tự
Prompt / depth	Kết quả truy xuất đã lưu	Đáp án đúng, qua guardrail
Đưa vào ứng dụng	Cấu hình thực nghiệm đã chốt	Chat, trích dẫn và truy xuất nguồn

P0 là system prompt đối chứng. **Baseline** là cấu hình tham chiếu để đo tác động ở tầng sinh.

Phản phụ: ablation về chunking và từ chối trả lời; kết quả không thay cấu hình chốt. Phase 2C được thiết kế sau held-out hỏi đáp.

Chọn retriever: BGE-M3 sparse đi tiếp

Xếp hạng trên câu resolved: ưu tiên MRR@5; nếu hòa, lần lượt xét nDCG@5, Hit@5 và độ trễ. Vòng này chưa dùng reranker.

Retriever	MRR@5	nDCG@5	Hit@5
BGE-M3 sparse	0,8059	0,8317	0,9181
BM25 Okapi + stemming	0,7815	0,8123	0,9146
BM25+	0,6881	0,7206	0,8221
BM25 Okapi	0,6732	0,7087	0,8185
Dense · e5-base-v2	0,6316	0,6684	0,7865
Dense · bge-small-en-v1.5	0,6285	0,6589	0,7651
Dense · bge-large-en-v1.5	0,6252	0,6536	0,7544
Dense · all-MiniLM-L6-v2	0,4851	0,5165	0,6299

Nhóm sparse vượt trội rõ rệt so với dense; BGE-M3 và e5-base-v2 được chọn làm đại diện cho hai nhóm. BGE-M3 hơn BM25-stemmed trên original; trên resolved chưa phân định được.

Development: 281 câu / 50 bài. Không suy ra thứ hạng ổn định giữa các mô hình dense.

Reranker cải thiện thứ tự bằng chứng

So sánh trên câu resolved: ưu tiên MRR@5, sau đó xét nDCG@5.

Retriever	MRR@5			nDCG@5		
	Không	MiniLM	BGE-large	Không	MiniLM	BGE-large
BGE-M3 sparse	0,8059	0,8387	0,8797	0,8317	0,8642	0,8976
Dense · e5-base-v2	0,6316	0,7783	0,7997	0,6684	0,7994	0,8172
Hybrid · sparse + dense	0,7192	0,7938	0,8203	0,7474	0,8164	0,8405

Sparse + BGE-large

+0,0738

Δ MRR@5 so với không rerank

Cái giá: thêm thời gian xếp hạng lại

Sparse	Không rerank	MiniLM	BGE-large
P50 tổng (ms)	66,1	163,9	510,1

Chọn **sparse + BGE-large**. Hybrid không cho thấy lợi ích trong thiết lập đã thử.

P50 là trung vị latency. So sánh trên 281 câu cùng môi trường; độ trễ thực tế phụ thuộc phần cứng và model đã được nạp.

Truy xuất đã chốt: kiểm tra trên bài chưa thấy

Final-test chỉ đánh giá retrieval: 871 câu / 150 bài; không sinh đáp án, không chọn lại cấu hình.

MRR@5 final-test

0,8112

Trung bình nghịch đảo hạng

nDCG@5 final-test

0,8313

Ưu tiên gold ở đầu danh sách

Hit@5 final-test

0,8978

Tỷ lệ câu có gold trong top 5

Chẩn đoán	Development	Final-test truy xuất
Hit@5	0,9573	0,8978
Câu không có gold trong top 5	12/281	89/871

Reranker vẫn tăng nDCG@5 trên final-test: **+0,0758**, CI95 [+0,0504; +0,1017].

Hai tập khác bài nên không ghép cặp dev-final. Held-out hỏi đáp 284 câu là tập con của final-test retrieval này.

Baseline end-to-end: P0, depth 5



Mô hình sinh gemini-3.1-flash-lite

Giám khảo glm-5p3-flash

BGE-M3 sparse → **bge-reranker-large** → **P0 + 5 đoạn context**
P0 đối chứng: trả lời ngắn, chỉ dựa trên context được cung cấp và gắn citation [n].
Recursive 512/64 · Truy xuất 20 ứng viên · Development: 281 câu / 50 bài

Thuốc đo	Baseline
Answer Correctness	0,6308
Faithfulness	0,9761
Exact Match	0,0000
Token F1	0,2648
Citation F1	0,8025
Citation Validity	0,9893

Coverage: 281/281 câu — 100%. RAGAS chấm đủ 281 câu.

Faithfulness cao nhưng EM bằng 0,0000: cần thử prompt giúp đáp án khớp dạng thông tin được hỏi.

Chọn prompt: thử cách yêu cầu đáp án

Giữ nguyên retrieval và depth 5; mỗi prompt chỉ thay đổi chỉ thị dành cho generator.

ID	Giả thuyết	Chỉ thị khác biệt
P0	Đôi chứng	Trả lời ngắn; chỉ dựa trên context; gắn citation [n].
P1	Siết bảm bằng chứng	Chỉ dùng sự kiện được viết rõ; không thêm giả định.
P2	Đúng loại thông tin	Một câu ngắn; không lặp câu hỏi hoặc thêm bối cảnh.
P3	Phân biệt sự kiện	Chọn đoạn khớp chủ thể, sự kiện, địa điểm và thời gian.

Kết quả	AC	Faithfulness	Citation F1	Citation Validity
P0	0,7118	1,0000	0,7808	0,9750
P1	0,6885	0,9750	0,7863	0,9625
P2	0,8363	1,0000	0,8133	0,9750
P3	0,7190	0,9750	0,8146	0,9625

Citation: 80 câu screening. AC và Faithfulness: cùng 20 câu cố định do RAGAS chấm. P2 là prompt triển vọng nhất và được đưa sang thử context depth; chưa quyết định winner tại đây.

Context depth: P0/P2 $\times$ 1/3/5 đoạn

Cùng ranked trace; chỉ cắt còn 1/3/5 đoạn. Depth 5 tái sử dụng từ vòng prompt.

Độ phủ bằng chứng

Depth	Hit@k	Mất gold
1	0,8221	38 câu
3	0,9324	7 câu
5	0,9573	0 câu

Độ phủ giảm mạnh ở depth 1 (mất 38 câu gold so với depth 5).

Chất lượng sàng lọc (P0 vs P2)

Depth	P0				P2			
	AC	Faith.	Cit.F1	Valid.	AC	Faith.	Cit.F1	Valid.
1	0,7063	0,9750	0,7250	0,8167	0,8671	0,9500	0,5500	0,6125
3	0,7046	0,9875	0,7792	0,9500	0,8795	0,9250	0,8125	0,9500
5	0,7118	1,0000	0,7808	0,9750	0,8363	1,0000	0,8133	0,9750

Sàng lọc trên 80 câu; 20 câu tính RAGAS. P2 vượt P0 ở mọi depth.

P2-depth3 và P2-depth5 là hai ứng viên triển vọng nhất được đưa vào đánh giá đủ 281 câu development.

Hit@k tính trên 281 câu từ trace retrieval dùng chung. Không retrieve lại khi đổi prompt hoặc context depth.

Kết quả finalist trên development

Ba cấu hình chạy trên cùng 281 câu / 50 bài; retrieval, reranker và generator model được giữ cố định.

Metric	P0-depth5	P2-depth3	P2-depth5
Answer Correctness	0,6308	0,7711	0,7350
Exact Match	0,0000	0,2633	0,0925
Token F1	0,2648	0,5549	0,4191
Faithfulness	0,9761	0,9561	0,9801
Citation F1	0,8025	0,8381	0,8391
Citation Validity	0,9893	0,9751	0,9858

P2-depth3 dẫn đầu về độ chính xác; bước tiếp theo kiểm tra mức suy giảm grounding và citation bằng guardrail đã đăng ký.

Đây là số tuyệt đối. Slide sau dùng chênh lệch so với P0-depth5 để xác định cấu hình hợp lệ trước khi chọn theo AC.

Chốt P2-depth5: qua guardrail trước khi so AC

Chênh lệch so với baseline P0-depth5 trên cùng 281 câu. Đủ là không đạt ngưỡng đã đăng ký.

Điều kiện	Ngưỡng	P2-depth3	P2-depth5
Δ Faithfulness	$\geq -0,02$	— 0,020029	+0,003992
Δ Citation F1	$\geq -0,01$	+0,035567	+0,036635
Δ Citation Validity	$\geq -0,01$	— 0,014235	— 0,003559
Coverage	$\geq 95\%$	100%	100%
Answer Correctness	Cao nhất trong nhóm hợp lệ	0,7711	0,7350
Quyết định		Loại	Chọn

P2-depth3 có AC cao hơn nhưng trượt hai guardrail. P2-depth5 được chọn để giữ chất lượng bằng chứng và trích dẫn trong ngưỡng cho phép.

Hiện thị sáu chữ số ở các delta để thấy Faithfulness của depth 3 vượt ngưỡng; không quyết định bằng số đã làm tròn.

P2-depth5 cải thiện đáp án trên development

So sánh cùng 281 câu / 50 bài, cùng retrieval, cùng generator; chỉ thay prompt P0 thành P2.

Metric	P0-depth5	P2-depth5	Δ	CI95 của Δ
Answer Correctness	0,6308	0,7350	+0,1043	[+0,0844; +0,1240]
Exact Match	0,0000	0,0925	+0,0925	[+0,0596; +0,1296]
Token F1	0,2648	0,4191	+0,1542	[+0,1317; +0,1786]
Faithfulness	0,9761	0,9801	+0,0040	[−0,0127; +0,0189]
Citation F1	0,8025	0,8391	+0,0366	[+0,0127; +0,0616]
Citation Validity	0,9893	0,9858	−0,0036	[−0,0112; +0,0000]

Kết quả trên development dùng để chọn cấu hình; held-out ở slide sau mới dùng để đánh giá cấu hình đã chốt.

Held-out: kết quả của cấu hình đã chốt

P2-depth5 · 284 câu / 50 bài chưa dùng để chọn prompt · Không chạy baseline để chọn lại trên held-out.

AC held-out

0,7157

284/284 câu · coverage 100%

Đơn vị tổng hợp

Bảng bên phải lấy trung bình theo câu.

AC trung bình theo bài: **0,7230**.

P2-depth5	Dev	Held-out
Answer Correctness	0,7350	0,7157
Faithfulness	0,9801	0,9249
Exact Match	0,0925	0,1092
Token F1	0,4191	0,4313
Citation F1	0,8391	0,7289
Citation Validity	0,9858	0,9437

Dev và held-out là hai tập khác nhau. Bảng mô tả khả năng tổng quát hóa, không phải so sánh A/B theo cặp.

Có bằng chứng trong context thì kết quả khác gì?

Tách các câu có và không có gold trong top 5 để tránh quy mọi lỗi cho mô hình sinh. Cùng cấu hình P2-depth5.

Nhóm câu hỏi	Dev: số câu	AC dev	Held-out: số câu	AC held-out
Có gold trong context	269	0,7597	249	0,7689
Không có gold trong context	12	0,1829	35	0,3375

Khi có gold

AC ở mức cao hơn trên cả hai tập. Tầng sinh có thể khai thác bằng chứng đã được đưa vào context.

Dev: 269/281 câu Held-out: 249/284 câu

Khi không có gold

Cần kiểm tra truy xuất và nhấn bằng chứng. Đôi prompt không tự bổ sung được đoạn bị thiếu.

Dev: 12/281 câu Held-out: 35/284 câu

Không có gold theo nhãn không đồng nghĩa không có đáp án hợp lý. Phân tầng này là chẩn đoán, không chứng minh nguyên nhân duy nhất.

Thử nghiệm mở rộng: Động lực và thiết kế Prompt one-shot

Theo góp ý GVHD: kiểm tra xem bổ sung 1 ví dụ mẫu in-context có giúp định hình câu trả lời ngắn và chuẩn hóa citation không.

Động lực và thiết lập thử nghiệm

- ▶ **Vấn đề ở Zero-shot:** Dữ liệu NewsQA dùng đáp án chuẩn là thực thể trích xuất ngắn (extractive span, vd: “26”, “March 2021”). Prompt zero-shot (P0) sinh câu thoại hoàn chỉnh $\Rightarrow$ Exact Match bằng 0.
- ▶ **Mục tiêu:** Dùng 1 ví dụ mẫu để mô hình bắt chước trực quan cấu trúc: *câu trả lời cực ngắn đúng thực thể + citation [n] ngay sau đáp án*.
- ▶ **Thiết lập:** Bổ sung 1 ví dụ tổng hợp vào prompt P2 tạo thành **P2-1S**. Ví dụ nhân tạo, không lấy từ NewsQA hay tập kiểm tra.
- ▶ **Kiểm chứng:** Giữ cố định BGE-M3 + BGE reranker, depth 5, Gemini 3.1 Flash-Lite; so sánh ghép cặp trên 281 câu dev.

Mẫu ví dụ in-context bổ sung trong P2-1S

Demonstration (format example only):

Context [1]: The Northbridge museum opened a new gallery in 2018.

Context [2]: The city council approved the Riverside transit plan in March 2021.

Question: When was the Riverside transit plan approved?

Answer: March 2021 [2]

- ▶ **Chỉ rõ loại thông tin:** Rút trích trực tiếp mốc thời gian, không lặp lại câu hỏi.
- ▶ **Chuẩn hóa vị trí citation:** Đặt ngay sau thông tin được dẫn chứng để bảo đảm tính kiểm chứng.

Một ví dụ in-context đóng vai trò trực quan hóa định dạng mong muốn: trả lời ngắn gọn đúng thực thể và gắn citation chuẩn xác.

Ví dụ được thiết kế tổng hợp (synthetic), bảo đảm không rò rỉ dữ liệu từ tập huấn luyện hoặc kiểm tra.

Prompt one-shot: Kết quả và phân tích đánh đổi

So sánh ghép cặp trên 281 câu development và phân tích nguyên nhân đánh đổi giữa các thước đo.

Bảng kết quả ghép cặp (P2-1S vs P2 zero-shot)

Thước đo	P2 dev	P2-1S dev	Δ ghép cặp	CI95 của Δ
Answer Correctness	0,7350	0,8015	+0,0664	[+0,0444; +0,0883]
Exact Match	0,0925	0,3559	+0,2634	—
Token F1	0,4191	0,6267	+0,2076	[+0,1728; +0,2427]
Faithfulness	0,9801	0,9603	-0,0199	[-0,0388; -0,0028]
Answer Relevancy	0,7092	0,5251	-0,1841	[-0,2233; -0,1458]
Citation F1	0,8391	0,8441	+0,0050	[-0,0104; +0,0229]
Citation Validity	0,9858	0,9786	-0,0071	[-0,0182; 0,0000]

Trên held-out độc lập (284 câu): P2-1S đạt AC = 0,7557; Token F1 = 0,6032; EM = 0,3239.

Phân tích hiện tượng đánh đổi

- **Cải thiện vượt bậc:** AC tăng +0,0664; Token F1 tăng +0,2076; Exact Match tăng gần 4× (0,0925 → 0,3559) do mô hình bắt chước format span ngắn.
- **Đánh đổi Faithfulness:** Giảm nhẹ (-0,0199), nằm sát ngưỡng guardrail 0,02.
- **Nghịch lý Answer Relevancy:** Trung vị độ dài giảm từ 11 xuống 7 từ; số đáp án ≤ 3 từ tăng từ 23 lên 105.
- **Lý do Relevancy giảm:** Khi đáp án quá ngắn (vd: “Scotland [1]”), RAGAS sinh câu hỏi ngược thiếu chủ thể $\Rightarrow$ Relevancy bị phạt xuống 0,037 dù AC đạt 1,00. Có 109/133 câu Relevancy < 0,5 vẫn có AC $\geq 0,8$.

One-shot tăng mạnh độ đúng và Token F1 nhưng đánh đổi Faithfulness và Relevancy. Khảo sát giải thích đánh đổi, không thay cấu hình zero-shot đã chốt.

Đánh giá trên 281 câu development; đối chứng P2 zero-shot được tái sử dụng, không sinh lại.

Thử nghiệm mở rộng: So sánh chất lượng các mô hình sinh

Mục tiêu: Đánh giá chất lượng sinh khi đổi generator. Cùng 281 câu dev, trace retrieval, depth 5, prompt P2-1S, temp 0; cùng judge GLM-5.3 Flash.

Bảng so sánh chất lượng sinh trên 281 câu development

Mô hình generator	Token F1	AC	Faith.	AR	Cit.F1	Valid.
Gemini 3.1 Flash-Lite	0,6267	0,8015	0,9603	0,5251	0,8441	0,9786
Gemini 3.5 Flash-Lite	0,6803	0,8164	0,9557	0,4351	0,8351	0,9680
Gemini 3.6 Flash	0,6934	0,8011	0,9472	0,3837	0,8248	0,9644

Gemini 3.5 Flash-Lite

AC trung bình cao nhất (0,8164), nhưng Faithfulness (0,9557) và Citation F1 (0,8351) thấp hơn 3.1 Flash-Lite.

Gemini 3.6 Flash

Token F1 cao nhất (0,6934) nhưng AC không tăng (0,8011); Citation F1 giảm sâu xuống 0,8248.

Mô hình lớn hơn không tự động cải thiện toàn diện: 3.5 nhỉnh hơn về AC nhưng 3.1 Flash-Lite duy trì độ tin cậy và dẫn nguồn tốt nhất.

Cả ba lần chạy đều dùng chung 666.604 token ngữ cảnh đầu vào và cùng giám khảo GLM-5.3 Flash.

Mô hình sinh: Đánh đổi tài nguyên, độ trễ và quyết định

So sánh chi phí tài nguyên, độ trễ thực tế và lý giải quyết định lựa chọn mô hình đích.

Tài nguyên và kiểm định ΔAC

Mô hình	ΔAC	CI95 của ΔAC	LLM P95	Token ra
3.1 Flash-Lite	Đối chứng	—	1,02 s	3.847
3.5 Flash-Lite	+0,0149	[−0,0052; +0,0359]	0,89 s	3.112
3.6 Flash	−0,0003	[−0,0204; +0,0195]	3,50 s (3,4×)	3.249

- ▶ **Kiểm định ΔAC :** Mức chênh lệch không có ý nghĩa thống kê; mô hình lớn hơn không đem lại cải thiện vượt trội.
- ▶ **Lượng token sinh:** Cả 3 mô hình xuất ra lượng token tương đương nhau ($\sim 3,1k$ – $3,8k$ tokens trên 281 câu).

Đánh đổi thực tế và quyết định

- ▶ **Gemini 3.6 Flash (Đánh đổi bất lợi):** Độ trễ P95 tăng vọt lên 3,50 s ($3,4\times$) trong khi AC không đổi; độ trung thực và dẫn nguồn đều giảm.
- ▶ **Gemini 3.5 Flash-Lite:** Tốc độ nhanh nhất (0,89 s) nhưng đánh đổi tính trung thực và chất lượng citation.
- ▶ **Quyết định cho NewsLens:** Giữ vững **Gemini 3.1 Flash-Lite** làm mô hình đích — tối ưu hài hòa giữa chất lượng, dẫn nguồn và thời gian phản hồi.

Chi phí tăng không tương xứng với chất lượng: Gemini 3.1 Flash-Lite là điểm cân bằng tối ưu giữa độ chính xác, dẫn nguồn và độ trễ cho NewsLens.

P95 chỉ tính các lượt gọi sinh thành công; token ra không bao gồm token chấm điểm của LLM judge.

Từ thực nghiệm đến cấu hình đích của NewsLens

Đây là cấu hình đã được đánh giá. Khi đưa vào ứng dụng, cần giữ đúng cả retrieval, prompt và generator.

Tầng	Lựa chọn chốt	Căn cứ thực nghiệm
Chia đoạn	Recursive 512/64	Giữ cấu hình sau khảo sát chunking
Truy xuất	BGE-M3 sparse · top-k 20	Đưa ứng viên chứa bằng chứng vào vòng rerank
Xếp hạng lại	bge-reranker-large	Cải thiện nDCG trên dev và final-test
Context	Top 5 đoạn đã rerank	Giữ bằng chứng; qua guardrail
Sinh đáp án	P2 + gemini-3.1-flash-lite	Câu ngắn, đúng loại thông tin, citation [n]

Kết quả đích: AC held-out 0,7157 trên 284 câu. Điểm này gắn với cấu hình trên; đổi model hoặc prompt cần đánh giá lại.

Giám khảo glm-5p3-flash phục vụ đánh giá ngoại tuyến, không phải một tầng bắt buộc trong mỗi lượt chat.

Khảo sát phụ: vì sao giữ cấu hình đã chốt?

Các thay đổi không được áp dụng; vai trò là kiểm tra lựa chọn chính, không mở thêm một vòng chọn trên held-out.

Khảo sát	Thay đổi được thử	Kết quả và quyết định
Kích thước chunk Development: 281 câu	Chunk ngắn / vừa / dài	Spread nDCG@5: 0,0469; chưa phân định được. Giữ 512/64.
Contextual chunking Resolved: 1.152 câu	Thêm ngữ cảnh bài báo trước chunk	Dense tăng +0,0293; sparse giảm -0,0208 nDCG@5. Không thêm vào nhánh sparse.
Phase 2C Development: 281 câu	Theo câu, đoạn; child–parent	C3-depth3 tăng AC +0,0380 nhưng trượt Citation F1, Hit@5, Recall@5. Không đổi winner.
Chính sách từ chối Development: 140 case	Schema answerability; cổng theo reranker	Token F1 ở câu có bằng chứng giảm -0,1070. Giữ B0 (chính prompt P2).

Không thay cấu hình chính chỉ vì một điểm tăng: kiểm tra bằng chứng, trích dẫn và phạm vi mẫu trước khi áp dụng.

Phase 2C là khảo sát sau held-out. Thử từ chối đồng thời đổi schema và chỉ thị đáp án, nên chưa tách được tác động của từng yếu tố.

NewsLens: kết quả chốt và bước đưa vào sử dụng

Truy xuất bằng chứng, sinh đáp án có citation, rồi kiểm tra từng tầng trước khi đưa cấu hình vào ứng dụng.

Truy xuất · Hit@5

0,8978

871 câu final-test

Hỏi đáp · AC

0,7157

284 câu held-out

P2 so với P0 · Δ AC

+0,1043

281 câu development

BGE-M3 sparse → bge-reranker-large → P2 + depth 5 → Gemini

Đưa vào sử dụng	Đồng bộ P2 và Gemini trong chat; nghiệm thu câu hỏi → đáp án → nguồn.
Giới hạn cần nhớ	Benchmark dùng câu resolved và nhãn gold hữu hạn; điểm RAGAS phụ thuộc giám khảo.
Kiểm tra tiếp	Audit mù đáp án, đo độ ổn định API, và thử câu hỏi người dùng chưa bổ sung ngữ cảnh.