

ĐỒ ÁN MÔN HỌC

NEWSLENS

Hệ thống hỏi đáp tin tức có dẫn nguồn

Ứng dụng RAG trên bộ dữ liệu NewsQA

Môn học: Khai thác dữ liệu và văn bản

Giảng viên: Lê Thanh Tùng


Nhóm thực hiện: Nhóm 9

Tìm bằng chứng trong kho tin tức, sinh đáp án có trích dẫn
và đánh giá từng bước của hệ thống.

Thuật ngữ: dữ liệu và bằng chứng

Phân biệt văn bản được tìm kiếm, bằng chứng được gán nhãn và câu hỏi dùng để đánh giá.

Thuật ngữ	Nghĩa trong dự án
Corpus / distractor	Kho bài báo để tìm kiếm / bài không được gán bằng chứng cho bộ câu hỏi đánh giá.
Chunk	Đoạn văn cắt từ bài báo để lập chỉ mục và truy xuất.
Evidence span	Vị trí đoạn bằng chứng trong văn bản gốc.
Gold chunk	Chunk được gán nhãn chứa bằng chứng trả lời câu hỏi.
Đáp án chuẩn	Câu trả lời tham chiếu dùng để chấm điểm.
Original / resolved	Câu hỏi gốc / câu hỏi được bổ sung ngữ cảnh để hiểu độc lập.



Original: “Ai thắng?” → **Resolved:** “Ai thắng cuộc bầu cử tổng thống Gabon?”

Ví dụ minh họa cách bổ sung ngữ cảnh; không phải kết quả thực nghiệm.

Đo độ đúng, bằng chứng và trích dẫn

Mô hình sinh	gemini-3.1-flash-lite	Giám khảo	glm-5p3-flash
Nhóm	Thước đo	Câu hỏi cần trả lời	
Đáp án	Answer Correctness — AC	Nội dung có khớp đáp án chuẩn?	
	Exact Match — EM	Khớp hoàn toàn sau chuẩn hóa?	
	Token F1	Các từ trong đáp án khớp đúng và đủ đến đâu?	
Bằng chứng	Faithfulness	Các khẳng định có được context hỗ trợ?	
Trích dẫn	Citation F1	Trích đúng và đủ đoạn bằng chứng?	
	Citation Validity	Chỉ số trích dẫn có hợp lệ trong context?	

RAGAS dùng mô hình giám khảo để chấm AC và Faithfulness.

Coverage là tỷ lệ câu chạy thành công hoặc được chấm trong tập cần đánh giá.

Context: các đoạn cung cấp cho mô hình sinh. Các điểm chất lượng có thang 0–1; cao hơn tốt hơn.

Kiểm định và điều kiện chọn cấu hình

Tách hai câu hỏi: chênh lệch có phân định được, và cấu hình có được phép chọn?

Kiểm định chênh lệch

$$d_i = m(B, q_i) - m(A, q_i)$$

$$H_0 : \mathbb{E}[d] = 0 \quad H_1 : \mathbb{E}[d] \neq 0$$

Bootstrap	Lấy mẫu lại có hoàn lại để ước lượng CI95.
Bác bỏ H_0	CI95 không chứa 0; mức ý nghĩa 0,05.
Phase 1	Theo câu, 1.000 mẫu.
Phase 2	Theo bài, 2.000 mẫu; giữ các câu cùng bài trong một cụm.

A: đối chứng; B: ứng viên; m : thước đo; q_i : câu hỏi.

Guardrail: điều kiện phải đạt

Dùng Δ trung bình, không dùng CI.

Điều kiện Phase 2	Ngưỡng
Δ Faithfulness	$\geq -0,02$
Δ Citation F1	$\geq -0,01$
Δ Citation Validity	$\geq -0,01$
Coverage sinh và chấm	$\geq 95\%$

Qua guardrail $\longrightarrow$ chọn AC cao nhất trong các ứng viên hợp lệ.

Bài toán và pipeline hệ thống

Đầu vào là câu hỏi; đầu ra là đáp án kèm trích dẫn để người dùng kiểm tra bằng chứng.



Context depth: số đoạn lấy từ đầu danh sách sau xếp hạng lại.

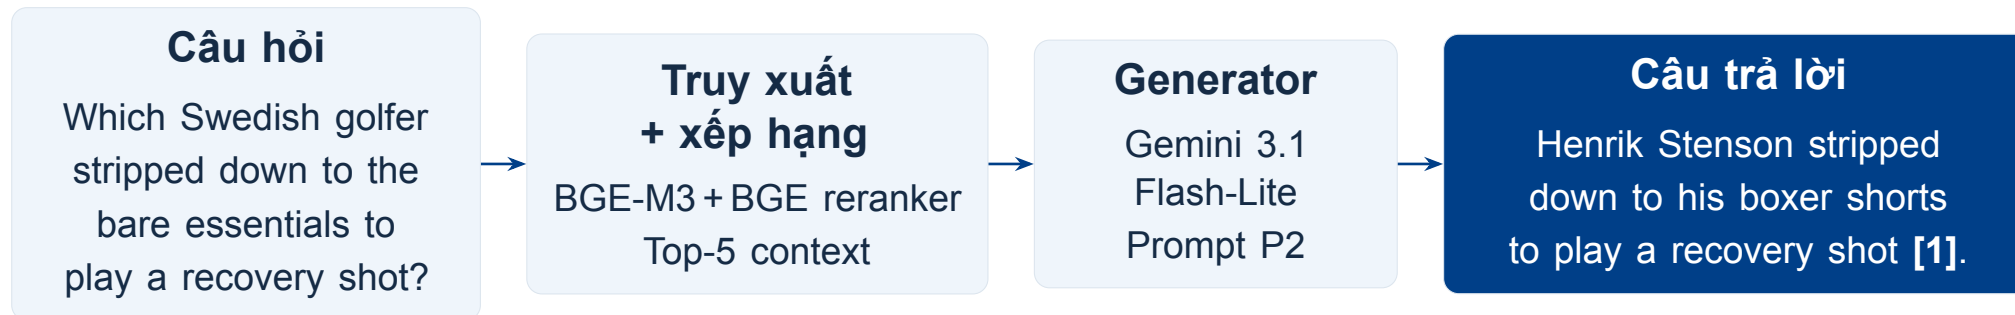
11.064 bài báo CNN · 22.766 chunk · 1.152 câu hỏi resolved

Tập	Số câu	Số bài	Vai trò
Development	281	50	Thử và chọn cấu hình
Held-out hỏi đáp	284	50	Đánh giá cấu hình đã chốt
Phản dự trữ	587	100	Dành cho đánh giá bổ sung

Chia tập theo bài báo để các câu cùng bài không lọt sang cả hai phía. Số chunk ứng với recursive 512/64.

Ví dụ truy vấn đầu-cuối

Một truy vấn thực tế từ tập development: hệ thống truy xuất bằng chứng, sinh câu trả lời và gắn citation có thể kiểm tra.



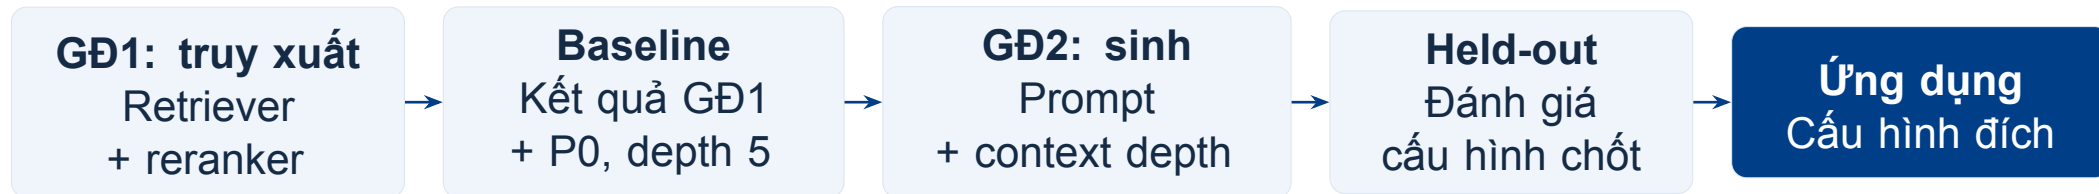
Ký hiệu	Chunk được dẫn	Bằng chứng trong bài báo
[1]	64646a6038ad_chunk_0	“Swedish golfer Henrik Stenson”; “Stenson stripped down to the bare essentials — a pair of white boxer shorts.”

Citation [1] trở tới context hạng 1 và cho phép kiểm tra trực tiếp bằng chứng.

Nguồn: prediction thành công của cấu hình finalist P2-depth5; question ID 0161b1de8e9944f58ba3663305c9759a.

Thực nghiệm dẫn tới cấu hình ứng dụng

Mỗi vòng chỉ thay đổi một tầng; cấu hình được chọn phải qua đánh giá trên tập chưa dùng để tinh chỉnh.



Quyết định	Giữ cố định	Đầu ra cần có
Retriever / reranker	Dữ liệu và câu hỏi đánh giá	Danh sách context có thứ tự
Prompt / depth	Kết quả truy xuất đã lưu	Đáp án đúng, qua guardrail
Đưa vào ứng dụng	Cấu hình thực nghiệm đã chốt	Chat, trích dẫn và truy xuất nguồn

P0 là system prompt đối chứng. **Baseline** là cấu hình tham chiếu để đo tác động ở tầng sinh.

Phản phụ: ablation về chunking và từ chối trả lời; kết quả không thay cấu hình chốt. Phase 2C được thiết kế sau held-out hỏi đáp.

Baseline end-to-end: P0, depth 5

Mô hình sinh gemini-3.1-flash-lite

Giám khảo glm-5p3-flash

BGE-M3 sparse → **bge-reranker-large** → **P0 + 5 đoạn context**

Recursive 512/64 · Truy xuất 20 ứng viên · Development: 281 câu / 50 bài

Thuốc đo	Baseline
Answer Correctness	0,6308
Faithfulness	0,9761
Exact Match	0,0000
Token F1	0,2648
Citation F1	0,8025
Citation Validity	0,9893

Coverage: 281/281 câu — 100%. RAGAS chấm đủ 281 câu.

Faithfulness cao nhưng EM bằng 0,0000: cần thử prompt giúp đáp án khớp dạng thông tin được hỏi.

Chọn retriever: BGE-M3 sparse đi tiếp

nDCG@5 đo mức ưu tiên gold chunk ở đầu danh sách; cao hơn tốt hơn. Vòng này chưa dùng reranker.

Retriever	Original	Resolved — nDCG@5 (0–1)
BGE-M3 sparse	0,4243	0,8317
BM25 Okapi + stemming	0,3563	0,8123
BM25+	0,2436	0,7206
BM25 Okapi	0,2420	0,7087
Dense · e5-base-v2	0,2263	0,6684
Dense · bge-small-en-v1.5	0,2249	0,6589
Dense · bge-large-en-v1.5	0,2325	0,6536
Dense · all-MiniLM-L6-v2	0,1788	0,5165

Sparse hơn e5-base: $\Delta +0,1634$, CI95 [$+0,1231$; $+0,2080$].

BGE-M3 hơn BM25-stemmed trên original; trên resolved chưa phân định được.

Development: 281 câu / 50 bài. Không suy ra thứ hạng ổn định giữa các mô hình dense.

Reranker cải thiện thứ tự bằng chứng

Giữ các retriever đi tiếp, so sánh không xếp hạng lại, MiniLM và bge-reranker-large trên development.

nDCG@5 — resolved	Không rerank	MiniLM-L6	BGE-large
BGE-M3 sparse	0,8317	0,8642	0,8976
Dense · e5-base-v2	0,6684	0,7994	0,8172
Hybrid · sparse + dense	0,7474	0,8164	0,8405

Sparse + BGE-large

+0,0659

Δ nDCG@5 so với không rerank

Cái giá: thêm thời gian xếp hạng lại

Sparse	Không rerank	MiniLM	BGE-large
P50 tổng (ms)	66,1	163,9	510,1

Chọn **sparse + BGE-large**. Hybrid không chứng minh được lợi ích trong thiết lập đã thử.

P50 là trung vị latency. So sánh trên 281 câu cùng môi trường; độ trễ thực tế phụ thuộc phần cứng và model đã được nạp.

Truy xuất đã chốt: kiểm tra trên bài chưa thấy

Final-test chỉ đánh giá retrieval: 871 câu / 150 bài; không sinh đáp án, không chọn lại cấu hình.

Hit@5 final-test

0,8978

Tỷ lệ câu có gold trong top 5

nDCG@5 final-test

0,8313

Ưu tiên gold ở đầu danh sách

MRR@5 final-test

0,8112

Trung bình nghịch đảo hạng


Chẩn đoán	Development	Final-test truy xuất
Hit@5	0,9573	0,8978
Câu không có gold trong top 5	12/281	89/871

Reranker vẫn tăng nDCG@5 trên final-test: **+0,0758**, CI95 [+0,0504; +0,1017].

Hai tập khác bài nên không ghép cặp dev-final. Held-out hỏi đáp 284 câu là tập con của final-test retrieval này.

Ví dụ truy xuất và xếp hạng lại

Minh họa một trace thực: BGE-M3 lấy 20 ứng viên từ chỉ mục; cross-encoder đọc từng cặp câu hỏi–chunk và giữ 5 context.




Hạng BGE-M3	Nội dung chunk	Điểm reranker	Hạng reranker	Kết quả
1	64646a..._0: Henrik Stenson; recovery shot	9,3047	1	Giữ
2	c7f52d..._0: lịch sử U.S. Open golf	−6, 0	10	Loại
8	9a3ab5..._0: hickory golf; Thụy Điển	−5, 2578	5	Giữ
15	6c21ba..._0: VĐV Thụy Điển; huy chương	−4, 2	3	Giữ

Chọn theo thứ hạng tương đối, không theo dấu của score. Đầu ra: 5 context có thứ tự kèm ID, điểm, metadata và văn bản.

Chọn prompt: thử cách yêu cầu đáp án

Giữ nguyên retrieval và depth 5. Sàng lọc trên 80 câu; AC do RAGAS chấm trên 20 câu cố định.

ID	Giả thuyết	Chỉ thị khác biệt	AC sàng lọc
P0	Đối chứng	Trả lời ngắn, dựa vào context, có citation.	0,7118
P1	Siết bám bằng chứng	Chỉ dùng sự kiện được viết rõ; không thêm giả định.	0,6885
P2	Đúng loại thông tin	Một câu trả lời ngắn; không lặp câu hỏi hoặc thêm bối cảnh.	0,8363
P3	Phân biệt sự kiện	Chọn đoạn khớp chủ thể, sự kiện, địa điểm và thời gian.	0,7190



Sàng lọc chọn ứng viên P2 để thử depth. Chưa dùng các điểm trên mẫu nhỏ này làm kết quả cuối cùng.

Context depth: bớt đoạn, mất bằng chứng nào?

Cắt từ đầu cùng danh sách đã rerank. Đọc Hit@k trước để thấy chi phí của việc giảm context.

Depth	Hit@k	Số câu mất gold so với depth 5
1 đoạn	0,8221	38 câu
3 đoạn	0,9324	7 câu
5 đoạn	0,9573	Mốc đối chứng: giữ toàn bộ top 5

P2 · depth 3

0,7711

AC trên toàn bộ development

P2 · depth 5

0,7350

AC trên toàn bộ development

Hai ứng viên chung kết

Depth 1 dừng ở sàng lọc.

P2-depth3 và P2-depth5 được chạy đủ 281 câu.

AC cao chưa đủ: bước tiếp theo là kiểm tra guardrail.

Hit@k tính trên 281 câu development từ trace retrieval dùng chung; không phải một lần truy xuất mới cho mỗi depth.

Chốt P2-depth5: qua guardrail trước khi so AC

Chênh lệch so với baseline P0-depth5 trên cùng 281 câu. Đủ là không đạt ngưỡng đã đăng ký.

Điều kiện	Ngưỡng	P2-depth3	P2-depth5
Δ Faithfulness	$\geq -0,02$	— 0,020029	+0,003992
Δ Citation F1	$\geq -0,01$	+0,035567	+0,036635
Δ Citation Validity	$\geq -0,01$	— 0,014235	— 0,003559
Coverage	$\geq 95\%$	100%	100%
Answer Correctness	Cao nhất trong nhóm hợp lệ	0,7711	0,7350
Quyết định		Loại	Chọn

P2-depth3 có AC cao hơn nhưng trượt hai guardrail. P2-depth5 được chọn để giữ chất lượng bằng chứng và trích dẫn trong ngưỡng cho phép.

Hiện thị sáu chữ số ở các delta để thấy Faithfulness của depth 3 vượt ngưỡng; không quyết định bằng số đã làm tròn.

P2-depth5 cải thiện đáp án trên development

So sánh cùng 281 câu / 50 bài, cùng retrieval, cùng generator; chỉ thay prompt P0 thành P2.

Thước đo	P0-depth5	P2-depth5
Answer Correctness	0,6308	0,7350
Exact Match	0,0000	0,0925
Token F1	0,2648	0,4191
Faithfulness	0,9761	0,9801
Citation F1	0,8025	0,8391
Citation Validity	0,9893	0,9858

Cải thiện AC

+0,1043

CI95 [+0,0844; +0,1240]

Điều thay đổi trong đáp án

P2 yêu cầu một câu ngắn, đúng loại thông tin được hỏi, kèm citation ngay sau đáp án.

AC, EM và Token F1 tăng. Faithfulness qua guardrail nhưng CI của chênh lệch chứa 0: chưa chứng minh được bám bằng chứng tốt hơn.

Kết quả trên development dùng để chọn cấu hình; held-out ở slide sau mới dùng để đánh giá cấu hình đã chốt.

Held-out: kết quả của cấu hình đã chốt

P2-depth5 · 284 câu / 50 bài chưa dùng để chọn prompt · Không chạy baseline để chọn lại trên held-out.

Chốt cấu hình: 13:31:30 UTC

Bắt đầu held-out: 14:23:24 UTC (2026-09-06)

AC held-out

0,7157

284/284 câu · coverage 100%

Đơn vị tổng hợp

Bảng bên phải lấy trung bình theo câu.

AC trung bình theo bài: **0,7230**.

P2-depth5	Dev	Held-out
Answer Correctness	0,7350	0,7157
Faithfulness	0,9801	0,9249
Exact Match	0,0925	0,1092
Token F1	0,4191	0,4313
Citation F1	0,8391	0,7289
Citation Validity	0,9858	0,9437

Dev và held-out là hai tập khác nhau. Bảng mô tả khả năng tổng quát hóa, không phải so sánh A/B theo cặp.

Có bằng chứng trong context thì kết quả khác gì?

Tách các câu có và không có gold trong top 5 để tránh quy mọi lỗi cho mô hình sinh. Cùng cấu hình P2-depth5.

Nhóm câu hỏi	Dev: số câu	AC dev	Held-out: số câu	AC held-out
Có gold trong context	269	0,7597	249	0,7689
Không có gold trong context	12	0,1829	35	0,3375

Khi có gold

AC ở mức cao hơn trên cả hai tập. Tầng sinh có thể khai thác bằng chứng đã được đưa vào context.

Dev: 269/281 câu Held-out: 249/284 câu

Khi không có gold

Cần kiểm tra truy xuất và nhấn bằng chứng. Đòi prompt không tự bổ sung được đoạn bị thiếu.

Dev: 12/281 câu Held-out: 35/284 câu

Không có gold theo nhãn không đồng nghĩa không có đáp án hợp lý. Phân tầng này là chẩn đoán, không chứng minh nguyên nhân duy nhất.

Từ thực nghiệm đến cấu hình đích của NewsLens

Đây là cấu hình đã được đánh giá. Khi đưa vào ứng dụng, cần giữ đúng cả retrieval, prompt và generator.

Tầng	Lựa chọn chốt	Căn cứ thực nghiệm
Chia đoạn	Recursive 512/64	Giữ cấu hình sau khảo sát chunking
Truy xuất	BGE-M3 sparse · top-k 20	Đưa ứng viên chứa bằng chứng vào vòng rerank
Xếp hạng lại	bge-reranker-large	Cải thiện nDCG trên dev và final-test
Context	Top 5 đoạn đã rerank	Giữ bằng chứng; qua guardrail
Sinh đáp án	P2 + gemini-3.1-flash-lite	Câu ngắn, đúng loại thông tin, citation [n]

Kết quả đích: AC held-out 0,7157 trên 284 câu. Điểm này gắn với cấu hình trên; đổi model hoặc prompt cần đánh giá lại.

Giám khảo glm-5p3-flash phục vụ đánh giá ngoại tuyến, không phải một tầng bắt buộc trong mỗi lượt chat.

Ứng dụng: hỏi đáp và mở bằng chứng



Luồng tương tác đã có trong code; phần cần hoàn thiện là đồng bộ cấu hình sinh với winner thực nghiệm.



Thành phần	Hiện trạng code	Để khớp benchmark
Retrieval và nguồn	Có nhánh sparse + reranker; có mở citation	Nạp đúng bộ chỉ mục đã chốt
Prompt sinh	Chat đang dùng prompt mặc định P0	Nối prompt P2 vào luồng chat
Model sinh	Chọn qua runtime; mặc định gpt-4o-mini	Chọn gemini-3.1-flash-lite
Chế độ trả lời	Có fallback sang chat trực tiếp khi RAG không sẵn sàng	Xác nhận lượt demo thực sự dùng RAG

Sơ đồ chức năng đối chiếu từ code, không phải ảnh chụp một phiên demo. Chưa có nghiệm thu end-to-end của app với cấu hình winner.

Khảo sát phụ: vì sao giữ cấu hình đã chốt?

Các thay đổi không được áp dụng; vai trò là kiểm tra lựa chọn chính, không mở thêm một vòng chọn trên held-out.

Khảo sát	Thay đổi được thử	Kết quả và quyết định
Kích thước chunk Development: 281 câu	Chunk ngắn / vừa / dài	Spread nDCG@5: 0,0469; chưa phân định được. Giữ 512/64.
Contextual chunking Resolved: 1.152 câu	Thêm ngữ cảnh bài báo trước chunk	Dense tăng +0,0293; sparse giảm -0,0208 nDCG@5. Không thêm vào nhánh sparse.
Phase 2C Development: 281 câu	Theo câu, đoạn; child-parent	C3-depth3 tăng AC +0,0380 nhưng trượt Citation F1, Hit@5, Recall@5. Không đổi winner.
Chính sách từ chối Development: 140 case	Schema answerability; cổng theo reranker	Token F1 ở câu có bằng chứng giảm -0,1070. Giữ B0 (chính prompt P2).

Không thay cấu hình chính chỉ vì một điểm tăng: kiểm tra bằng chứng, trích dẫn và phạm vi mẫu trước khi áp dụng.

Phase 2C là khảo sát sau held-out. Thử từ chối đồng thời đổi schema và chỉ thị đáp án, nên chưa tách được tác động của từng yếu tố.

NewsLens: kết quả chốt và bước đưa vào sử dụng

Truy xuất bằng chứng, sinh đáp án có citation, rồi kiểm tra từng tầng trước khi đưa cấu hình vào ứng dụng.

Truy xuất · Hit@5

0,8978

871 câu final-test

Hỏi đáp · AC

0,7157

284 câu held-out

P2 so với P0 · Δ AC

+0,1043

281 câu development

BGE-M3 sparse → bge-reranker-large → P2 + depth 5 → Gemini

Đưa vào sử dụng	Đồng bộ P2 và Gemini trong chat; nghiệm thu câu hỏi → đáp án → nguồn.
Giới hạn cần nhớ	Benchmark dùng câu resolved và nhãn gold hữu hạn; điểm RAGAS phụ thuộc giám khảo.
Kiểm tra tiếp	Audit mù đáp án, đo độ ổn định API, và thử câu hỏi người dùng chưa bổ sung ngữ cảnh.